

Universidad Internacional de La Rioja

Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Inteligencia artificial

Estrategia inteligente para la detección del desgaste en imágenes BLMD

Trabajo fin de estudio presentado por:	Alcalde Martín-Calero, Daniel González Sánchez, Miguel Peiró Castelló, Jordi
Tipo de trabajo:	Desarrollo software Comparativa de soluciones
Director/a:	Gil Del Val, Alain
Fecha:	15/07/2026

Resumen

La detección automática del desgaste en herramientas de roscado es un problema crítico de control de calidad industrial, condicionado por la escasez de datos etiquetados y por condiciones de captura adversas (reflejos e iluminación variable). Este trabajo aborda la detección de desgaste en roscas métricas M10×1,5 a partir de imágenes ópticas, planteado deliberadamente como una comparativa experimental de soluciones bajo un marco común, en lugar de defender a priori un único modelo. Sobre un conjunto de 22 herramientas (11 conformes y 11 con desgaste; ~262 imágenes etiquetadas a nivel de pieza) se comparan seis variantes de preprocesado multiescala (BLMD riguroso, una aproximación rápida tipo paso-alto, BEMD, wavelet, filtrado homomórfico y sin preprocesado) y cuatro estrategias de inteligencia artificial complementarias: detección de anomalías con PatchCore, clasificación supervisada débil mediante Multiple Instance Learning con EfficientNet-B0, adaptación del modelo fundacional de segmentación SAM mediante LoRA y segmentación con U-Net entrenada con máscaras sintéticas del perfil ISO. La evaluación se realiza a nivel de rosca y atiende a precisión, robustez, coste computacional e interpretabilidad. Los resultados muestran que un filtrado paso-alto computacionalmente económico supera a la descomposición rigurosa y que los enfoques basados en textura aprendida superan claramente a los puramente geométricos. El hallazgo principal es que, en este dominio, el desgaste se manifiesta como un cambio de textura superficial y no como una deformación macroscópica del perfil, lo que reorienta el problema desde la metrología hacia la caracterización de la textura

Palabras clave Inteligencia artificial, visión artificial, detección de desgaste, segmentación de imágenes, rosca métrica.

Abstract

Automatic tool-wear detection in threading operations is a critical industrial quality-control problem, constrained by the scarcity of labelled data and by adverse imaging conditions (specular reflections, uneven illumination). This work addresses wear detection on M10×1.5 metric threads from optical images, deliberately framed as an experimental comparison of solutions under a shared evaluation framework rather than the a priori defense of a single model. On a set of 22 tools (11 conforming and 11 worn; around 262 images labelled at the part level), six multi-scale preprocessing variants are compared (rigorous BLMD, a fast high-pass approximation, BEMD, wavelet, homomorphic filtering and no preprocessing) together with four complementary artificial-intelligence strategies: adaptation of a foundation model via SAM+LoRA, Multiple Instance Learning with EfficientNet-B0, a U-Net trained on synthetic masks derived from the ISO profile, and anomaly detection with PatchCore. Evaluation is performed at the tool level and considers accuracy, robustness, computational cost and interpretability. Results show that a computationally cheap high-pass filter outperforms the rigorous decomposition, and that learned texture-based approaches clearly dominate purely geometric ones. The main finding is that, in this domain, wear manifests as a change in surface texture rather than as a macroscopic deformation of the profile, which reframes the problem from profile metrology towards surface-texture characterization.

Keywords: artificial intelligence; computer vision; image segmentation; tool wear detection; metric thread.

Índice de contenidos

1. Introducción 1
1.1. Motivación 1
1.2. Planteamiento del trabajo 1
1.3. Estructura del trabajo 2
2. Contexto y estado del arte 3
2.1. Contexto del problema 3
2.1.1. Contexto del Roscado por Arranque de viruta 3
2.1.2. Dinámica del mecanizado y generación de errores 4
2.1.3. Problemática del control de calidad en roscas 4
2.1.4. El error de paso e integridad superficial 4
2.1.5. Contexto de la detección de desgaste 4
2.2. Estado del arte 6
2.2.1. Limitaciones de los Calibres Manuales (Pasa/No Pasa) 6
2.2.2. Máquinas de Medición por Coordenadas (MMC/CMM) 7
2.2.3. Metrología Portátil y Escaneado 7
2.2.4. Técnicas basadas en BLMD para la medición de desgaste 8
2.2.5. Preprocesado de imágenes para iluminación y reflejos 9
2.2.6. Alternativas multi-escala a BLMD: BEMD y wavelets 13
2.2.7. Preprocesamiento de imagen y relevancia del BLMD 15
2.2.8. De los métodos de Machine Learning al Deep Learning 15
2.2.9. Limitaciones derivadas de la falta de datos etiquetados 17
2.2.10. Latencia en producción en entornos de fabricación 20
2.2.11. Modelado temporal del desgaste y detección temprana 20

2.2.12. Modelos fundacionales en visión industrial 21
2.3. Conclusiones 23
2.3.1. Justificación de la Visión Artificial y Deep Learning 23
3. Objetivos concretos y metodología de trabajo 24
3.1. Objetivo general 24
3.2. Objetivos específicos 24
3.3. Metodología del trabajo 26
3.3.1. Enfoque metodológico 26
3.3.2. Dataset y unidad de evaluación 27
3.3.3. Preprocesamiento y preparación de imágenes 28
3.3.4. Protocolo de evaluación 28
3.3.5. Métricas y criterios de comparación 28
3.3.6. Agregación de resultados e interpretabilidad 29
3.4. Estrategias de inteligencia artificial 29
3.5. PREPOCESADO E INFRAESTRUCTURA COMPÁRTIDA 33
3.5.1. Segmentación Otsu y morfología 33
3.5.2. Calibración de escala (px/mm) 36
3.5.3. Generación de la máscara ideal ISO 37
3.5.4. Registro y alineación de la máscara 40
3.6. PREPOCESADO E INFRAESTRUCTURA COMPÀRTIDA 41
3.6.1. Entorno experimental y reproducibilidad 41
3.6.2. Visualización, trazabilidad y ejecución de experimentos 41
4. Desarrollo específico de la contribución 44
4.1. Estrategia SAM+LORA 44
Propósito de la estrategia y uso industrial 44

4.1.1. Datos utilizados y mascaras manuales 45
4.1.2. Cómo se entrena 49
4.1.3. Detección de anomalías 52
4.1.4. Parámetros utilizados en el modelo 56
4.1.5. Resultados 58
4.1.6. Interpretabilidad 62
4.1.7. Limitaciones 65
4.2. Clasificación mediante Multiple Instance Learning y análisis del perfil ISO 67
4.2.1. La idea en una frase y su uso industrial 67
4.2.2. Datos y etiquetado 67
4.2.3. Cómo se entrena 68
4.2.4. Cómo decide conforme/desgastada 69
4.2.5. Parámetros del modelo 69
4.2.6. Resultados 70
4.2.7. Interpretabilidad 71
4.2.8. Comparación con el baseline geométrico: perfil ISO directo 72
4.2.9. Limitaciones 73
4.3. Arquitectura U-Net con encoder EfficientNet-B0 73
4.3.1. La idea en una frase y su uso industrial 73
4.3.2. Datos y etiquetado 74
4.3.3. Cómo se entrena 74
4.3.4. Cómo decide conforme/desgastada 75
4.3.5. Parámetros del modelo 76
4.3.6. Resultados 76
4.3.7. Interpretabilidad 78

4.3.8. Limitaciones 79
4.4. PatchCore 80
4.4.1. La idea en una frase y su uso industrial 80
4.4.2. Datos y etiquetado 81
4.4.3. Cómo se entrena 82
4.4.4. Cómo decide conforme/desgastada 83
4.4.5. Parámetros del modelo 85
4.4.6. Resultados 85
4.4.7. Nota sobre la comparabilidad de protocolos 89
4.4.8. Interpretabilidad: el perfilómetro y la firma física del desgaste 90
4.4.9. Limitaciones y coste computacional 93
4.5. Comparativa global de las estrategias 95
4.5.1. Cómo se entrenó y se validó cada estrategia 95
4.5.2. Rendimiento comparado y mejor estrategia 96
4.5.3. Cada estrategia explicada en lenguaje sencillo 98
5. Conclusiones y trabajo futuro 100
5.1. Conclusiones 100
5.2. Líneas de trabajo futuro 103
Referencias bibliográficas 106
Anexo A. Código fuente y datos analizados 111
Anexo B. Glosario 111

Índice de figuras

Figura 1. Perfil característico de una rosca métrica ISO 3

Figura 2. Comparación entre inspección automatizada (Industria 4.0) e inspección visual manual 5

Figura 3. Evolución temporal del desgaste de la herramienta. 21

Figura 4. Flujo metodológico global 27

Figura 5. Preparación de imágenes antes de la segmentación con SAM+LoRA. 34

Figura 6. Máscara ideal generada por el algoritmo. 39

Figura 7. Herramienta de visualización y análisis implementado con Streamlit 42

Figura 8. Preparación de imágenes antes de la segmentación con SAM+LoRA. 45

Figura 9. Ejemplo de anotación manual de crestas y pasos en Label Studio 47

Figura 10. Esquema de la arquitectura SAM+LoRA 50

Figura 11. Extracción de métricas sobre imagen segmentada 55

Figura 12. Resumen del entrenamiento y validación del modelo Auto-RB03. 61

Figura 13. Curva ROC y matriz de confusión del modelo auto_RB03. 62

Figura 14. Resumen métricas vs umbral para detectar desgaste. 63

Figura 15. Segmentación, ISO y Grad-CAM por imagen analizada 65

Figura 16. Mapa de calor de la imagen 000501 de la rosca conforme 5 (RB05) 72

Figura 17. Desviación entre la máscara predicha y la ideal de la rosca desgastada 07 (RM07) 78

Figura 18. Matriz de confusión a nivel pieza con calibración por P95. 89

Figura 19. Perfil promedio Conforme (verde), Desgastada (naranja) e ISO teórico (línea discontinua); las bandas muestran la dispersión P25-P75 y las áreas rellenas, el déficit de material respecto al ISO. 92

Figura 20. Distribuciones por altura (izq.), área (centro) y profundidad (der.). 92

Figura 21. Comparativa cuatro estrategias frente a los métodos de referencia 97

Índice de tablas

Tabla 1. Organización del trabajo en grupo. XIII

Tabla 2. Comparativa ML vs DL en detección de desgaste. 17

Tabla 3. Enfoques para detección de desgaste con pocos datos 19

Tabla 4. Objetivos específicos 25

Tabla 5. Resumen de las estrategias de inteligencia artificial estudiadas 32

Tabla 6. Dimensiones básicas ISO 724 37

Tabla 7. Zonas del ciclo de paso y altura del perfil ISO 38

Tabla 8. Resumen de anotaciones manuales en Label Studio 48

Tabla 9. Modos de entrenamiento 51

Tabla 10. Resumen de métricas geométricas calculadas a partir de las máscaras segmentadas. 54

Tabla 11. Parámetros utilizados en SAM+Lora. 57

Tabla 12. Resultados obtenidos en la estrategia SAM+Lora. 59

Tabla 13. Parametrización de la estrategia MIL + EfficientNet-B0. 69

Tabla 14. Resultado del modelo MIL + EfficientNet-B0 (LOO-CV, 24 folds) 70

Tabla 15. Distribución de scores por clase 70

Tabla 16. Casos límite en herramientas desgastadas 71

Tabla 17. Parametrización de la estrategia U-Net + ISO 76

Tabla 18. Resultados del modelo U-Net (agregación por máximo, LOO-CV) 77

Tabla 19. Caso anómalo detectado 78

Tabla 20. Limitaciones identificadas y trabajo pendiente 80

Tabla 21. Comparativa de veredictos a nivel de rosca 84

Tabla 22. Parámetros del modelo PatchCore 85

Tabla 23 Comparativa de los seis pipelines de procesado. 86

Tabla 24 Ablación con y sin máscara. 88

Tabla 25. Cuantificación conforme frente a desgastada frente a ISO 91

Tabla 26. Clasificador basado en distancia al perfil patrón. 93

Tabla 27. Limitaciones y líneas de mejora 94

Tabla 28. Las cuatro estrategias: qué hace entrenamiento y validación 96

Índice de Ecuaciones

Ecuación 1. Umbralización de otsu 34
Ecuación 2. Escala px por mm 36
Ecuación 3. Posición relativa 38
Ecuación 4. Flanco de subida 38
Ecuación 5. Flanco de bajada 38
Ecuación 6. Threshold 39
Ecuación 7. Área 54
Ecuación 8. Ancho 54
Ecuación 9. Alto 54
Ecuación 10. Solidez 54
Ecuación 11. Rectagularidad 54
Ecuación 12. Ratio alto/ancho 54
Ecuación 13. Horizontalidad 54
Ecuación 14. Coeficiente de variación de área 54
Ecuación 15. Función de pérdida 68
Ecuación 16. GradCam 71
Ecuación 17. Score de desviación 72
Ecuación 18. Perdida de BCE 75
Ecuación 19. Score de desgaste 75

Organización del trabajo en grupo

En este apartado se detallarán las distintas partes en las que se ha dividido el trabajo entre los componentes del grupo, los objetivos perseguidos en cada una de ellas y los mecanismos de coordinación empleados. Este apartado deberá ser validado por el director para poder comenzar con el trabajo.

Partes que aborda el TFE

Cada estudiante debe abordar elementos/partes que, individualmente, podrían suponer un TFE por sí mismas.

Distribución y estructura de la memoria

Tabla 1. Organización del trabajo en grupo.

Organización del trabajo en grupo - Desarrollo de la memoria	
Apartado de la memoria	**Responsables**
Introducción	Alcalde, González, Peiró
Contexto y estado del arte	Alcalde, González, Peiró
Objetivos y metodología de trabajo	Alcalde, González, Peiró
Marco normativo	Alcalde, González, Peiró
Desarrollo específico de la contribución	Alcalde
Desarrollo específico de la contribución	González
Desarrollo específico de la contribución	Peiró
Conclusiones	Peiró

Fuente: Elaboración propia.

Mecanismos de coordinación empleados

Hay que recordar que este trabajo es una preparación para un día a día en un mundo laboral cada vez más complejo. Este mundo laboral implica siempre trabajar en conjunto con otras personas y profesionales de diferentes ámbitos. Un TFE grupal prepara para la realidad de un entorno laboral real en el que el trabajo en equipo es constante.

1. INTRODUCCIÓN

La detección automática del desgaste en herramientas de roscado es un problema de creciente interés para la industria, donde el control de calidad debe conciliar precisión, velocidad y coste sin renunciar a la fiabilidad de la medida. La inspección manual resulta lenta y subjetiva, mientras que los equipos metrológicos de alta precisión son difíciles de integrar en líneas de producción. En este contexto, la visión y la inteligencia artificial ofrecen una vía prometedora para automatizar la verificación del estado de la rosca.

1.1. MOTIVACIÓN

El roscado por arranque de viruta es una operación de acabado crítica en la industria mecánica, donde la integridad de la geometría helicoidal determina la vida útil del componente. Actualmente, la industria enfrenta el desafío de controlar el desgaste de las herramientas de forma eficiente. Los métodos tradicionales presentan limitaciones severas: los calibres manuales son subjetivos, las máquinas de medición por coordenadas (MMC) son lentas para la producción en masa y el escaneado láser sufre de oclusiones y reflejos en superficies metálicas.

La necesidad de una inspección del 100% de la producción a alta velocidad justifica el desarrollo de estrategias basadas en Visión Artificial. Este trabajo se motiva en la capacidad de la técnica BLMD para descomponer imágenes y resaltar detalles finos de desgaste que otros filtros lineales no logran capturar, permitiendo una metrología precisa sin instrumentación de laboratorio costosa.

1.2. PLANTEAMIENTO DEL TRABAJO

Este Trabajo Fin de Estudios (TFE) propone una estrategia inteligente para la detección del desgaste en herramientas de roscado a partir de imágenes, planteada como una comparativa experimental de soluciones sobre un mismo problema industrial. En lugar de apostar a priori por un único modelo, se diseña un marco experimental común que permite evaluar y

contrastar distintas aproximaciones de inteligencia artificial bajo idénticas condiciones de datos y los mismos criterios de validación.

En la base de este marco se sitúa una etapa de preprocesado de imagen orientada a mitigar la falta de contraste, los reflejos parásitos y las variaciones de iluminación propias de las superficies metálicas. Para ello se comparan técnicas de descomposición multiescala (BLMD, la Empirical Mode Decomposition bidimensional (BEMD) y la transformada wavelet), junto con variantes de corrección de iluminación como el filtrado homomórfico y configuraciones sin preprocesado, con el fin de medir su impacto real sobre el rendimiento posterior en lugar de presuponer la superioridad de ninguna de ellas.

Sobre esa base se implementan y comparan cuatro estrategias de inteligencia artificial complementarias: la detección de anomalías con PatchCore, el aprendizaje supervisado débil con Multiple Instance Learning y EfficientNet-B0, la adaptación de un modelo fundacional de segmentación mediante SAM+LoRA y la segmentación con U-Net entrenada a partir de máscaras sintéticas derivadas del perfil ISO. Estas estrategias se entrenan y evalúan sobre un mismo conjunto de imágenes de roscas métricas M10×1,5 y bajo un protocolo de validación por pieza. La finalidad última es determinar qué combinación de preprocesado y estrategia ofrece el mejor equilibrio entre precisión, robustez, coste computacional e interpretabilidad ante un problema marcado por la escasez de datos etiquetados.

1.3. ESTRUCTURA DEL TRABAJO

Capítulo 2: Analiza el contexto técnico del roscado y el estado del arte de las técnicas BLMD, BEMD y wavelets.

Capítulo 3: Define los objetivos SMART y la metodología experimental.

Capítulo 4: Describe el desarrollo específico de la contribución y la identificación de requisitos.

Capítulo 5: Presenta las Conclusiones y describe trabajo futuro

Conclusiones: Resume el alcance de la investigación y propone líneas de trabajo futuro.

2. CONTEXTO Y ESTADO DEL ARTE

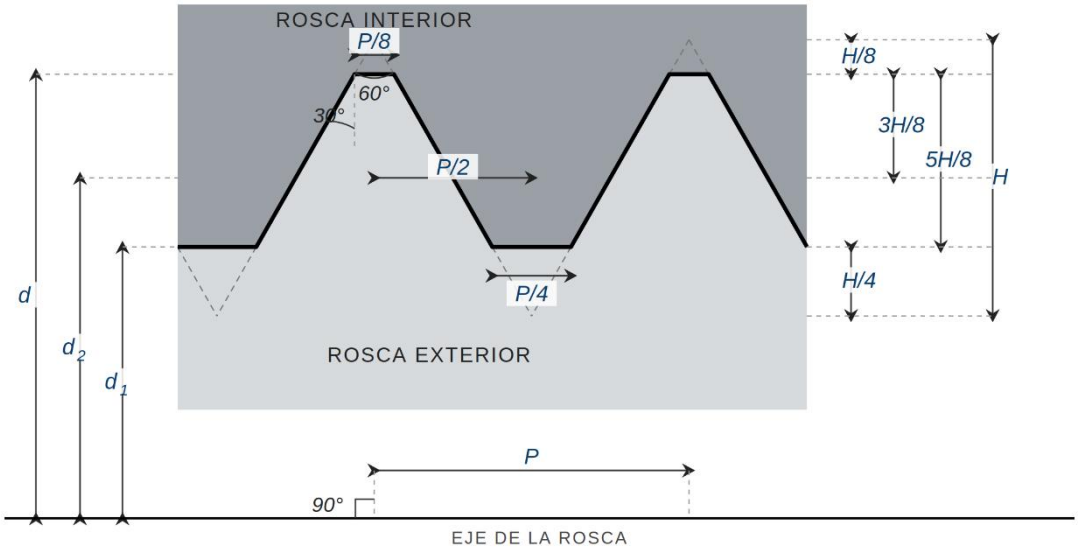
2.1.CONTEXTO DEL PROBLEMA

2.1.1. Contexto del Roscado por Arranque de viruta

El roscado se define como una operación crítica de acabado dentro de la industria mecánica. A diferencia de otros procesos de mecanizado, este genera una geometría helicoidal compleja donde factores como la integridad de los flancos y el radio del fondo son determinantes para la capacidad de carga y la vida a fatiga del componente (Astakhov, 2010).

La Figura 1 muestra el perfil característico de una rosca métrica ISO (International Organization for Standardization, 2023a), donde se identifican los elementos geométricos fundamentales mencionados: los flancos del filete, el fondo o raíz, la cresta, así como el paso (P) y los diámetros mayores (D) y menor (d_1)."

Figura 1. Perfil característico de una rosca métrica ISO



Perfil básico de la rosca métrica ISO (ISO 68-1). H = (√3/2)·P. d: diámetro mayor · d_2: diámetro de flancos · d_1: diámetro menor

Fuente: Elaboración propia ISO 68-1

2.1.2. Dinámica del mecanizado y generación de errores

Existen diversas técnicas de generación de roscas que presentan desafíos específicos:

- Roscado con macho (Tapping): En esta técnica, la herramienta debe evacuar la viruta a través de sus ranuras mientras avanza axialmente de forma sincronizada con la rotación. En materiales dúctiles, es común el fenómeno de "anidamiento", donde la viruta larga queda atrapada en el fondo del agujero, provocando el "re-corte" que daña el perfil de la rosca y obstruye la lubricación.
- Fresado de roscas (Thread Milling): Este proceso introduce variables cinemáticas adicionales. La deflexión de la herramienta debido a las fuerzas radiales y el desgaste progresivo pueden alterar el radio de fondo de la rosca, creando concentradores de tensiones microscópicos que derivan en fallos por fatiga en entornos de alta vibración (Dornfeld, 2019).

2.1.3. Problemática del control de calidad en roscas

La inspección de una rosca es intrínsecamente más compleja que la de diámetros lisos. Se define por un "triángulo de incertidumbre" que incluye el paso, el ángulo del flanco y el diámetro medio (Dornfeld, 2019).

2.1.4. El error de paso e integridad superficial

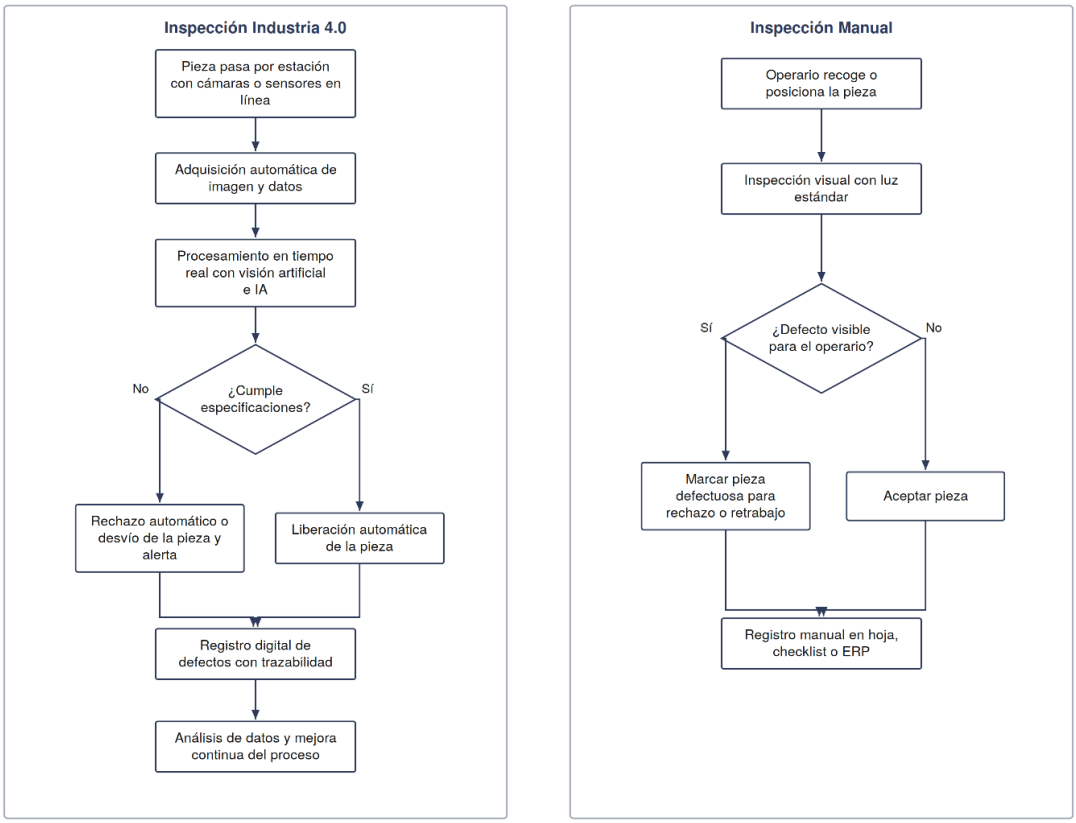
Un error de paso acumulado puede generar tensiones internas críticas durante el montaje, incluso si la pieza se encuentra dentro de las tolerancias dimensionales. Asimismo, las altas temperaturas del arranque de viruta pueden inducir una "capa blanca" (martensita frágil) en la superficie. Los métodos tradicionales suelen ser ineficaces para detectar estos cambios metalúrgicos, limitándose a un control binario de dimensiones.

2.1.5. Contexto de la detección de desgaste

La predicción de la vida útil de las herramientas ha sido un desafío del sector industrial desde sus inicios. Un uso erróneo ya sea por un uso excesivo o una rotura imprevista, puede incurrir

en un elevado coste económico y operativo, provocando paradas no planificadas, la fabricación de piezas defectuosas o, en el peor de los casos la inutilización de la máquina. Para evitar estos problemas, tradicionalmente se han realizado las inspecciones de forma manual y con la maquinaria apagada, utilizando láseres, microscopios y otras herramientas, basándose normalmente en normativas ISO para analizar el estado de las piezas (Holgado, 2023). Esta operativa hacía que la inspección fuera lenta, ineficiente y altamente determinada por la subjetividad y experiencia del personal especializado. En la Figura 2 se ilustran dos ejemplos de inspección visual manual de herramientas en condiciones de laboratorio.

Figura 2. Comparación entre inspección automatizada (Industria 4.0) e inspección visual manual



Fuente: Elaboración propia

Gracias a la digitalización y la transición hacia la industria 4.0, estas inspecciones han evolucionado a sistemas que pueden reducir los errores manuales, a la par que se automatizan procesos gracias a técnicas de visión artificial, siendo estas las alternativas no intrusivas prometedoras. Sin embargo, la sensorización de las máquinas ha trasladado el análisis desde un entorno de laboratorio con condiciones controladas a un entorno industrial real, donde las

condiciones raramente son óptimas. La presencia de fluidos de corte como la taladrina, virutas metálicas adheridas, vibraciones continuas, sombras y brillos provenientes del metal complican la extracción de características visuales. Este nuevo entorno conlleva investigar técnicas avanzadas de procesamiento de imágenes combinadas con arquitecturas de inteligencia artificial para conseguir predecir de forma robusta y eficiente la vida útil de la herramienta, parando la producción cuando realmente sea necesario y no con tareas de mantenimiento (Li, et al., 2025).

2.2. ESTADO DEL ARTE

La utilización de distintas herramientas y técnicas de inteligencia artificial en procesos de mecanizado ha estado condicionada por diversos obstáculos, que se han ido identificando a medida que se implementaban nuevas tecnologías. Sin embargo, no todos los estudios sobre detección de desgaste validan sus resultados en entornos reales de fabricación, lo que conduce a porcentajes de precisión elevados que no siempre consideran las condiciones no controladas propias del entorno industrial real.

A continuación, se presentan las distintas técnicas en función de las limitaciones específicas que tratan de superar, así como de los nuevos desafíos que surgen en su aplicación.

2.2.1. Limitaciones de los Calibres Manuales (Pasa/No Pasa)

Aunque este método representa el estándar histórico en el control de roscados, no está exento de limitaciones relevantes. En su concepción original, el criterio de evaluación dependía en gran medida de la destreza sensorial del operario, lo que introducía un componente de subjetividad considerable. A ello se sumaba el desgaste progresivo del calibre provocado por el rozamiento continuo, que podía derivar en lecturas erróneas y falsos positivos en el proceso de verificación.

Con el tiempo, el método ha experimentado una evolución significativa. En la actualidad se emplean calibres dotados de reglas integradas que permiten obtener medidas de longitud precisas, fabricados además con materiales de mayor durabilidad. La gestión de estos

instrumentos en las cadenas de calibración supervisadas por los departamentos de calidad garantiza su idoneidad y minimiza el margen de error en el control del roscado. No obstante, el método sigue presentando una limitación estructural: la ausencia de datos cuantitativos suficientes para optimizar el proceso de forma dinámica y en tiempo real.

2.2.2. Máquinas de Medición por Coordenadas (MMC/CMM)

Este tipo de sistemas emplea palpadores físicos para reconstruir la geometría tridimensional de la rosca; sin embargo, presenta dos limitaciones fundamentales que condicionan su aplicabilidad. La primera de ellas es de naturaleza geométrica: cuando el radio del palpador supera al radio del fondo de la rosca, el sistema es incapaz de alcanzar la profundidad real del perfil, lo que impide medir con precisión tanto dicha profundidad como el radio de entalladura. La segunda limitación es de carácter productivo, puesto que el tiempo de ciclo requerido resulta excesivo para entornos de producción en masa, lo que obliga a restringir el control de calidad a un muestreo estadístico que, en la práctica, no suele superar el 5% de la producción total.

2.2.3. Metrología Portátil y Escaneado

Los brazos articulados permiten trasladar la precisión de medición al entorno del taller, pero su repetibilidad queda condicionada por la presión y el ángulo que aplica el operario durante la medición. Cualquier inclinación involuntaria introduce los denominados errores de coseno, que comprometen la exactitud en la medición del diámetro de los flancos.

Por su parte, el escaneado láser presenta la problemática de la oclusión, fenómeno por el cual los flancos de la hélice interceptan la trayectoria del haz luminoso antes de que este alcance el valle de la rosca, generando sombras ópticas que impiden una captura completa del perfil. A esta limitación se añade la interferencia producida por los acabados especulares propios de piezas nuevas, cuyas superficies tipo espejo generan reflexiones que distorsionan y corrompen la señal recibida por el sensor.

2.2.4. Técnicas basadas en BLMD para la medición de desgaste

El uso de la *Bidimensional Local Mean Decomposition* (BLMD) (An, 2019) surge como respuesta a una limitación clásica de la visión artificial aplicada al desgaste: las zonas degradadas no siempre presentan un contraste fuerte respecto a las regiones sanas y, además, pequeñas variaciones de iluminación pueden ocultar completamente el desgaste real. Frente a filtros lineales simples, BLMD descompone la imagen en componentes de baja y alta frecuencia adaptados a la propia distribución de intensidades, de forma que los detalles finos asociados al desgaste (micromuescas, cambios de textura en el filo, bordes erosionados) quedan concentrados en los componentes de alta frecuencia, donde pueden ser amplificados selectivamente (Nunes & Deléchelle, 2009). Esta capacidad multiescala y local convierte a BLMD en una herramienta muy adecuada para preparar imágenes de secciones de pieza antes de segmentar o medir el desgaste.

(Alhabshan, 2023) propone uno de los sistemas más representativos de medición óptica de desgaste en brocas apoyado en BLMD. En su trabajo, el autor extrae primero el contorno completo de la rosca mediante segmentación local basada en varianza y operaciones morfológicas; a continuación, aplica BLMD para separar la componente suave de iluminación de la componente detallada de bordes y textura, realza la parte de alta frecuencia y reconstruye una imagen mejorada. Sobre esa imagen segmenta la zona de desgaste y calcula parámetros como el ancho medio de desgaste, el área y el perímetro de la región desgastada, que compara con mediciones de microscopio digital. Los resultados muestran errores medios bajos entre ambas mediciones, lo que valida BLMD como base para una metrología de desgaste precisa sin necesidad de instrumentación de laboratorio costosa.

De forma similar,(Yu, Cheng, et al., 2021) desarrolla un método de visión para la medición de desgaste en herramientas de mecanizado que también utiliza BLMD como paso de realce. El flujo de trabajo consiste en aplicar BLMD a las imágenes de la rosca, mejorar el contraste entre zona desgastada y no desgastada, segmentar posteriormente el área de desgaste mediante umbralado y extracción de bordes, y calcular métricas geométricas como área y anchura de desgaste. Los autores muestran que, sin la etapa de BLMD, la segmentación confunde con

frecuencia ruido de iluminación y suciedad con desgaste real, mientras que tras la descomposición la zona dañada aparece claramente delimitada.

A partir de estos trabajos se han planteado enfoques más generales que hablan de medición "universal" de desgaste. En estos enfoques se combina BLMD con análisis de correlación cruzada entre patrones de pieza conforme y pieza en uso, de forma que la imagen realzada por BLMD hace más sensibles esas correlaciones a pequeñas modificaciones del contorno y de la textura producidas por el desgaste. Aunque el detalle de la implementación varía entre autores, todos coinciden en la idea de utilizar BLMD como un bloque de preprocesado que transforma la imagen original en una representación donde el desgaste es mucho más evidente y medible.

En síntesis, la literatura sitúa BLMD como una técnica madura para realzar el desgaste y permitir su medición geométrica directa a partir de imágenes ópticas. Para este trabajo, estos artículos constituyen el punto de partida del estado del arte: demuestran que es posible cuantificar parámetros de desgaste solo con visión artificial, pero también dejan abiertas preguntas sobre cómo se comporta BLMD ante imágenes con reflejos intensos, baja calidad o conjuntos de datos reducidos, y sobre cómo podría combinarse con técnicas más modernas como BEMD, wavelets o redes neuronales convolucionales.

2.2.5. Preprocesado de imágenes para iluminación y reflejos

Uno de los principales desafíos prácticos en la inspección visual de herramientas metálicas es que la iluminación y los reflejos especulares dominan la escena, ocultando o distorsionando la información de desgaste. La literatura insiste en que, si no se controla bien este aspecto, el rendimiento de cualquier algoritmo de segmentación o clasificación se ve gravemente comprometido. Por ello, antes incluso de aplicar BLMD o redes profundas, numerosos trabajos se centran en el diseño de la iluminación y en técnicas de corrección digital de la iluminación y los reflejos.

(J. Zhang & Regtien, 2007) analiza de forma sistemática distintos métodos de iluminación para la detección óptica del desgaste. En su estudio se comparan configuraciones de campo claro, campo oscuro, iluminación rasante y anillos de luz, evaluando cómo cada esquema afecta al contraste entre la zona de desgaste y el resto de la pieza. El autor concluye que pequeñas

variaciones en el tipo y el ángulo de iluminación pueden convertir un problema de segmentación sencillo en uno prácticamente intratable, lo que justifica la necesidad de diseñar cuidadosamente la geometría de luz en sistemas de visión para desgaste. De manera complementaria, (Bilal et al., 2024) diseñan una unidad de iluminación específica para fresas que minimiza sombras y brillos parásitos, demostrando experimentalmente que la estabilidad de las medidas de desgaste depende en gran medida de ese diseño óptico inicial.

Cuando no es posible garantizar unas condiciones de iluminación ideales, distintos autores recurren a técnicas de corrección digital, entre las que destacan el filtrado homomórfico y los modelos de tipo Retinex. Estas técnicas modelan la imagen como el producto de una componente de iluminación lenta y una componente de reflectancia rápida; al pasar al dominio logarítmico, esta relación se vuelve aditiva y permite atenuar selectivamente la parte asociada a la iluminación, preservando la estructura de reflectancia. Un trabajo clásico sobre realce de imágenes basado en Retinex combina precisamente la estimación de iluminación con filtrado homomórfico para mejorar el contraste de imágenes con iluminación muy desigual, como las de rayos X, logrando resaltar detalles finos sin amplificar en exceso el ruido (Cheng et al., 2009).

En un contexto más cercano a la fabricación avanzada, (Mrinal Sarvagya et al., 2024) propone una estrategia de compensación de reflejos en superficies negras y brillantes de materiales compuestos. En este trabajo se aplica filtrado homomórfico para reducir los reflejos intensos y, posteriormente, se utiliza umbralización binaria para segmentar las zonas problemáticas. Los resultados experimentales muestran que, tras la compensación, las inclusiones internas se distinguen claramente del fondo, algo que antes resultaba muy difícil incluso para un operador experto.

En el ámbito de la minería, Bian (2024) integra también filtrado homomórfico dentro de un flujo de visión para detectar defectos en equipamiento de automatización. Su enfoque combina un preprocesado de corrección de iluminación mediante filtrado homomórfico, un realce de bordes con el operador de Laplace y, finalmente, la detección mediante una red Faster-RCNN entrenada con estas imágenes preprocesadas. Los resultados empíricos indican que esta combinación mejora sustancialmente las métricas de detección frente a entrenar el

detector directamente sobre las imágenes originales, lo que refuerza la idea de que el preprocesado de iluminación sigue siendo crucial incluso cuando se utilizan modelos profundos.

Más allá de la iluminación global, una parte de la literatura se centra en el tratamiento explícito de los reflejos especulares, que se manifiestan como zonas muy brillantes y saturadas que ocultan la información subyacente. (Nie et al., 2023) abordan este problema en imágenes endoscópicas, proponiendo un método para detectar y eliminar reflejos en función de la luminosidad global de la imagen. En primer lugar, clasifican la imagen según su nivel de brillo general; después aplican criterios adaptativos en el espacio de color para identificar regiones especulares y, por último, las eliminan mediante un algoritmo de inpainting por parches mejorado, de modo que los algoritmos de segmentación posteriores se centran en información real de tejido en lugar de en highlights saturados. Aunque el dominio médico difiere del industrial, el tipo de artefacto y la solución propuesta son muy similares a los problemas de reflejos en superficies metálicas pulidas.

Por último, varias contribuciones recuerdan que los reflejos también pueden mitigarse a nivel de hardware mediante técnicas de polarización. Trabajos sobre inspección visual en entornos industriales describen el uso de fuentes de luz polarizada y filtros polarizadores en la cámara para configurar esquemas de polarización cruzada, capaces de cancelar gran parte de la componente especular y dejar principalmente la componente difusa asociada a la textura de la superficie (Hifly Technology (Shenzhen) Co., 2026). Esta misma idea se recoge en una patente de cámara para inspección de superficies metálicas, donde la combinación de óptica y polarizadores se diseña específicamente para mejorar la detectabilidad de defectos bajo condiciones de luz complejas (Jang & Lee, 2013).

En conjunto, el estado del arte en preprocesado de imágenes para desgaste sugiere una estrategia multinivel: diseñar una iluminación adecuada desde el hardware (geometría de luz y polarización), aplicar técnicas de corrección global de iluminación y reflejos como el filtrado homomórfico y Retinex, y eliminar de forma explícita las regiones especulares mediante detección de highlights e inpainting cuando sea necesario. Esta combinación proporciona una

base limpia sobre la que BLMD, BEMD, wavelets o modelos profundos pueden analizar el desgaste con mucha mayor fiabilidad.

2.2.6. Alternativas multi-escala a BLMD: BEMD y wavelets

Aunque BLMD ha demostrado ser eficaz para realzar el desgaste, no es la única técnica multi-escala disponible. Dos familias de métodos emergen como alternativas o complementos naturales: la *Empirical Mode Decomposition Bidimensional* (BEMD) y la transformada wavelet. Ambas persiguen separar componentes de distinta escala, pero difieren en cómo construyen esa descomposición.

(Nunes & Deléchelle, 2009) en su revisión sobre descomposición modal empírica, analizan en detalle la EMD aplicada a señales e imágenes, incluyendo la extensión bidimensional BEMD. En este enfoque, la imagen se somete a un proceso iterativo de "*sifting*" que identifica máximos y mínimos locales, ajusta superficies de envolvente y extrae una serie de *Intrinsic Mode Functions* (IMF), cada una asociada a cierto rango de frecuencias espaciales. A diferencia de las wavelets, que utilizan funciones base predefinidas, BEMD es completamente adaptativa: la forma de cada IMF viene determinada por la propia imagen, lo que resulta especialmente útil cuando las variaciones de iluminación y textura son altamente no estacionarias.

Esta adaptabilidad se aprovecha en el trabajo de (Lu & Lu, 2018), que proponen una versión rápida de BEMD como técnica de realce para la detección de defectos en fruta. En su método, las imágenes presentan un oscurecimiento de bordes y cambios de iluminación que dificultan la observación de manchas y podredumbres; la BEMD permite separar esos efectos de baja frecuencia en determinados IMFs, mientras concentra los bordes y texturas de los defectos en otros modos. Al reconstruir la imagen a partir de un subconjunto de IMFs seleccionados, se obtiene una versión en la que los defectos son mucho más visibles y segmentables. El paralelismo con el desgaste en superficies metálicas es claro: en ambos casos se trata de resaltar sutiles alteraciones de textura sobre un fondo con iluminación complicada.

También se ha aplicado BEMD al análisis de textura en hojas de cítricos, donde las texturas correspondientes a diferentes estados de salud se representan mediante descriptores extraídos de los IMFs bidimensionales (Sumanto et al., 2023) . Los autores muestran que estas características basadas en BEMD superan a descriptores clásicos en tareas de clasificación, lo

que refuerza la idea de que la descomposición empírica captura mejor patrones de textura complejos y distribuciones espaciales irregulares.

Por otro lado, la transformada wavelet constituye una aproximación multi-escala más clásica, pero con una base matemática sólida y un amplio cuerpo de trabajos en distintos dominios.(Sun et al., 2018) proponen un método de realce de imagen basado en transformada wavelet en el que se modifican los coeficientes de alta y baja frecuencia mediante funciones no lineales para mejorar simultáneamente el contraste global y la nitidez de los detalles, manteniendo el ruido bajo control. Los autores demuestran que operar en el dominio wavelet permite un control más preciso del equilibrio entre realce y aparición de artefactos que los enfoques puramente espaciales.

En la literatura reciente se encuentran también algoritmos de restauración y realce de imagen apoyados en wavelets, que separan la estructura significativa del ruido mediante umbralado y filtrado de coeficientes antes de reconstruir la imagen (Wang, 2022). Aunque algunos de estos trabajos han sido posteriormente retractados por cuestiones formales, su planteamiento técnico coincide con muchas otras propuestas sólidas que usan wavelets para mejorar la relación señal-ruido y el contraste en imágenes degradadas.

Un caso particularmente relevante para este trabajo es el de (Vishwanatha et al., 2024), que desarrollan un modelo basado en procesado de imagen para evaluar la rugosidad superficial en el mecanizado de Ti-6Al-4V. En este estudio se extraen características de textura a partir de transformadas wavelet y se utilizan como entrada de modelos predictivos de rugosidad, comparando sus estimaciones con mediciones de instrumentos de contacto. Los resultados muestran una fuerte correlación entre las características wavelet y la rugosidad real, lo que implica que estas transformadas son capaces de capturar variaciones muy finas de la topografía superficial, análogas a las producidas por el desgaste progresivo en una pieza.

La comparación entre BLMD, BEMD y wavelets pone de manifiesto diferencias metodológicas relevantes. Tanto BLMD como BEMD son descomposiciones empíricas de carácter adaptativo, capaces de ajustarse de forma local a la estructura intrínseca de la imagen. Las wavelets, en cambio, ofrecen una descomposición de base fija que resulta especialmente eficiente en el

análisis multiescala y multioriental, siendo particularmente adecuada para realzar bordes, grietas y variaciones de rugosidad superficial.

A partir de la revisión bibliográfica realizada, se propone adoptar BLMD como técnica de referencia en el presente trabajo, dado su uso contrastado en aplicaciones de medición de desgaste. Paralelamente, se plantea la realización de experimentos comparativos que incorporen BEMD y wavelets sobre las imágenes disponibles, con el objetivo de determinar qué combinación ofrece el mejor equilibrio entre el realce de las zonas de desgaste, la robustez frente a reflejos especulares y la estabilidad de las medidas geométricas resultantes.

2.2.7. Preprocesamiento de imagen y relevancia del BLMD

El preprocesamiento de las imágenes es un paso fundamental para la detección de anomalías por visión por computador en procesos mecanizados, ya que las condiciones de obtención pueden estar alteradas por la presencia de reflejos, fluidos de corte y variación de iluminación. Para poder solventar este problema, técnicas como la BLMD permiten mejorar la calidad de la imagen mediante la descomposición en modos intrínsecos, reduciendo alteraciones por sombras o variaciones en la iluminación.

Este tratamiento previo ayuda a que los modelos de Deep Learning aprendan sobre imágenes más regulares, mejorando la capacidad de extracción de características y segmentación de las áreas de desgaste o rotura. Diversos trabajos han demostrado que la combinación de técnicas de preprocesamiento con arquitecturas de segmentación como U-Net o modelos basados en atención como Segment Anything Model (SAM) permite identificar las zonas de desgaste con mayor precisión, especialmente en condiciones controladas (Li et al., 2024) (Lin et al., 2021).

2.2.8. De los métodos de Machine Learning al Deep Learning

La detección del desgaste en procesos de mecanizado mediante el uso de visión artificial ha evolucionado desde enfoques clásicos de machine learning hacia modelos basados en técnicas más recientes del Deep learning. Durante las primeras etapas de la automatización, se empleaban algoritmos como las máquinas de vectores de soporte (SVM) o Random Forest, los

cuales requieren una definición manual de las características relevantes, como son los bordes, texturas o patrones geométricos del desgaste (Zhou, 2024).

Aplicar esta nueva metodología implica una carga de trabajo elevada para la clasificación de características, donde debían identificar explícitamente qué secciones de la imagen eran consideradas un defecto, un desgaste, una rotura, etc. Y tiene un factor de posible fallo humano en la clasificación. Como consecuencia, estos modelos presentan una elevada rigidez y limitan la capacidad de generalización, ya que solo identifican los tipos de defectos clasificados por el personal experto, y generaban problemas cuando había cambios de iluminación o ruidos en el entorno industrial (X. Zhang, 2020).

Con el objetivo de reducir los tiempos de procesamiento y minimizar los errores derivados de la intervención humana en la identificación de características, se introdujo progresivamente el uso de modelos de aprendizaje profundo (Deep Learning). En este contexto, las redes neuronales convolucionales (CNN, por sus siglas en inglés) adquirieron especial protagonismo gracias a su capacidad para extraer y aprender características de forma automática a partir de las imágenes de entrenamiento, sin necesidad de una definición manual de los atributos relevantes. Este tipo de redes, aplican filtros convolucionales que permiten detectar desde características locales como bordes o texturas, hasta patrones más complejos asociados al desgaste, sin indicar manualmente dichas características (Khan et al., 2024). Este aprendizaje automático de características se lleva a cabo mediante filtros convolucionales que actúan como ventanas deslizantes de pequeño tamaño, las cuales recorren sistemáticamente la imagen analizando el conjunto de píxeles contenido en cada región local explorada.

En el contexto de las CNN, arquitecturas como U-Net que demuestran una gran precisión en tareas de segmentación en la localización del desgaste en la pieza (Lin et al., 2021). De igual modo, modelos específicos del dominio, como los propuestos por (X. Wu et al., 2019), han reportado una mejora importante en la precisión respecto a enfoques clásicos de Machine Learning.

No obstante, las CNN no están exentas de limitaciones relevantes en el contexto de la detección de anomalías. Al basarse en filtros de carácter local, ofrecen un buen rendimiento en la identificación de defectos de pequeña escala, pero presentan dificultades para capturar

anomalías de mayor extensión o degradaciones progresivas que se desarrollan de forma gradual a lo largo del proceso de fabricación o durante el uso de la herramienta. A ello se suma una limitación estructural común a los modelos de aprendizaje profundo: la necesidad de grandes conjuntos de datos etiquetados para el entrenamiento, cuya obtención resulta especialmente compleja y costosa en entornos industriales reales (Molitor et al., 2021).

A modo de síntesis, la Tabla 2 recoge las diferencias fundamentales entre los enfoques basados en Machine Learning y los basados en Deep Learning aplicados a la detección de desgaste.

Tabla 2. Comparativa ML vs DL en detección de desgaste.

Aspecto	Machine Learning	Deep Learning
Extracción de características	Manual	Automático
Robustez	Baja	Alta
Generalización	Limitada	Buena
Sensibilidad al ruido	Alta	Baja
Datos necesarios	Alto	Muy alto

Fuente: Elaboración propia

2.2.9. Limitaciones derivadas de la falta de datos etiquetados

Uno de los mayores problemas en el uso de algoritmos de inteligencia artificial en el mecanizado industrial para la detección de defectos, predicción de fallas o estimación de vida útil de herramientas es la obtención de imágenes. Mientras que obtener imágenes de herramientas en buen estado es solo cuestión de tiempo, el intentar generar un dataset amplio con defectos reales es muy problemático. Para ello, sería necesario documentar todo el proceso de fabricación desde su inicio hasta que se produce el desgaste o rotura de la herramienta, lo que implica elevados costes económicos y operativos, además de posibles interrupciones en la producción.

Con el fin de resolver esta limitación, diversas líneas de investigación recientes exploran enfoques alternativos orientados a reducir la dependencia de grandes volúmenes de datos etiquetados necesarios para el entrenamiento de modelos de Inteligencia Artificial. En el ámbito de la detección de anomalías, uno de los más destacados es PatchCore, un método que permite entrenar el modelo exclusivamente con imágenes de la pieza en buen estado. Durante la fase de inferencia, cualquier desviación significativa respecto a ese estado de referencia es interpretada por el modelo como una anomalía. Este comportamiento se logra gracias a que PatchCore construye un gran dataset con las características representativas, posteriormente se optimiza mediante técnicas de muestreo como coreset sampling, reduciendo la redundancia y el coste computacional (Jiang et al., 2024).

En una línea de investigación similar, métodos como FastFlow modelan directamente la distribución de los datos normales mediante flujos normalizantes, eliminando también la necesidad de ejemplos defectuosos. Aunque ambos enfoques comparten el objetivo de trabajar sin datos anómalos, presentan diferencias en su planteamiento: PatchCore se basa en la comparación en el espacio de características, mientras que FastFlow adopta un enfoque probabilístico, lo que influye en su capacidad de generalización ante variaciones del entorno (Yu, Zheng, et al., 2021).

Otra línea de investigación relevante es el few-shot learning o aprendizaje con pocos ejemplos, cuyo objetivo es que el modelo sea capaz de detectar nuevos tipos de defectos a partir de un número muy reducido de imágenes. Este enfoque resulta especialmente interesante en entornos industriales, debido al problema de disponibilidad de imágenes (Liu et al., 2025) (NIE & YU, 2025) . La técnica One-shot busca detectar anomalías mediante el uso de una sola imagen, el cual tiende al sobreajuste, five-shots lo hace con 5 imágenes y mejora bastante la precisión de acierto en entornos controlados (Singh & Pant, 2025).

Por último, el uso de modelos generativos ha cobrado relevancia como estrategia para mitigar la escasez de datos en entornos industriales. Los modelos de difusión (diffusion models) permiten generar imágenes sintéticas realistas a partir de un conjunto reducido de imágenes, aumentando la diversidad del dataset. Este enfoque ofrece la posibilidad de utilizar modelos de detección que requieren grandes volúmenes de datos, mejorando la capacidad de

generalización y precisión en la identificación de desgastes y anomalías. Sin embargo, la calidad y representatividad de las imágenes generadas sigue siendo un factor crítico que puede afectar al rendimiento final del sistema (Zhao et al., 2021).

A pesar de estos avances, ninguna de estas estrategias resuelve completamente el problema en entornos industriales reales. Los métodos basados en anomalías pueden ser sensibles a cambios en las condiciones de captura de la imagen, los enfoques few-shot presentan limitaciones de generalización, y los modelos generativos pueden introducir sesgos en los datos sintéticos. Esto evidencia que la escasez de datos sigue siendo una de las principales limitaciones en la aplicación de inteligencia artificial en procesos de fabricación.

La Tabla 3 sintetiza las distintas estrategias propuestas en la literatura para abordar la limitación derivada de la escasez de datos etiquetados, indicando para cada enfoque la necesidad de imágenes defectuosas, su principal ventaja y la limitación más relevante.

Tabla 3. Enfoques para detección de desgaste con pocos datos

Enfoque	Imágenes con defectos	Ventaja	Limitación
CNN	Si	Alta precisión	Muchos datos
PatchCore	No	No necesita defectos	Sensible al entorno
FastFlow	No	Distribución de datos	Complejidad
Few-shot	Pocos	Fácil adaptación a nuevos defectos	Generalización
Generativo	Pocos	Generación de dataset	Supervisión y validación de imágenes
SAM+LoRA	No	Interpretable, pocos datos, sin defectos	Requiere anotación manual de clases

Fuente: Elaboración propia

2.2.10. Latencia en producción en entornos de fabricación

La latencia en los sistemas de detección de anomalías en el sector industrial constituye un factor crítico cuando se necesita una detección en tiempo real de fabricación. Durante el proceso de mecanizado, si el sistema de detección de anomalías tarda varios segundos en procesar e inferir un resultado, la herramienta puede haber generado múltiples piezas defectuosas o haber roto una pieza de largo tiempo de fabricación y coste económico.

Esta necesidad de detección de anomalías en tiempo real ha impulsado el desarrollo de modelos diseñados para procesar la información manteniendo el equilibrio entre precisión y velocidad de inferencia. Modelos como EfficientAD demuestran que se pueden realizar detecciones de anomalías con latencias de milisegundos, permitiendo procesar cientos de imágenes por segundo sin alto coste de rendimiento (Batzner et al., 2024).

A pesar de los avances, sigue existiendo un compromiso entre precisión y tiempo de respuesta, especialmente en entornos industriales con recursos computacionales limitados. Este trade-off es uno de los principales desafíos en el diseño de arquitectura de sistemas de detección de anomalías basados en inteligencia artificial.

2.2.11. Modelado temporal del desgaste y detección temprana

En el contexto industrial, el desgaste de herramientas no es un fallo puntual que ocurre en un momento determinado del tiempo, sino que es un proceso progresivo de degradación que evoluciona a lo largo del tiempo. Analizar cada imagen de forma independiente puede resultar insuficiente para detectar el desgaste, especialmente en etapas de detección en etapas tempranas donde los cambios son sutiles.

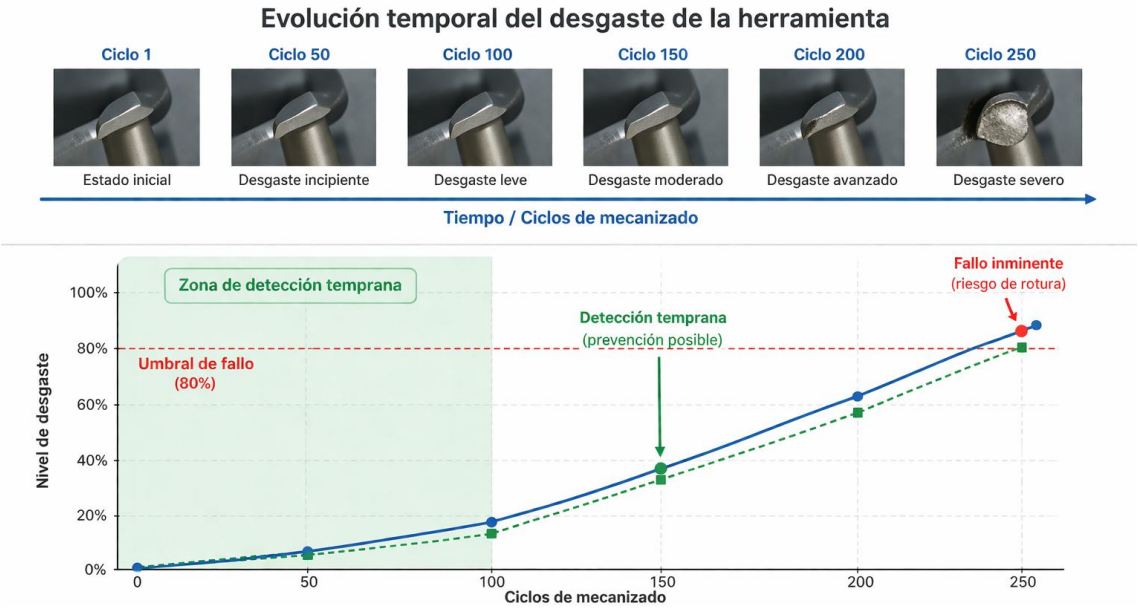
Para abordar esta problemática, se han utilizado redes neuronales recurrentes, en particular las redes que usan memorias a corto y largo plazo (LSTM), estas permiten modelar dependencias temporales a partir de secuencias de imágenes. De esta manera el sistema puede evaluar la evolución de la pieza lo largo del tiempo del uso, facilitando detectar desgastes progresivos, facilitando la detección temprana de patrones de desgaste o fallos incipientes (Kamat et al., 2024).

En el contexto industrial, hay diferentes enfoques que han combinado redes convolucionales con modelos LSTM, integrando la extracción automática de características con el análisis temporal. Trabajos más recientes han incorporado mecanismos de atención sobre estas arquitecturas, permitiendo al modelo centrarse en regiones más relevantes de la imagen, como es el filo de la rosca, reduciendo el impacto del ruido generado en el entorno industrial (Y. Wu & Chen, 2026).

A pesar de su capacidad para modelar la evolución temporal, estos enfoques presentan limitaciones importantes en entornos reales debido a la variabilidad de las condiciones de obtención de imágenes, presentando ruidos y posibles faltas de imágenes en la secuencia temporal, lo que limita su adopción en sistemas industriales de mecanizados.

La Figura 3 ilustra la evolución temporal del desgaste de una herramienta de mecanizado a lo largo de 250 ciclos de mecanizado.

Figura 3. Evolución temporal del desgaste de la herramienta.



2.2.12. Modelos fundacionales en visión industrial

La tecnología más reciente en la detección de desgaste mediante visión artificial es la incorporación de modelos fundacionales basados en transformers de visión (VIT). A diferencia

de las arquitecturas convolucionales, que analizan la imagen mediante ventanas locales deslizantes, los modelos VIT introducen mecanismos de autoatención que permiten relacionar distintas regiones de la imagen y evaluar la imagen de forma global.

Modelos como Segment Anything Model han supuesto un cambio significativo en tareas de segmentación, los modelos fundacionales están entrenados a base de cientos de miles de imágenes de muchos contextos, lo que permite identificar objetos o regiones de interés en imágenes no vistas previamente. Sin embargo, son modelos generalistas y carecen de conocimiento específico del dominio industrial para identificar desgastes en herramientas de mecanizado lo que limita su rendimiento (Li et al., 2024) .

Para adaptar los modelos fundacionales al contexto de detección de desgaste en mecanizados sin reentrenar un modelo que conlleva mucho tiempo y requisitos computacionales muy altos, se han propuesto técnicas como el Low-Rank Adaptation (LoRA), los cuales introducen modificaciones en los pesos en las capas de atención. Lo que permite especializar el modelo utilizando un número reducido de imágenes y recursos computacionales moderados, facilitando su aplicación cuando se dispone de datasets de imágenes limitados (Li et al., 2025).

También hay estudios que combinan modelos fundacionales con arquitecturas como U-Net. En este tipo de arquitecturas hibridas, U-Net se utiliza para identificar regiones de desgaste en la imagen, que posteriormente se envían como prompts a modelos SAM, mejorando la precisión en la segmentación de zonas de desgaste o micro-roturas (Li et al., 2024).

Por último, han comenzado a emerger arquitecturas multimodales que combinan información visual con otras fuentes de datos, como pueden ser los obtenidos por sensores o del CNC. Estas arquitecturas permiten enriquecer el análisis incorporando información adicional del contexto de fabricación para inferir de forma temprana las anomalías en el tiempo de ejecución del proceso mecanizado, lo que puede mejorar la robustez en sistemas industriales de fabricación complejos. Aun así, su aplicación práctica sigue siendo limitada debido a la complejidad de integración y la necesidad de datos sincronizados(Bayoudh et al., 2022) .

A pesar de los avances que representan los modelos fundacionales y las arquitecturas multimodales, estos enfoques aún presentan limitaciones en términos de especialización,

coste computacional y dependencia de datos de calidad, lo que mantiene abierta la investigación en este ámbito.

2.3.CONCLUSIONES

2.3.1. Justificación de la Visión Artificial y Deep Learning

La metrología tradicional actúa como un cuello de botella para la alta producción. La Visión Artificial se presenta como la única alternativa capaz de realizar una inspección del 100% de la producción a altas velocidades.

A diferencia de los métodos de contacto o láser, la visión combinada con Deep Learning ofrece ventajas competitivas:

- Detección de limpieza: Identificación de virutas o aceites atrapados.
- Análisis de integridad: Uso de redes neuronales convolucionales (CNN) para detectar micro-fisuras, rebabas y falta de hilos.
- No invasión: Al ser un método sin contacto, se elimina el riesgo de daño en la pieza y el desgaste de la herramienta de medida.

3. OBJETIVOS CONCRETOS Y METODOLOGÍA DE TRABAJO

3.1.OBJETIVO GENERAL

El objetivo general de este trabajo es desarrollar y comparar distintas estrategias basadas en inteligencia artificial para la detección de desgaste en roscas mediante técnicas de visión artificial. Para ello, se plantea un marco experimental común que evalúa comparativamente técnicas de preprocesamiento multiescala como BLMD, BEMD y wavelets, junto con cuatro aproximaciones de análisis: detección de anomalías mediante PatchCore, aprendizaje supervisado con pocos datos mediante MIL y EfficientNet-B0, segmentación con modelos fundacionales adaptados mediante SAM+LoRA, y segmentación basada en U-Net entrenada con máscaras sintéticas generadas a partir del perfil ISO.

Todas las estrategias se entrenan, ajustan y evalúan sobre un mismo conjunto de imágenes de roscas métricas M10×1,5, capturadas bajo condiciones homogéneas. Esta comparación permite analizar el rendimiento, la robustez y la interpretabilidad de cada enfoque ante un problema industrial caracterizado por la escasez de datos etiquetados, la variabilidad visual del desgaste y la necesidad de obtener decisiones trazables a nivel de pieza.

3.2.OBJETIVOS ESPECÍFICOS

Para alcanzar el objetivo general, se plantean los siguientes objetivos específicos:

- Definir un marco experimental común para la detección de desgaste en herramientas de roscado a partir de imágenes, estableciendo un dataset compartido y definiendo un protocolo de evaluación homogéneo y común entre las distintas estrategias.
- Diseñar y evaluar técnicas de preprocesamiento de imagen orientadas a mejorar la calidad visual de las imágenes de roscas, reduciendo el efecto de reflejos, ruido, variaciones de iluminación y artefactos en la imagen, con el objetivo de maximizar el rendimiento de las estrategias de detección posteriores. Dentro de este objetivo se comparan enfoques como BLMD, BEMD y wavelets, junto con variantes de filtrado homomórfico y configuraciones sin preprocesamiento.

- Implementar y adaptar distintas estrategias de inteligencia artificial para la detección de desgaste, incluyendo detección de anomalías, aprendizaje supervisado con pocos datos, segmentación con modelos fundacionales y segmentación mediante máscaras sintéticas basadas en el perfil ISO, evaluando su viabilidad en ámbitos industriales con acceso limitado a datos etiquetados.
- Evaluar el rendimiento de las estrategias desarrolladas mediante métricas adecuadas a cada enfoque y bajo un marco común de comparación, considerando resultados de clasificación, segmentación, detección de anomalías, agregación a nivel de pieza y coste computacional.
- Analizar la interpretabilidad de las predicciones y la trazabilidad de los resultados mediante visualizaciones, métricas y referencias teóricas que permitan justificar la decisión del sistema más allá de una identificación binaria de si la imagen de una rosca tiene o no desgaste.

Tabla 4. Objetivos específicos

Objetivo	Descripción resumida	Componente del software	Métricas de validacion
O1	Establecer marco común de comparación.	Dataset, protocolo común, partición por rosca.	Dataset documentado, LOO-CV, criterios homogéneos.
O2	Mejorar calidad visual de las imágenes.	BLMD, BEMD, wavelets, filtrado homomórfico, sin preprocesado	Comparativa de pipelines, métricas de calidad visual/SNR, coste de procesamiento.
O3	Desarrollar estrategias de inteligencia artificial.	PatchCore, SAM+LoRA, MIL+EfficientNet, U-Net	Modelos entrenados, resultados por estrategia
O4	Comparar el rendimiento de estrategias.	Clasificación, segmentación, anomalías, agregación por rosca	AUC, F1, matriz de confusión, IoU cuando procede, tiempo de inferencia.

O5	Justificar las decisiones del sistema.	GradCAM++, mapas de anomalía, máscaras, métricas geométricas	Visualizaciones, métricas interpretables, análisis de casos.

Fuente: Elaboración propia.

3.3. METODOLOGÍA DEL TRABAJO

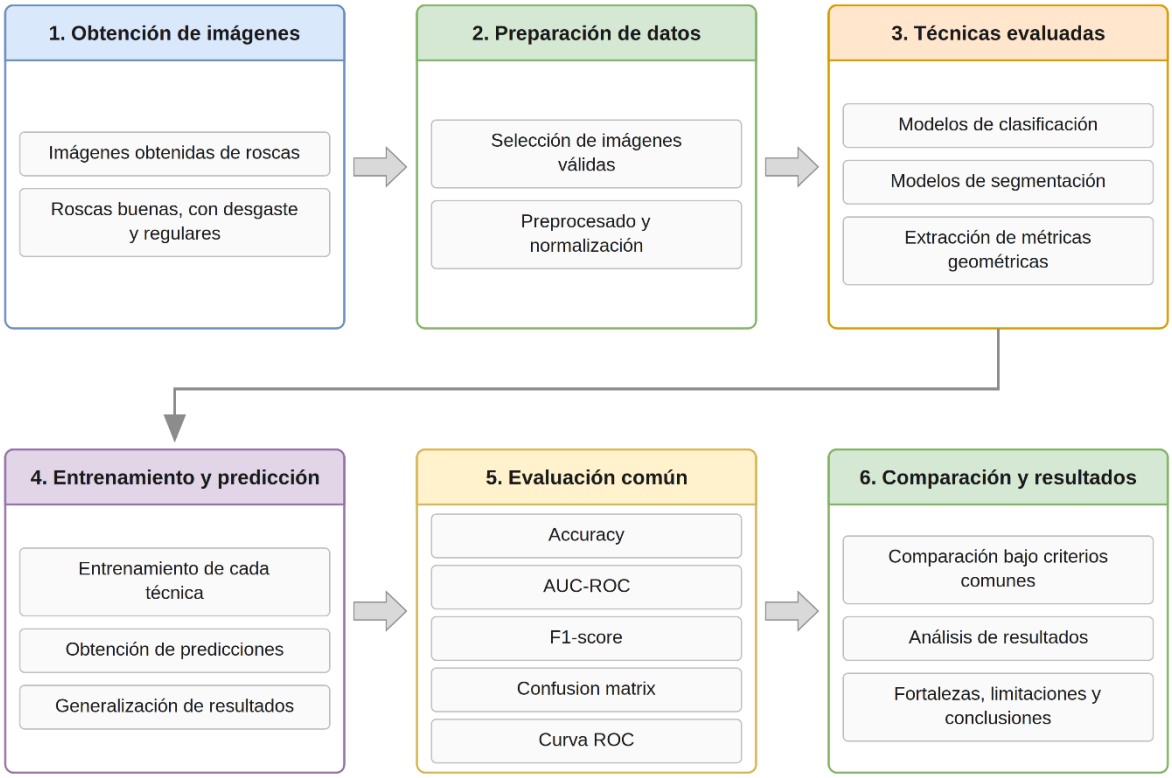
La metodología del trabajo se ha diseñado para comparar distintas estrategias de inteligencia artificial bajo un mismo marco experimental. Dado que el problema abordado combina visión artificial, escasez de datos etiquetados y necesidad de validación sobre herramientas reales, se adopta una metodología experimental orientada a evaluar no solo la precisión de cada modelo, sino también su robustez, coste computacional e interpretabilidad.

3.3.1. Enfoque metodológico

El trabajo se plantea como una comparativa experimental de soluciones aplicadas sobre un mismo problema: la detección de desgaste en herramientas de roscado a partir de imágenes. Todas las estrategias parten de un conjunto de datos común y se evalúan siguiendo criterios compartidos, aunque cada una aborda el problema desde una aproximación diferente. Esta decisión permite comparar modelos de distinta naturaleza sin perder la coherencia metodológica del estudio.

La Figura 4 resume el flujo general seguido en el trabajo, desde la preparación inicial de las imágenes hasta la evaluación de los modelos y el análisis de los resultados obtenidos.

Figura 4. Flujo metodológico global



Fuente: Elaboración propia.

3.3.2. Dataset y unidad de evaluación

El trabajo parte de un conjunto común de imágenes de herramientas de roscado M10×1,5, etiquetadas a nivel de pieza como buenas o con desgaste. Esta forma de etiquetado reproduce una situación habitual en entornos industriales, donde la decisión de calidad suele asignarse a la pieza completa y no a regiones concretas de cada imagen.

Además de esta etiqueta global, se utiliza la referencia ISO asociada a la rosca M10×1,5 como apoyo para el análisis geométrico. Esta referencia permite comparar algunas medidas estimadas de la rosca, como el paso o el perfil de la cresta, con los valores teóricos esperados. De este modo, la ISO no se emplea como etiqueta de entrenamiento, sino como criterio técnico complementario para interpretar las medidas obtenidas.

Todas las estrategias utilizan el mismo dataset como base, aunque cada una adapta internamente el formato de entrada según sus necesidades: imágenes completas, regiones de interés, máscaras geométricas, bolsas de imágenes o mapas de anomalía. La unidad principal

de evaluación es la rosca, no la imagen individual, ya que cada rosca puede estar representada por varias capturas correlacionadas entre sí.

3.3.3. Preprocesamiento y preparación de imágenes

Antes de aplicar los modelos de inteligencia artificial, se define una etapa común de preparación y análisis de las imágenes. Esta etapa incluye la revisión del dataset, la identificación de artefactos de captura, la normalización de las imágenes y, cuando procede, la aplicación de técnicas de preprocesamiento orientadas a mejorar la visibilidad del perfil de la rosca.

En este punto se comparan distintos enfoques de realce y filtrado, incluyendo BLMD, BEMD, wavelets, filtrado homomórfico y configuraciones sin preprocesamiento. El objetivo no es asumir de partida que una técnica es superior, sino medir su impacto sobre el rendimiento posterior de los modelos.

3.3.4. Protocolo de evaluación

La evaluación se plantea a nivel de rosca para evitar fugas de información entre entrenamiento y prueba. Cuando una misma pieza dispone de varias imágenes, estas no deben repartirse entre ambos conjuntos, ya que el modelo podría aprender características específicas de esa rosca y ofrecer resultados artificialmente optimistas.

Por este motivo, se emplea una validación Leave-One-Out Cross-Validation por rosca cuando la estrategia lo permite: en cada iteración se reserva una pieza completa para prueba y el resto se utiliza para entrenamiento o ajuste. De este modo, cada pieza actúa una vez como caso no visto y la evaluación refleja mejor la capacidad de generalización del sistema.

3.3.5. Métricas y criterios de comparación

Las métricas utilizadas se seleccionan en función de la naturaleza de cada estrategia, pero siempre dentro de un marco común de comparación. Para los enfoques de clasificación y detección de anomalías se consideran métricas como AUC-ROC, F1-score, precisión, recall y matriz de confusión. En los enfoques de segmentación se incorporan métricas como IoU por clase y, cuando procede, la evolución del IoU durante el entrenamiento incremental.

Además, cuando la salida del modelo permite obtener medidas geométricas, se calculan indicadores relacionados con la regularidad del perfil, la desviación respecto a referencias teóricas y la coherencia de las regiones detectadas. También se tiene en cuenta el coste computacional, especialmente el tiempo de entrenamiento, el tiempo de inferencia por imagen y los recursos necesarios para ejecutar cada aproximación.

3.3.6. Agregación de resultados e interpretabilidad

Dado que el diagnóstico final debe interpretarse a nivel de pieza, las predicciones obtenidas sobre imágenes individuales se agregan cuando es necesario. Esta agregación permite transformar varias salidas parciales en una única decisión sobre el estado de la rosca.

Dependiendo de la estrategia, esta decisión puede basarse en el valor máximo de anomalía, en un umbral calibrado sobre herramientas buenas, en la combinación de métricas geométricas o en el score global aprendido por el modelo. Este criterio es especialmente relevante porque al localizarse el desgaste en secciones concretas del filo, una rosca desgastada puede tener imágenes que caen sobre zonas todavía en buen estado y en las que el defecto no aparece.

Finalmente, la metodología incorpora una fase de análisis visual e interpretabilidad. Además de comparar métricas numéricas, se revisan salidas como máscaras de segmentación, mapas de activación, mapas de anomalía, perfiles geométricos y visualizaciones agregadas. Esta fase permite comprobar si las decisiones del sistema se apoyan en regiones coherentes con el desgaste real de la rosca y si los resultados pueden justificarse más allá de una clasificación binaria.

3.4. ESTRATEGIAS DE INTELIGENCIA ARTIFICIAL

Una vez definido el marco metodológico común, el trabajo compara cuatro estrategias de inteligencia artificial orientadas a resolver el problema de detección de desgaste desde enfoques complementarios. La elección de estas estrategias responde a las principales limitaciones identificadas en el contexto industrial: escasez de datos etiquetados, dificultad

para disponer de máscaras reales de desgaste, variabilidad visual entre imágenes y necesidad de obtener resultados interpretables.

Las cuatro aproximaciones seleccionadas no compiten únicamente como modelos alternativos, sino que representan formas distintas de abordar el mismo problema. Por un lado, se incluyen métodos supervisados capaces de aprender patrones discriminativos cuando existen etiquetas disponibles. Por otro, se incorporan enfoques que reducen la dependencia de ejemplos defectuosos o de anotaciones manuales exhaustivas, aspecto especialmente relevante en escenarios industriales donde obtener imágenes representativas de desgaste real puede ser costoso y poco frecuente.

La estrategia SAM+LoRA se plantea como una aproximación basada en modelos fundacionales de visión. Su objetivo es adaptar un modelo generalista de segmentación al dominio específico de las roscas mediante un ajuste eficiente con pocos parámetros entrenables. Esta estrategia permite estudiar hasta qué punto un modelo previamente entrenado sobre grandes volúmenes de datos puede especializarse en un problema industrial concreto con un número limitado de imágenes anotadas.

La estrategia basada en Multiple Instance Learning con EfficientNet-B0 aborda el problema desde una perspectiva supervisada con etiquetas a nivel de pieza. En lugar de requerir una etiqueta individual para cada imagen, considera cada rosca como un conjunto de capturas y aprende a emitir un diagnóstico global. Este planteamiento resulta adecuado cuando la anotación disponible indica si la rosca está desgastada o no, pero no especifica en qué imagen o zona aparece el defecto.

La estrategia basada en U-Net con máscaras sintéticas ISO explora la posibilidad de entrenar un modelo de segmentación sin disponer de máscaras reales anotadas manualmente para todas las imágenes. Para ello, utiliza referencias geométricas generadas a partir del perfil teórico de la rosca. Esta aproximación permite evaluar si una representación ideal de la geometría puede servir como base para detectar desviaciones asociadas al desgaste.

Por último, PatchCore se emplea como estrategia de detección de anomalías. Este enfoque se entrena únicamente con imágenes de piezas buenas y considera anómala cualquier desviación relevante respecto a ese patrón de normalidad. Su inclusión es especialmente relevante para

el problema tratado, ya que en un entorno industrial suele ser más sencillo recopilar ejemplos conformes que construir un conjunto amplio y equilibrado de defectos reales.

La Tabla 5 resume las principales características de las estrategias comparadas y sirve como punto de entrada al desarrollo específico que se presenta en el capítulo 4.

Tabla 5. Resumen de las estrategias de inteligencia artificial estudiadas

Estrategia	Tipo de enfoque	Entrada	Nivel anotación	Objetivo	Aportación
SAM+LoRA	Segmentación con modelo fundacional adaptado	Imágenes de roscas y máscaras de cresta/paso	Máscaras manuales de cresta y paso	Adaptar un modelo generalista de segmentación al dominio de las roscas industriales	Permite obtener máscaras interpretables y calcular métricas geométricas asociadas al desgaste
MIL + EfficientNet-B0	Clasificación supervisada débil	Conjunto de imágenes asociadas a cada pieza	Etiqueta global por pieza	Clasificar herramientas buenas o con desgaste sin etiquetar cada imagen de forma individual	Reduce la necesidad de anotación detallada y trabaja con etiquetas a nivel de pieza
U-Net + máscaras sintéticas ISO	Segmentación supervisada con referencia geométrica	Imágenes de roscas y máscaras generadas a partir del perfil ISO	Máscaras sintéticas basadas en geometría teórica	Evaluar si una referencia ideal de la rosca permite detectar desviaciones geométricas	Permite entrenar segmentación sin depender exclusivamente de máscaras reales anotadas manualmente
PatchCore	Detección de anomalías	Imágenes de piezas buenas	Solo ejemplos conformes para entrenamiento	Detectar desviaciones respecto al patrón de normalidad aprendido	Resulta adecuado cuando existen pocas muestras de desgaste y predominan ejemplos buenos

Fuente: Elaboración propia.

3.5. PREPOCESADO E INFRAESTRUCTURA COMPÁRTIDA

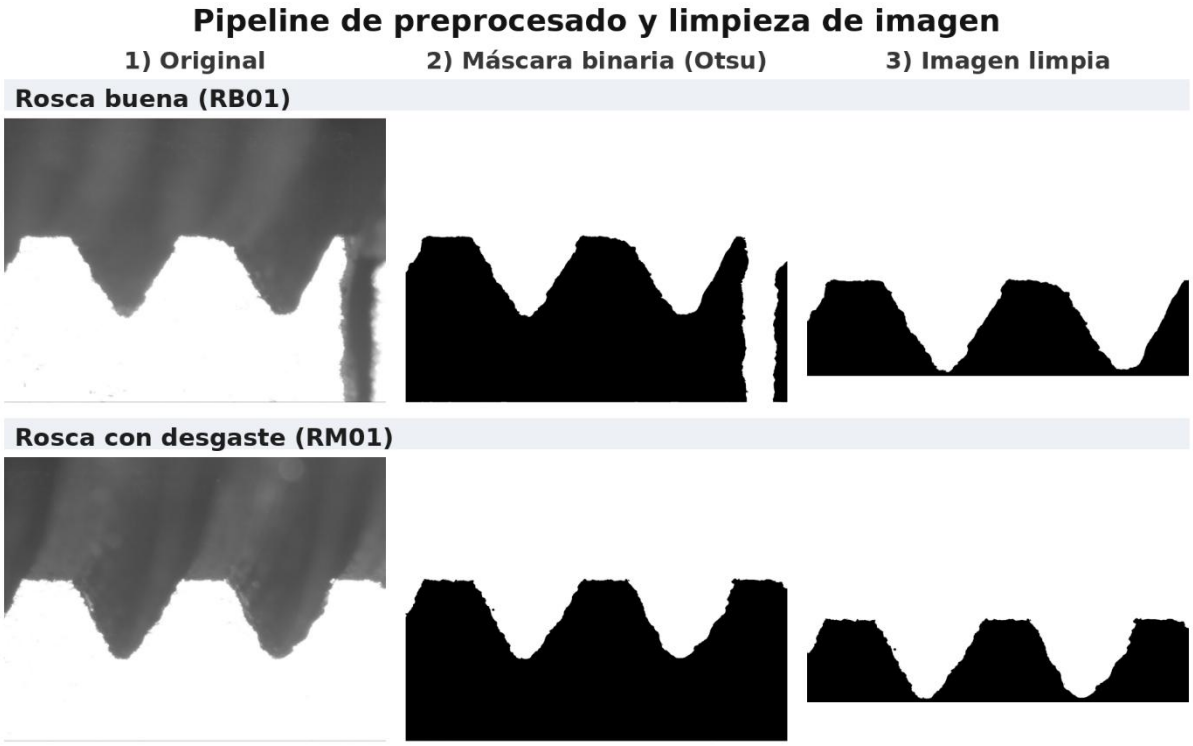
3.5.1. Segmentación Otsu y morfología

Para aplicar correctamente el modelo SAM+LoRA, las imágenes obtenidas de las roscas se preparan previamente con el objetivo de reducir elementos que puedan interferir en la segmentación. Las capturas originales pueden presentar variaciones de iluminación, ruido de fondo, reflejos, brillos saturados o zonas ajenas a la geometría principal de la rosca. Esta fase es relevante porque la estrategia depende de identificar correctamente las regiones de cresta y paso; por tanto, cualquier error o alteración en la imagen de entrada puede propagarse posteriormente al cálculo de las métricas geométricas.

El proceso de preparación parte de la imagen original y genera una representación más limpia de la zona útil de la rosca. Para ello, se aplica un pipeline de limpieza compuesto por varias operaciones. En primer lugar, se neutralizan los brillos saturados con valores de intensidad superiores a 240, reduciendo el efecto de reflejos muy marcados. A continuación, se aplica umbralización de Otsu para separar la rosca del fondo claro y obtener una máscara binaria, donde el perfil de la rosca queda representado en blanco y el fondo en negro. Posteriormente, se eliminan artefactos pequeños y fragmentos sueltos, se detecta el cabezal visible de la rosca, que aparece como una línea vertical de mayor longitud, y se elimina de la imagen. Finalmente, se realiza un recorte vertical para ajustar la imagen a la zona relevante de la rosca.

Como se observa en la Figura 5, el pipeline se aplica tanto sobre imágenes de roscas buenas como sobre imágenes de roscas con desgaste. En ambos casos se parte de la imagen original, se genera una máscara binaria mediante Otsu y se obtiene una imagen limpia tras la eliminación de artefactos y el recorte de la zona útil. Esta transformación permite reducir el fondo y conservar principalmente la geometría de la rosca, facilitando la posterior anotación manual y la segmentación de crestas y pasos mediante SAM+LoRA.

Figura 5. Preparación de imágenes antes de la segmentación con SAM+LoRA.



Fuente: Elaboración propia.

Esta preparación no se considera una etapa meramente auxiliar, ya que condiciona la estabilidad de las máscaras predichas. Una región mal aislada, un artefacto no eliminado o una variación fuerte de iluminación pueden alterar la segmentación y, en consecuencia, modificar métricas como el área de cresta, la rectangularidad o la horizontalidad del paso.

3.5.1.1. Separación rosca

El primer módulo de procesado aplica umbralización de Otsu sobre la imagen completa en escala de grises para separar la zona oscura de la pieza del fondo saturado. El método de Otsu determina el umbral óptimo de binarización maximizando la varianza inter-clase entre los dos grupos de píxeles (fondo claro y rosca oscura):

$$\sigma_B^2(t) = w_0(t) \cdot w_1(t) \cdot [\mu_0(t) - \mu_1(t)]^2 \quad (1)$$

donde w_0, w_1 son las probabilidades acumuladas de cada clase y μ_0, μ_1 sus medias de intensidad. El umbral óptimo $t*$ maximiza esta varianza inter-clase sobre todos los posibles valores de umbral.

Dado que la rosca es más oscura que el fondo, se aplica umbralización inversa: los píxeles por debajo del umbral (rosca) quedan a 255 y los del fondo a 0. A continuación se aplica cierre morfológico con un elemento estructurante elíptico de 15×15 píxeles para rellenar los huecos internos de la región de pieza, principalmente los valles de rosca, cuya profundidad puede provocar intensidades similares al fondo en algunas imágenes. El resultado es una máscara binaria de la región de interés (ROI) y la imagen enmascarada (con el fondo anulado a cero) sobre la que operan todos los enfoques posteriores. El resultado se almacena en caché por ruta de imagen, de modo que los tres enfoques comparten el mismo resultado sin recalcularlo.

3.5.1.2. Objetivo general estrategia

El bloque de segmentación aísla la rosca del fondo de la imagen antes de que el detector y el perfilómetro procesen los píxeles. Esta etapa garantiza que las decisiones del sistema se basan en la geometría real de la rosca y no en variaciones del entorno (sombras, reflejos del soporte, suciedad del campo de visión). La segmentación se ha implementado con un esquema robusto y libre de hiperparámetros manuales por imagen.

El procedimiento consta de cuatro pasos en cascada:

- Umbralización adaptativa de Otsu sobre la imagen en escala de grises, que separa píxeles claros y oscuros de forma óptima sin ajuste manual.
- Cierre morfológico con kernel 15×15 para rellenar pequeñas oclusiones del filo causadas por reflejos especulares puntuales.
- Selección de la componente conexa de mayor área que cubre al menos el 5 % del marco, descartando ruido residual y manchas aisladas del fondo.
- Filtrado por orientación: la rosca debe ocupar predominantemente la mitad inferior de la imagen, lo que descarta capturas mal encuadradas.

Sobre la máscara binaria resultante se calcula una banda de contorno perimetral de 20 píxeles que delimita la zona del filo donde se concentra la información relevante para detectar desgaste.

3.5.2. Calibración de escala (px/mm)

Todos los parámetros geométricos de la rosca (paso, altura del diente y ancho de cima) se expresan en milímetros. La conversión a píxeles requiere el factor de escala px_per_mm. Para obtenerlo, se analiza el perfil de intensidad media por columna en la zona de rosca del ROI enmascarado: las cimas de los dientes producen máximos locales de brillo porque corresponden a zonas de material plano perpendicular al eje óptico. La distancia en píxeles entre picos consecutivos se divide por el paso físico de rosca:

$$px_per_mm = \frac{distancia_entre_picos_px}{pitch_mm} \quad (2)$$

Para un macho M10×1.5 el paso es exactamente 1.5 mm, lo que produce un factor de escala de 572 px/mm a la magnificación del microscopio Leica MZ125 empleado. La detección de picos se realiza exclusivamente sobre el 75% central de la imagen (columnas del 0% al 75% del ancho) para excluir la cabeza del macho, que ocupa el borde derecho de algunas imágenes y tiene un perfil de intensidad diferente a la zona activa de rosca.

Para garantizar la coherencia del factor de escala a lo largo de todo el sistema, el acceso a este valor se ha centralizado mediante una resolución en cadena: primero se busca la clave px_per_mm directamente en el fichero de configuración YAML del enfoque; si no está presente, se busca el fichero de calibración cuya ruta se especifica en la configuración; y como último recurso se aplica un valor conservador

por defecto de 348.0 px/mm.

3.5.3. Generación de la máscara ideal ISO

La máscara ideal es una imagen binaria generada matemáticamente que representa dónde debería estar el material de rosca según la geometría perfecta del macho M10×1.5. Sirve como referencia geométrica para los enfoques que cuantifican el desgaste como desviación respecto al perfil teórico.

3.5.3.1. Parámetros geométricos ISO

El perfil del diente, trapezoidal según ISO 68-1, presenta para M10×1,5 las dimensiones básicas recogidas en ISO 724 (Tabla 6) (International Organization for Standardization, 2023b, 2023a)

Tabla 6. Dimensiones básicas ISO 724

Parámetro	Símbolo	Valor M10×1.5	Valor en px (572 px/mm)
Paso de rosca	P	1.5 mm	858 px
Altura del diente (valle→cima)	h	0.76 mm	435 px
Ancho de cima plana (norma P/8)	c	0.19 mm	109 px
Ancho de valle plano (P − c − 2f)	a_v	0.43 mm	247 px
Semiancho de valle (a_v / 2)	v	0.216 mm	124 px
Ángulo de flanco	—	60°	—
Proyección horiz. del flanco (h/tan60°)	f	0.44 mm	251 px

Fuente: Elaboración propia.

3.5.3.2. Algoritmo de generación columna a columna

La función itera sobre todas las columnas de la imagen. Para cada columna se calcula su posición relativa dentro del ciclo de paso mediante el operador módulo:

$$x_{rel} = (col - x_{inicio}) \bmod pitch_{px} \quad (3)$$

donde x_inicio centra el patrón en la imagen. El operador módulo hace el patrón periódico, repitiéndose a lo largo de todo el ancho. Dentro de cada ciclo se distinguen cinco zonas:

Tabla 7. Zonas del ciclo de paso y altura del perfil ISO

x_rel	[0, 54]	[54, 305]	[305, 414]	[414, 665]	[665, 858]
Zona	Valle ½ izq	Flanco subida	Cima plana	Flanco bajada	Valle ½ der
h_px	0	0 -> 435 (lineal)	435	435 -> 0 (lineal)	0

Fuente: Elaboración propia.

Para los flancos, la altura se interpola linealmente:

- Flanco de subida:

$$h = (x_{rel} - v)/f \times height_{px} \quad (4)$$

- Flanco de bajada:

$$h = (1 - (x_{rel} - v - f - c)/f) \times height_{px} \quad (5)$$

Una vez calculada la altura h para cada columna, la máscara se rellena de blanco desde la fila `center_row` − h hasta el borde inferior de la imagen, de forma que el cuerpo sólido del macho (zona por debajo de los valles) queda siempre relleno. Finalmente se aplica una inversión vertical (`flipud`) para adecuar la orientación al dataset: en las imágenes reales el cuerpo sólido ocupa la franja superior del ROI (filas 0–659) y la zona de rosca apunta hacia abajo, mientras que el algoritmo de generación produce la orientación contraria.

3.5.3.3. Posicionamiento vertical automático de la máscara

El algoritmo de generación requiere como entrada la fila donde se sitúan los valles de rosca (`center_row`). Este valor se detecta automáticamente para cada imagen mediante el análisis

del perfil de intensidad media por fila del ROI enmascarado (con fondo a cero). El cuerpo sólido del macho presenta una media alta (~120 unidades de gris). Los valles de rosca interrumpen el material con franjas de fondo negro, reduciendo la media por fila. La frontera cuerpo/rosca se detecta como la primera fila donde la media cae un 25% desde el nivel del cuerpo sólido:

$$threshold = body_level - 0.25 \times (body_level - bg_level) \quad (6)$$

El umbral del 25% detecta el inicio de los valles (donde el fondo negro comienza a reducir la media), evitando el 50% que caería en la mitad de la transición. Una vez detectada la fila de frontera `boundary`, `center_row` se calcula como `H - 1 - boundary`, convirtiendo el índice desde la parte superior al sistema de referencia interno de la función de generación (que opera antes del `flipud`).

Este componente se ha integrado en todos los enfoques que emplean la máscara ideal. En la Figura 6 se puede observar la máscara ideal generada por el algoritmo.

Figura 6. Máscara ideal generada por el algoritmo.



Fuente: Elaboración propia

3.5.4. Registro y alineación de la máscara

El módulo de registro alinea la máscara ideal sobre el ROI real mediante dos componentes independientes: la alineación vertical y la horizontal.

La alineación vertical se realiza mediante correlación cruzada normalizada de perfiles de fila. Se calcula el gradiente Sobel vertical del ROI real (que resalta los bordes horizontales del perfil de rosca) y la media por fila del ROI y de la máscara ideal. La correlación cruzada de estos dos perfiles unidimensionales (implementada mediante convolución en el dominio de la frecuencia con fftconvolve) produce un pico en el desfase que maximiza la superposición vertical. Se calcula un índice de confianza normalizado como (pico-media)/pico si la confianza cae por debajo de 0.3, la máscara se deja sin desplazar para evitar alineaciones espurias. La traslación vertical se aplica mediante transformación afín.

Alineación horizontal de fase mediante autocorrelación del perfil de columnas medias. El perfil de intensidad media por columna en la zona de rosca es una señal periódica con el mismo periodo que el paso de rosca. La autocorrelación de una señal periódica presenta un pico en el lag igual al periodo, con independencia de si la señal tiene mesetas planas (como ocurre con las cimas de 109 px). Esta propiedad hace que la autocorrelación sea más robusta que la detección de picos (find_peaks), que requiere máximos locales estrictos y falla en las mesetas. El paso estimado para M10×1.5 a 572 px/mm es de 858 px. A partir de este valor se calcula el desfase horizontal óptimo mediante correlación cruzada restringida a una ventana de ±pitch/2 y se aplica mediante traslación afín con warpAffine y relleno de borde a cero (sin envoltura circular, para evitar dientes espurios en los bordes). Las columnas negras que quedan en los bordes tras la traslación se rellenan copiando desde la posición desplazada exactamente ±858 px, aprovechando la periodicidad de la rosca, de modo que ninguna columna de la máscara registrada queda vacía.

3.6. PREPOCESADO E INFRAESTRUCTURA COMPÀRTIDA

3.6.1. Entorno experimental y reproducibilidad

La implementación se realiza principalmente en Python, utilizando librerías de visión artificial, aprendizaje profundo y análisis de datos. OpenCV se emplea para las operaciones de procesado de imagen, PyTorch para el entrenamiento e inferencia de modelos neuronales, scikit-learn para métricas y validación, y librerías específicas según cada estrategia.

Los experimentos se registran de forma estructurada mediante ficheros de configuración, bases de datos locales o herramientas de seguimiento de experimentos, según las necesidades de cada aproximación. Este registro permite conservar los parámetros utilizados, las particiones de datos, las métricas obtenidas y las salidas generadas, facilitando la trazabilidad y reproducción de las pruebas realizadas.

3.6.2. Visualización, trazabilidad y ejecución de experimentos

Con el fin de poder probar los modelos desarrollados, así como revisar y comparar los experimentos realizados, se han utilizado interfaces desarrolladas en Streamlit. Streamlit es un framework de Python que permite crear aplicaciones web de forma sencilla, sin necesidad de desarrollar una interfaz completa con HTML, CSS y JavaScript. Por este motivo, se ha utilizado como herramienta de apoyo para visualizar resultados, consultar métricas y revisar las predicciones generadas por las distintas estrategias.

La aplicación se plantea como una herramienta común de trabajo. Su objetivo es facilitar la ejecución de pruebas, la consulta de experimentos y el análisis de los resultados obtenidos con las distintas configuraciones. De esta forma, el proceso resulta más rápido e interactivo que revisar únicamente scripts de Python, notebooks o ficheros de salida, ya que la información principal queda centralizada en una interfaz.

La herramienta permite consultar los experimentos ejecutados, comparar configuraciones y revisar métricas como accuracy, AUC-ROC, AUPRC, F1-score, IoU cuando procede, tiempo de entrenamiento y tiempo de inferencia. Con esto no solo se analiza el resultado final del modelo, sino también el coste computacional asociado a cada prueba.

Además, la aplicación permite revisar salidas visuales generadas por las distintas estrategias, como máscaras de segmentación, mapas Grad-CAM, mapas de anomalía, comparación con el perfil ISO, curvas ROC, matrices de confusión o mapas de desviación. Esto es importante porque las implementaciones no buscan únicamente obtener una métrica final, sino facilitar la comprensión de cómo se ha llegado a cada resultado.

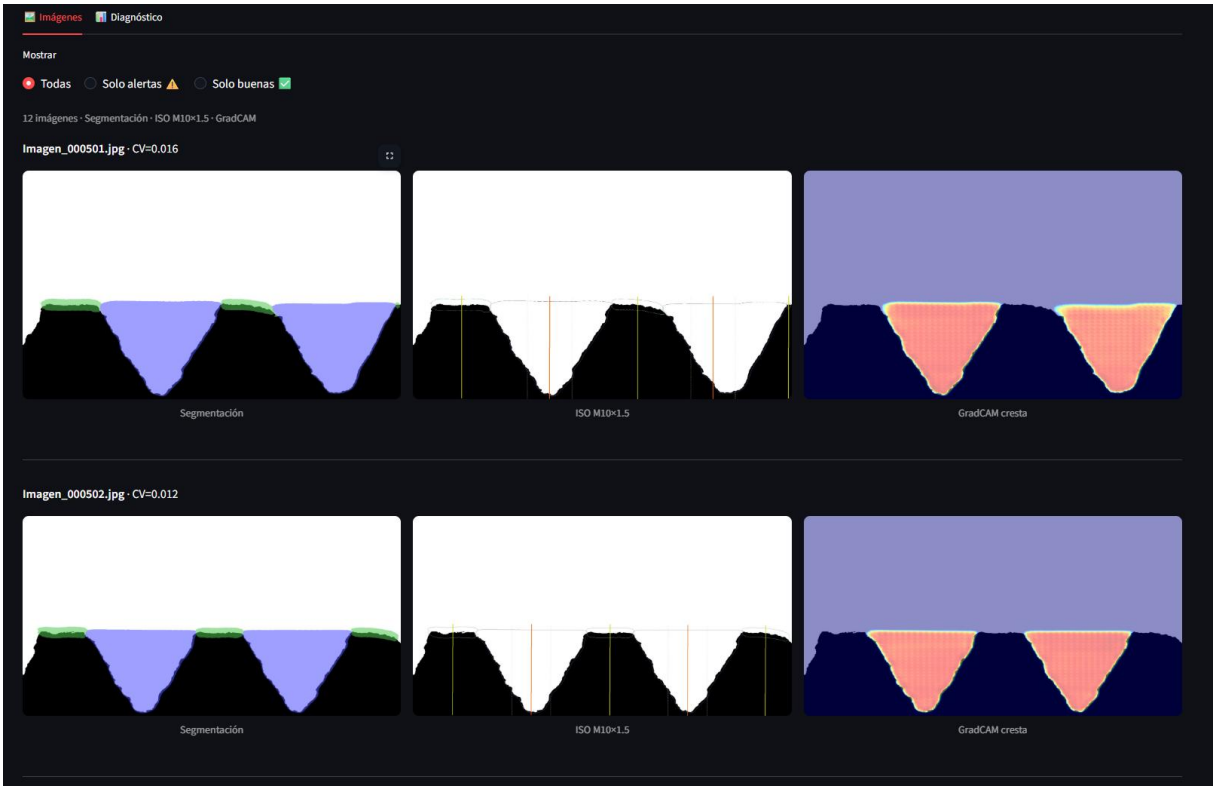
En la Figura 7 se muestran dos ejemplos de las interfaces desarrolladas en Streamlit. La primera vista permite consultar los experimentos ejecutados, comparar métricas y revisar las configuraciones probadas. La segunda vista está orientada a la comparación de ramas de clasificación y a la visualización de predicciones sobre imágenes concretas.

La preparación inicial de las imágenes, el entrenamiento de los modelos y el cálculo de métricas se realizan en los notebooks o scripts correspondientes a cada estrategia. Por tanto, Streamlit actúa principalmente como una capa de visualización, inferencia y trazabilidad, permitiendo centralizar los resultados y facilitar su análisis posterior.

Con este planteamiento, la herramienta queda integrada dentro de la metodología común del trabajo. Cada estrategia mantiene su desarrollo específico en el capítulo 4, mientras que las interfaces desarrolladas en Streamlit se utilizan como soporte común para revisar experimentos, comparar resultados y analizar visualmente las decisiones obtenidas.

Figura 7. Herramienta de visualización y análisis implementado con Streamlit





Fuente: Elaboración propia.

4. DESARROLLO ESPECÍFICO DE LA CONTRIBUCIÓN

En este apartado se explica las diferentes estrategias utilizadas en la primera fase para la identificación de desgaste en imágenes de roscas.

4.1. ESTRATEGIA SAM+LORA

Propósito de la estrategia y uso industrial

En vez de decidir directamente si una rosca está gastada, esta estrategia primero "recorta" la rosca en sus partes (las crestas, que son los dientes salientes, y los pasos, que son los huecos entre dientes) y después mide si esas partes son regulares. Si los dientes varían mucho de tamaño o forma, sospecha desgaste. La ventaja es que el resultado se puede revisar: se ve qué zona de la imagen ha provocado la alarma y las métricas asociadas.

La estrategia SAM + LoRA se basa en adaptar el modelo fundacional Segment Anything Model (SAM), modelo fundacional de segmentación general desarrollado por Meta AI, entrenado con millones de máscaras de segmentación sombre millones de imágenes, a la detección de desgaste en imágenes de roscas mediante Low-Rank Adaptation (LoRA). Esta estrategia no plantea el modelo como un clasificador directo de roscas buenas o con desgaste, sino como un modelo de segmentación basado en la geometría visible de la rosca. Para ello, el modelo aprende a identificar dos zonas principales: las crestas, que corresponden a las zonas más salientes de la rosca, y los pasos, entendidos como la región o espacio entre dos crestas consecutivas.

A partir de las máscaras predichas por el modelo para la cresta y el paso, se calculan diferentes métricas geométricas que permiten analizar si la rosca mantiene una forma regular o si presenta desviaciones que puedan asociarse al desgaste de la rosca.

Desde un punto de vista de uso industrial, esta estrategia se entiende como una inspección visual asistida por inteligencia artificial. Para ello, primero se segmentan las zonas principales detectadas de la rosca y posteriormente se analizan las métricas para identificar si mantienen una geometría correcta y cercana a la ISO, identificando como desgaste las métricas que se alejen de las métricas establecidas como rosca buena.

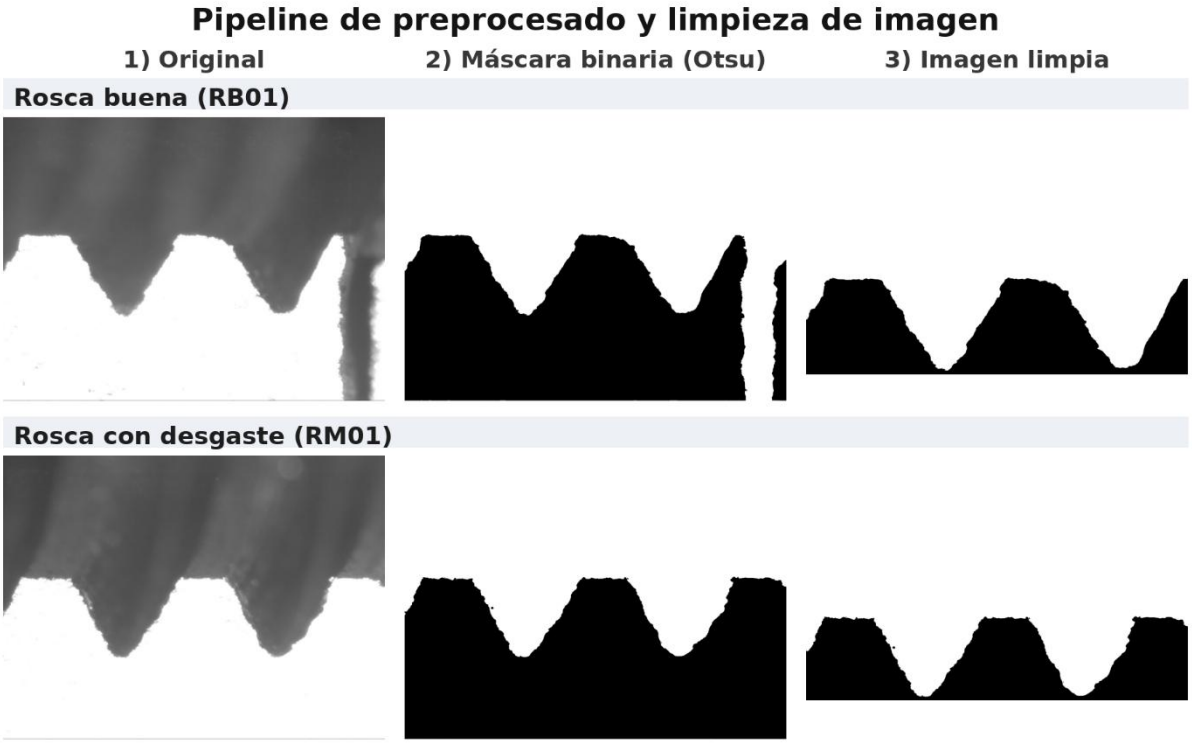
Esta estrategia puede resultar útil en industria ya que no se limita a clasificar una imagen de una rosca, sino que enriquece esta clasificación con las métricas y las áreas segmentadas que influyen en la clasificación. Esto aporta trazabilidad a la clasificación indicando cuál es el motivo de la clasificación, lo cual es muy relevante tanto en un entorno industrial como en el uso de herramientas de inteligencia artificial.

Todo el proceso de entrenamiento e inferencia se ejecuta de forma local, sin necesidad de enviar datos a servidores externos o servicios en la nube, lo que garantiza la privacidad de las imágenes del proceso de fabricación.

4.1.1. Datos utilizados y mascaras manuales

Para adaptar SAM+LoRA al dominio de las roscas se utilizó el dataset facilitado para la elaboración de este trabajo. Antes de crear las máscaras, las imágenes se preprocesan para generar versiones de alto contraste tal y como se explica en el capítulo 3, donde la rosca aparece en blanco sobre un fondo negro, como se muestra en la Figura 8, lo que facilita la identificación manual de las zonas que posteriormente se utilizarán como máscaras de entrenamiento.

Figura 8. Preparación de imágenes antes de la segmentación con SAM+LoRA.



Fuente: Elaboración propia.

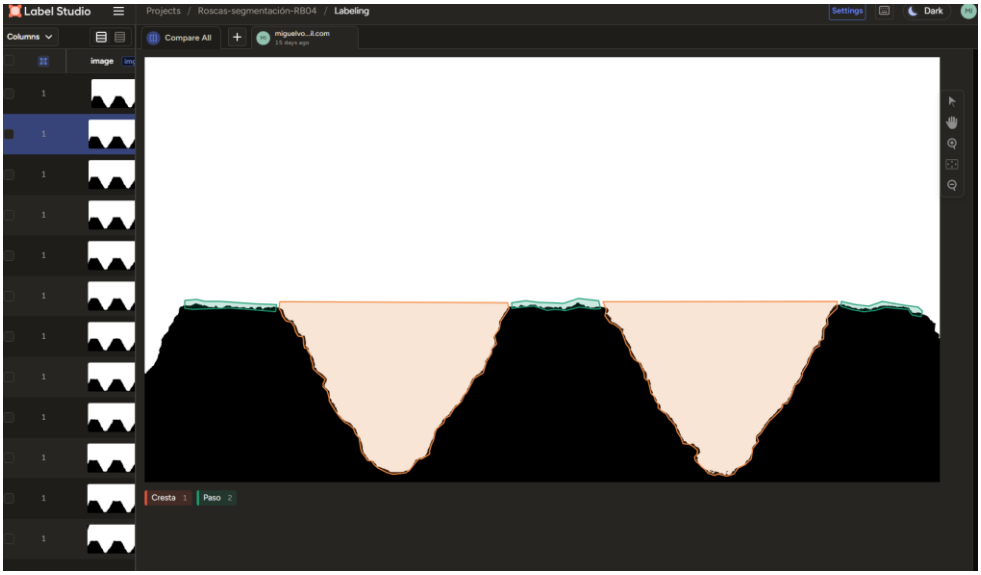
En esta estrategia solo se crearon máscaras manuales de las imágenes de roscas sin desgaste. El objetivo no es entrenar al modelo para reconocer directamente una zona desgastada, sino enseñarle la geometría de una rosca en buen estado, para que el modelo pueda detectar anomalías cuando las regiones segmentadas contengan variaciones relevantes, como puede ser una menor superficie de cresta, perfiles más lisos o deformaciones visibles en la geometría.

Para crear estas máscaras se ha utilizado la herramienta Label Studio, configurando 11 proyectos segmentación mediante polígonos, tantos como roscas sin desgaste del dataset utilizado, en la Figura 7 se puede observar cómo se definen dos clases geométricas una para área importante en la rosca como son la cresta y el paso. Y se identifican estas áreas en cada una de las imágenes de todas las roscas sin desgaste. Esta separación permite que el modelo no solo aprenda la silueta general de la rosca, sino también la alternancia geométrica entre crestas y pasos, que posteriormente permitirá calcular métricas de regularidad y detectar posibles desviaciones en cualquiera de las dos clases.

Para crear estas máscaras se utilizó la herramienta Label Studio, donde se configuraron 11 proyectos de segmentación mediante polígonos, uno por cada rosca sin desgaste del dataset. En la Figura 9 se muestra el proceso de creación de máscaras, donde se definen dos clases geométricas: la cresta y el paso.

Esta separación permite que el modelo no aprenda únicamente la silueta general de la rosca, sino también la alternancia geométrica entre crestas y pasos. Esta información será utilizada posteriormente para calcular métricas de regularidad y así poder detectar posibles desviaciones en cualquiera de las dos clases.

Figura 9. Ejemplo de anotación manual de crestas y pasos en Label Studio



Fuente: Elaboración propia.

La Tabla 8. Resumen de anotaciones manuales en Label Studio resume el número de imágenes y anotaciones generadas manualmente para cada rosca sin desgaste, diferenciando las regiones etiquetadas para cada clase definida.

Tabla 8. Resumen de anotaciones manuales en Label Studio

Rosca	Clase	Imágenes	Mascara cresta	Mascara paso	Total
RB01	Buena	11	22	32	54
RB02	Buena	11	22	32	54
RB03	Buena	11	22	33	55
RB04	Buena	12	24	35	59
RB05	Buena	12	24	36	60
RB06	Buena	12	24	35	59
RB07	Buena	12	24	35	59
RB08	Buena	12	24	35	59
RB09	Buena	12	24	35	59
RB10	Buena	12	22	35	57
RB11	Buena	12	24	35	59
Total	---	129	256	378	634

Fuente: Elaboración propia.

Una vez generadas las máscaras, cada proyecto de Label Studio se exportó en formato COCO. Estos ficheros contienen la información de las imágenes del proyecto, clases anotadas y segmentación definida por los puntos de cada polígono de cada máscara creada. Este formato permite utilizar las anotaciones como entrada durante el proceso de entrenamiento del modelo.

La creación de las máscaras es una parte muy sensible de la estrategia, ya que su calidad influye directamente en el aprendizaje del modelo. Si las máscaras son poco precisas, el error

de precisión en la segmentación puede afectar al cálculo de métricas geométricas como el área, la solidez, la rectangularidad o la regularidad de las regiones de cresta y paso.

4.1.2. Cómo se entrena

Se parte de SAM, un modelo de Meta que ya sabe recortar objetos en fotos, y se reentrena con unas pocas roscas anotadas para que aprenda a separar "crestas" y "pasos". Solo se reentrena una parte muy pequeña del modelo, así que el ajuste es rápido y necesita pocas imágenes.

Para el entrenamiento se parte de un modelo fundacional SAM ya preentrenado. Para esta estrategia se usa SAM ViT-B, desarrollado por Meta AI. Esta versión se selecciona por ofrecer un equilibrio adecuado entre capacidad de segmentación y coste computacional, permitiendo adaptar el modelo al dominio de las roscas sin utilizar modelos de mayor tamaño y sin la necesidad de crear un modelo de segmentación few-shot desde cero.

El entrenamiento se centra en enseñar al modelo a segmentar correctamente las crestas y los pasos a partir de las máscaras creadas de forma manual. Para ello, en el entrenamiento se realizan comparaciones entre la máscara que el modelo predice y la máscara manual que contiene el fichero con formato COCO. El objetivo que se busca no es que el modelo aprenda a etiquetar si la imagen es buena o contiene desgaste, sino que aprenda a identificar y separar de forma estable las zonas geométricas de interés: cresta y paso. Estas zonas después se utilizarán para calcular las métricas.

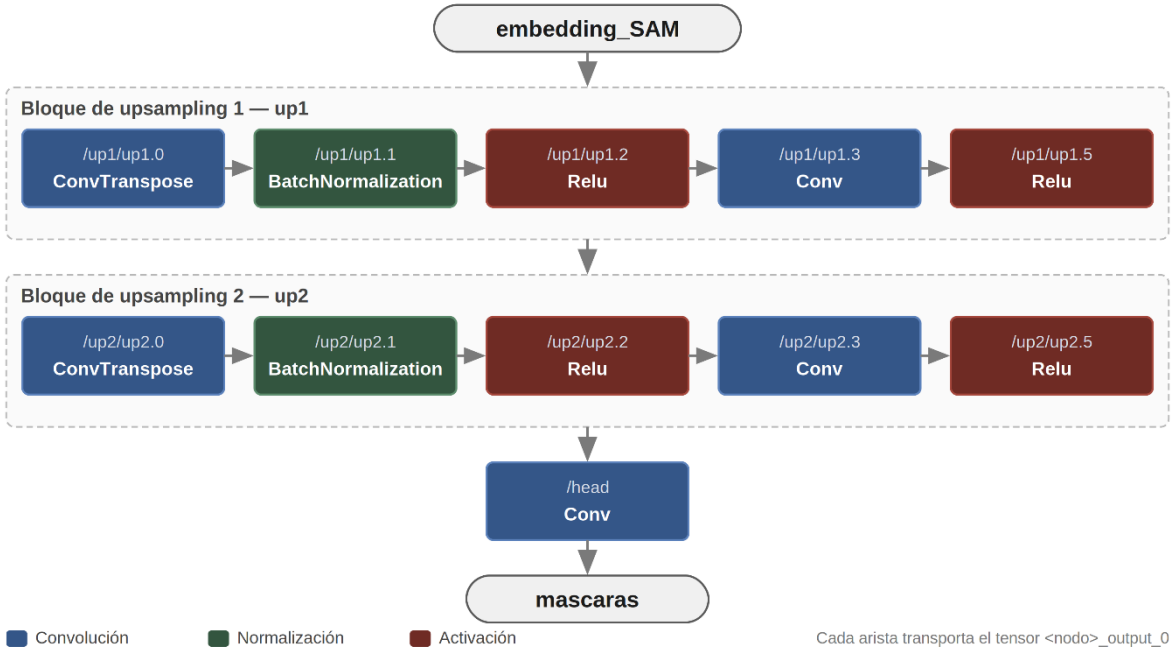
Para adaptar SAM al dominio de la detección de desgaste en roscas se utiliza la técnica LoRA, en concreto adaptan las capas de atención del codificador de la imagen, que son las responsables de decidir qué zonas de la imagen son relevantes en la segmentación. Esta técnica permite mantener congelada la mayor parte de los pesos del modelo base y entrenar únicamente un conjunto reducido de parámetros adicionales, junto con la cabeza de segmentación definida para esta estrategia. De esta forma se reduce considerablemente el coste computacional y el tiempo de entrenamiento.

La Figura 10 representa de forma esquemática la arquitectura del modelo seghead.onnx, ya que el grafo computacional completo del modelo visualizado mediante herramientas como

Netron resulta demasiado extenso para ser mostrado de forma legible en el documento. Esto se debe a que SAM está basado en una arquitectura transformer, compuesta por múltiples bloques de atención, normalización y proyección interna. Por este motivo, en la figura se resumen únicamente los bloques funcionales principales de la estrategia: imagen preparada, codificador SAM ViT-B adaptado mediante LoRA, embeddings, cabeza de segmentación y máscaras finales de cresta y paso.

SegHead o cabeza de segmentación genera dos mapas de salida, uno para la cresta y otra para el paso, posteriormente estos mapas se transformarán en mascaras binarias que se empleara para el cálculo de las métricas geómetras utilizadas para el análisis de detección de desgaste.

Figura 10. Esquema de la arquitectura SAM+LoRA



Fuente: Elaboración propia.

Durante el entrenamiento se utiliza la función de pérdida BCEWithLogitsLoss, esta es. Esta es óptima para comparar las máscaras predichas con las máscaras binarias de referencia creadas manualmente, ya que evalúa píxel a píxel si la predicción del modelo coincide con la máscara manual. El optimizador empleado es AdamW junto con un planificador de aprendizaje CosineAnnealingLR, esta combinación permite que el modelo ajuste sus parámetros de forma progresiva, reduciendo gradualmente la velocidad de aprendizaje para evitar que el modelo

oscile en las últimas épocas de entrenamiento. Solo se actualizan los parámetros de LoRA y los de la cabeza de segmentación, manteniendo congelado el resto del modelo base.

Para la búsqueda de un modelo que se ajuste al uso industrial, se crearon dos modos de entrenamiento: uno manual y otro automático. El modo manual permite entrenar un modelo SAM+LoRA seleccionando directamente una o varias roscas sin desgaste que se usaran para entrenar el modelo. El modo automático, crea distintos modelos a partir de diferentes combinaciones de roscas buenas anotadas, con el objetivo de comparar cuál se ajusta mejor al criterio buscado para un posible entorno industrial.

Tabla 9. Modos de entrenamiento

Modo	Objetivo	Selección de roscas	Evaluación
Manual	Crear modelo con roscas seleccionadas manualmente	Selección manual de una o varias roscas	Resto de roscas sin desgaste no seleccionas y todas las roscas con desgaste
Auto	Crear modelos con mejores métricas	Genera combinación con roscas sin desgaste	Resto de roscas sin desgaste no seleccionas y todas las roscas con desgaste

Fuente: Elaboración propia.

Aunque el dataset de entrenamiento contiene las 11 roscas sin desgaste y con las máscaras manualmente creadas, en un total de 129 imágenes, cada entrenamiento del modelo creado utiliza únicamente la combinación de roscas seleccionada. Es decir, un modelo puede entrenarse con una sola rosca, con dos roscas o con una combinación mayor. Después se evalúa sobre las roscas buenas que no se han usado para entrenar y sobre todas las roscas con desgaste.

El modo automático, la búsqueda se organiza en varias partes. Primero se entrena un modelo independiente por cada rosca sin desgaste anotada. Es decir, cada rosca sin desgaste se utiliza de forma individual como referencia de geometría y se observa cómo se comporta el modelo al evaluar el resto de las roscas sin desgaste y todas las roscas con desgaste. Con esta primera

fase se obtiene qué roscas aportan una segmentación más estable y una mejor separación entre roscas buenas y roscas con desgaste.

A partir de los mejores resultados individuales se generan combinaciones de dos roscas. El objetivo es comprobar si unir varias roscas sin desgaste mejora el desempeño del modelo frente a entrenarlo con una única rosca. En esta evaluación se mantiene el criterio: las roscas utilizadas para entrenar se excluyen de la prueba y el modelo se evalúa sobre el resto de las roscas sin desgaste disponibles y sobre las roscas con desgaste.

Por último, se realiza una expansión progresiva de las mejores combinaciones. En esta fase se añaden nuevas roscas sin desgaste a la combinación siempre que el resultado mejore. Con ello se puede probar configuraciones más completas sin tener que entrenar todas las combinaciones posibles.

Este proceso permite comparar distintas referencias de geometría de una forma ordenada. Además, evita seleccionar el modelo únicamente por una elección manual previa, buscando la combinación optima.

Para la elaboración de esta estrategia se generaron dos tipos de experimentos:

- Experimento manual: en este experimento se decide entrenar el modelo con todas las roscas sin desgaste a excepción de dos. Por lo cual, el modelo se entrena con las roscas RB01 a RB09 y se evalúa su rendimiento con las roscas RB10, RB11 y con las roscas con desgaste RM01 a RM11.
- Experimento automático: en este experimento se genera un total de 32 entrenamientos con combinaciones diferentes, utilizando únicamente roscas sin desgaste para el entrenamiento. Posteriormente, cada modelo se evalúa sobre las roscas buenas no utilizadas en esa combinación y las roscas con desgaste.

4.1.3. Detección de anomalías

Para poder detectar si las imágenes de una rosca contienen anomalías, primero hay que calcular las métricas geométricas de las zonas que el modelo ha segmentado, con ello se

convierte una segmentación visual en valores numéricos que se podrán comparar entre las imágenes analizadas y que determinaran si esta contiene desgaste.

Las métricas creadas tienen como objetivo analizar si la geometría de la rosca mantiene un comportamiento regular en las crestas y los pasos. Por el contrario, cuando una rosca contiene desgaste, se puede observar pérdidas de material, zonas más lisas en los flancos de la cresta o cambios de forma de las crestas o variación del ancho del paso.

No todas las métricas mostradas en la Tabla 10 tienen el mismo peso en la decisión final a la hora de determinar si puede existir desgaste. En esta estrategia la métrica principal es el coeficiente de variación (Ecuación 8), que permite comprobar si las crestas segmentadas tienen tiene áreas similares entre sí o por el contrario existe mucha variación entre ellas. El resto de las métricas calculadas son utilizadas como apoyo del análisis. El área, el ancho y alto permiten analizar si hay cambios de tamaño. La solidez y rectagularidad ayuda a detectar contornos más irregulares o menos compactos. La ratio alto/ancho permite analizar cambios en la proporción de la cresta y la horizontalidad del paso ayuda a comprobar que se mantiene la distancia entre crestas.

Tabla 10. Resumen de métricas geométricas calculadas a partir de las máscaras segmentadas.

Métrica	Clase	Fórmula		Utilidad
Área	Cresta / paso	$A = \sum_{x,y} M(x,y)$	(7)	Mide la superficie segmentada de la región
Ancho	Cresta / paso	$w = X_{max} - X_{min}$	(8)	Analiza la extensión horizontal.
Alto	Cresta / paso	$h = y_{max} - y_{min}$	(9)	Analiza la extensión vertical
Solidez	Cresta	$S = \frac{A}{A_{convexa}}$	(10)	Evalúa compacidad e irregularidades en el contorno
Rectangularidad	Cresta	$R = \frac{A}{w * h}$	(11)	Mide cuánto se aproxima la región a su rectángulo delimitador
Ratio alto/ancho	Cresta	$RA = \frac{h}{w}$	(12)	Compara la proporción de la cresta
Horizontalidad	Paso	$H_{paso} = \frac{\sigma(Y_{top})}{h}$	(13)	Evalúa la variabilidad vertical del borde superior del paso.
Coef. de variación del área	Cresta	$CV = \frac{\sigma(A_i)}{\mu(A_i)}$	(14)	Evalúa la regularidad global de las áreas de la cresta

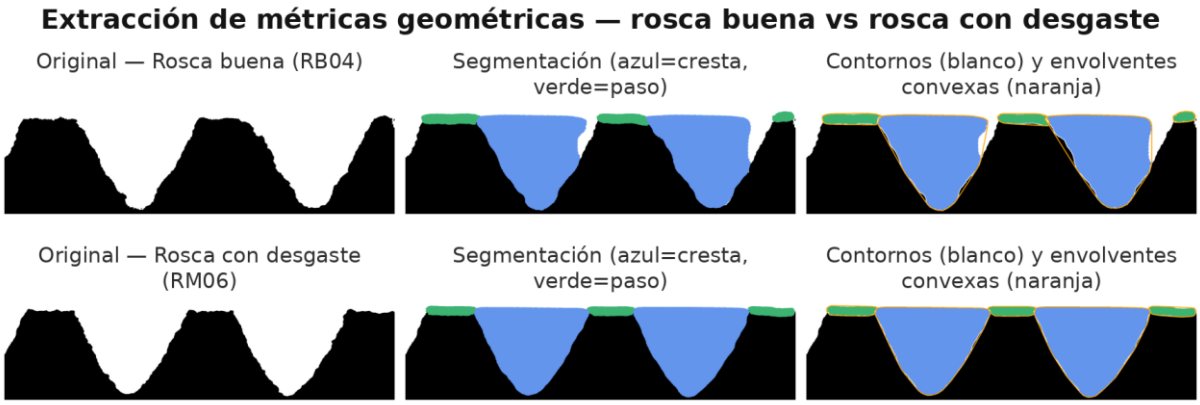
Fuente: Elaboración propia.

Todas estas métricas analizadas permiten visualizar distintos indicios geométricos que pueden estar relacionados con desgaste. Por ejemplo, una reducción del área o del alto de la cresta puede indicar pérdida de material. Una menor solidez puede indicar un contorno más irregular. Así como cambios en la rectagularidad o en la ratio alto/ancho pueden mostrar deformaciones en la forma de la cresta y una mayor variabilidad en la horizontalidad del paso puede indicar que las crestas pueden estar deformadas o con pérdida de material.

En la Figura 11 se puede observar como a partir de la imagen original (preprocesada) se obtiene la segmentación de las regiones de crestas (azul) y pasos (verde) que contiene la imagen. Posteriormente se calcula los contornos y envolventes conexas de las regiones

detectadas, lo que permite calcular métricas como el área, el ancho, la solidez, la rectagularidad y la regularidad del paso.

Figura 11. Extracción de métricas sobre imagen segmentada



Fuente: Elaboración propia.

Respecto al coeficiente de variación del área, un resultado de este coeficiente indica con una variación baja que la geometría analizada es más regular, mientras que una variación alta puede estar indicar que la cresta analizada puede tener pérdida de material, deformaciones o sufre de un desgaste irregular en su superficie. Para calcular el coeficiente de variación del área (Ecuación 8) se divide $\sigma(A_i)$ que es desviación típica del área entre $\mu(A_i)$ que es su valor medio.

Para determinar si la rosca sufre de desgaste se utiliza un umbral fijo sobre el coeficiente de variación de la rosca, donde se considera que puede existir desgaste cuando $CV_{area} > 0{,}025$. Si el valor del CV de la rosca se mantiene por debajo de este umbral la rosca se considera buena o sin desgaste.

Además del diagnóstico basado en el coeficiente de variación, se implementa una segunda capa de validación que compara las métricas de la rosca analizada con los valores del perfil teórico ISO para roscas M10×1,5. Para realizar esta comparación es necesario convertir las medidas de la segmentación de píxeles a milímetros. Para ello se utiliza la distancia entre los pasos segmentados como referencia de calibración, ya que el paso teórico de una rosca M10×1,5 es de 1,5 mm. La calibración se calcula proyectando los centroides de los pasos

detectados sobre el eje principal del tornillo mediante SVD y midiendo la distancia mediana entre pasos consecutivos, lo que permite obtener una escala en píxeles por milímetro para cada imagen.

Una vez calibrada la escala, la segunda capa compara tres métricas promedio de la rosca con sus valores teóricos. La ratio alto/ancho de la cresta se compara con el valor teórico de 3/2 ≈ 0,866. El ángulo de flanco se compara con los 30° teóricos del perfil ISO, para lo cual se estima el ángulo ajustando rectas a los puntos del contorno izquierdo y derecho de cada cresta. Y el alto de cresta en milímetros se compara con el valor teórico de 5H/8 ≈ 0,812 mm, siendo H la altura del triángulo fundamental. Cada métrica tiene definido un umbral de desviación máxima permitida, y en función del número de métricas que lo superen la rosca se clasifica como conforme, desviación leve o desviación significativa.

De esta forma, el diagnóstico final combina dos criterios: la variabilidad interna de la geometría segmentada (Capa 1, basada en el CV) y la desviación respecto al perfil teórico ISO (Capa 2). Si cualquiera de las dos capas indica posible desgaste, la rosca se marca como tal, aplicando un criterio conservador coherente con el uso industrial.

El pipeline que se ejecuta para determinar si una rosca puede contener desgaste en sus imágenes realiza los siguientes pasos: Cada imagen de la rosca a analizar se segmenta, se calculan sus métricas geométricas y se comparar con el umbral definido. Posteriormente, se aplica un criterio conservador, donde si una de las imágenes de una rosca supera el umbral la rosca es marcada como posible desgaste.

4.1.4. Parámetros utilizados en el modelo

Para definir el comportamiento en la estrategia SAM+LoRA, se utilizan los parámetros que se muestran a continuación en la Tabla 11. La configuración utilizada está diseñada para poder hacer un ajuste del modelo SAM sin necesidad de reentrenar el modelo completo y poder utilizar un número limitado de datos para su adaptación con LoRA.

Esta configuración permite al modelo aprender segmentación de objetos o regiones nuevas, como son las crestas y los pasos. Utilizando la segmentación identificada para hacer cálculos

de las métricas geométricas que determinan si una imagen puede contener signos de desgaste o no. Además, se utiliza una referencia geométrica basada en la rosca ISO M10×1,5 como apoyo visual para revisar si la geometría segmentada es coherente con el perfil esperado.

Tabla 11. Parámetros utilizados en SAM+Lora.

Parámetro	Valor
Modelo Base	SAM ViT-B
Tarea a realizar	Segmentación de 2 clases
Técnica de adaptación del modelo	LoRA
Capas adaptadas	Proyecciones (q), (k), (v) del codificador de imagen
Rango LoRA	r=8
Alpha LoRA	Alpha=16
Clases segmentadas	Cresta y paso
Formato de las anotaciones manuales	COCO
Función de pérdida	BCEWithLogitsLoss
Optimizador	AdamW
Scheduler	CosineAnnealingLR
Configuración LoRA	Pesos modelo base congelados. Parámetros LoRA y segHead entranados
Principal métrica	Coeficiente de variación
Otras métricas	Area, Ancho, Alto, Solidez, Rectangularidad, Ratio ancho/alto y Horizontalidad
Referencia	Perfil ISO para roscas M10x1.5
Uso de la referencia	Comparación visual y apoyo al diagnostico

Fuente: Elaboración propia.

4.1.5. Resultados

Partiendo de los modelos generados en los 2 experimentos realizados y descritos en el apartado de entrenamiento, se analizan los resultados obtenidos para la estrategia SAM+LoRA con anotaciones solo con roscas sin desgaste. Para analizar los resultados, se compara el comportamiento de los distintos modos y se eligen los modelos con mejores resultados centrados en su uso en un entorno industrial y no en laboratorio.

Al centrarse en los resultados para entorno industrial no solo se tendrá en cuenta las métricas de desempeño del modelo, sino que también se valora que el modelo tenga un buen desempeño en la detección de roscas que muestran desgastes, siendo más permisivos si el modelo da un falso positivo en una rosca sin desgaste, ya que es preferible que el sistema marque una rosca buena como desgaste para su análisis manual. Los falsos negativos en roscas con desgaste pueden conllevar problemas en entorno industrial, pudiendo parar la cadena de fabricación.

La Tabla 12 muestra los mejores resultados obtenidos durante la búsqueda automática y los resultados del entrenamiento manual.

Tabla 12. Resultados obtenidos en la estrategia SAM+Lora.

Modelo	Roscas train	Buenas Correcta	Desgaste Detectado	Accu.	AUC-ROC	F1	Tiempo (train / inf)
Auto_RB11	1	10/10	2/10	0.57	0.909	0.308	100/26.8s
Auto_RB05_RB09_RB10_RB11	4	7/7	5/11	0.66	0.896	0.625	408/23.1s
Auto_RB09	1	9/10	6/11	0.714	0.873	0.667	108/26.6s
Auto_RB03	1	4/10	10/11	0.66	0.654	0.741	100/28.8
Auto_RB01	1	3/10	11/11	0.66	0.664	0.759	111/27.2s
Manual	9	2/2	4/11		0.364	0.533	962/17.6s

Fuente: Elaboración propia.

Como se puede observar en la Tabla 12, el entrenamiento que mejores métricas tiene es Auto_RB11, este modelo clasifica correctamente todas las roscas sin desgaste y con un valor alto en AUC-ROC (0.909), pero su F1-score de 0.308 indica que detecta 2 de las 11 roscas con desgaste. Esto se debe a que el modelo genera segmentaciones muy regulares incluso en roscas con desgaste, lo que hace que los valores del coeficiente de variación no superen el umbral establecido.

En el extremo opuesto se encuentra Auto_RB01, que detecta las 11 roscas con desgaste, pero solo clasifica correctamente 3 de las 10 roscas sin desgaste, esto indica que el modelo genera

segmentaciones con demasiada variabilidad y no es capaz de distinguir entre roscas buenas y roscas con desgaste.

Los modelos Auto_RB09 y Auto_RB03 tienen un rendimiento global parecido, pero cada uno detecta mejor un tipo de rosca. Auto_RB09 detecta mejor las roscas sin desgaste (9 de 10) y por el contrario Auto_RB03 detecta mejor las roscas que presentan desgaste, clasificando de forma correcta 10 de 11 roscas, aunque solo clasifica bien 4 de 10 roscas sin desgaste. Un dato relevante es que Auto_RB03 obtiene el mayor IoU de paso de todos los modelos individuales (0.769), lo que indica que segmenta con más precisión las regiones entre crestas. Dado que las métricas geométricas se calculan sobre los contornos segmentados, una mejor segmentación del paso reduce el error en el cálculo de las métricas y mejora la capacidad de distinguir entre roscas con y sin desgaste.

La única rosca con desgaste que Auto_RB03 no detecta es RM08, con un coeficiente de variación de 0.0165, muy por debajo del umbral de 0.025. Esta rosca es la más difícil de detectar del dataset, ya que solo 2 de los 11 modelos individuales la clasifican como posible desgaste. Esto sugiere que RM08 presenta un desgaste sutil que no se refleja en la variabilidad geométrica de las crestas segmentadas.

Según las reglas establecidas para entorno industrial, se prioriza el modelo que menos falsos negativos en roscas con desgaste tenga. Tras analizar los resultados, se obtienen estos modelos como los más relevantes:

- Mejor modelo por métrica AUC-ROC: Auto_RB11.
- Modelo conservador: Auto_RB01.
- Mejor modelo según requisitos: Auto_RB03.

Tras estos análisis se selecciona Auto_RB03 como el modelo que más se ajusta a los requisitos establecidos. Aunque no es el mejor modelo en la métrica AUC-ROC, consigue clasificar correctamente 10 de 11 roscas con desgaste y acertar 4 de 10 roscas sin desgaste. Este rendimiento se puede considerar aceptable en entorno industrial ya que tiene una gran capacidad de detección de desgaste, pero tiene que mejorar a la hora de detectar roscas sin desgaste. También se observa que utilizar más roscas para entrenar no mejora necesariamente los resultados, ya que el modelo manual entrenado con 9 roscas (RB01 a

RB09) obtiene el peor AUC-ROC de todos los experimentos (0.364), lo que indica que al combinar muchas geometrías de referencia el modelo pierde capacidad de discriminación.

En la Figura 12 se muestra un resumen del proceso de entrenamiento y validación, puede observarse las métricas obtenidas y así como parte de las clasificaciones que el modelo hizo de las roscas, su clasificación, el coeficiente de variación y si el modelo clasifico correctamente o no. También se puede ver en las curvas de perdida y de IoC que el modelo a mejora la pérdida según pasan las épocas de entrenamiento.

Figura 12. Resumen del entrenamiento y validación del modelo Auto-RB03.

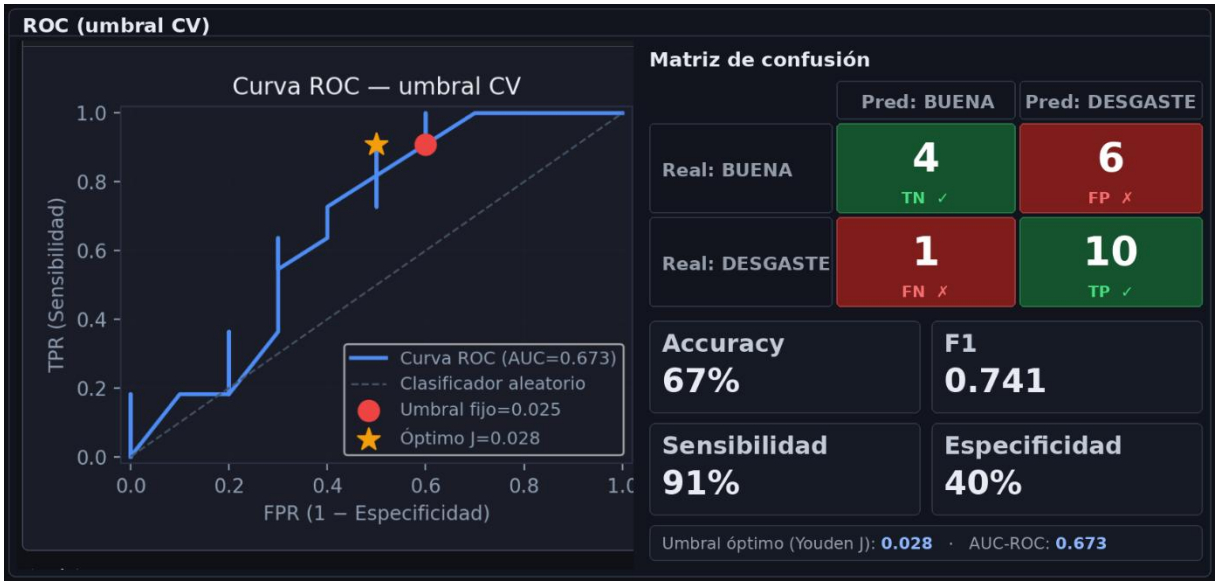


Fuente: Elaboración propia.

La Figura 13 muestra la curva ROC donde se identifica el umbral fijado y el umbral óptimo de Youden J para este entrenamiento (J=0.028). Con el umbral fijo común para todos los

experimentos (0.025) el modelo obtiene 10 verdaderos positivos, 4 verdaderos negativos, 1 falso negativo y 6 falsos positivos como muestra la matriz de confusión de la validación del modelo. El modelo tiene una sensibilidad del 91% es decir que detecta el 9 de cada 10 roscas con desgaste, aunque solo clasifica de forma correcta el 40% de las roscas sin desgaste.

Figura 13. Curva ROC y matriz de confusión del modelo auto_RB03.



Fuente: Elaboración propia.

4.1.6. Interpretabilidad

Esta estrategia tiene una parte importante de interpretabilidad por parte humana en la decisión de si una rosca contiene desgaste o no. SAM+LoRA no se limita a clasificar una rosca con desgaste, el sistema calcula una serie de métricas que presenta mediante una herramienta visual las distintas métricas y representaciones visuales, que permite revisar cual ha sido el motivo de la clasificación y confirmar si existe desgaste en la rosca analizada.

Esto puede ser especial útil en un entorno de industrial, ya que el sistema puede analizar una imagen en aproximadamente 0.11s por imagen, esto significa que si a una rosca se le toma 12 imágenes se analiza el lote de imágenes en 25s. En caso de detectar un posible desgaste el sistema genera una alerta donde el técnico puede realizar una inspección visual de la segmentación, comparando con la norma ISO para roscas M10x1.5, métricas geométricas de

las segmentaciones detectadas, desviación de los valores de referencia y métricas que superan el umbral y mapas visuales de calor para diagnóstico de imágenes.

La Figura 14 muestra un resumen de las métricas utilizadas por el sistema para la clasificación de posible desgaste. Se observa cómo se comparan los valores calculados para la rosca analizada con los umbrales definidos para cada métrica. De esta forma se puede revisar qué variables superan el umbral establecido.

Figura 14. Resumen métricas vs umbral para detectar desgaste.



Fuente: Elaboración propia.

Para mostrar cómo funciona esta herramienta se pueden comparar tres casos del modelo Auto_RB03. La rosca RM09 obtiene un coeficiente de variación de 0.5147 y un score combinado de 3.53, donde la mayoría de las métricas superan sus umbrales, lo que indica un desgaste severo y fácilmente verificable por el técnico. En cambio, la rosca RM07 obtiene un coeficiente de variación de 0.0746 y un score de 0.43, apenas por encima del umbral de 0.025, en este caso el técnico puede revisar qué métricas concretas contribuyen a la alerta y decidir si el desgaste detectado es relevante. El caso opuesto es RM08, con un coeficiente de variación de 0.0165 y un score de 0.08, que el sistema clasifica como buena a pesar de presentar desgaste, lo que muestra que la herramienta de interpretabilidad es útil también cuando el

sistema no detecta el desgaste, ya que un técnico que revise las métricas y las visualizaciones puede identificar indicios que el umbral automático no captura.

En el Anexo I se adjunta el fichero CSV con la comparativa completa de métricas.

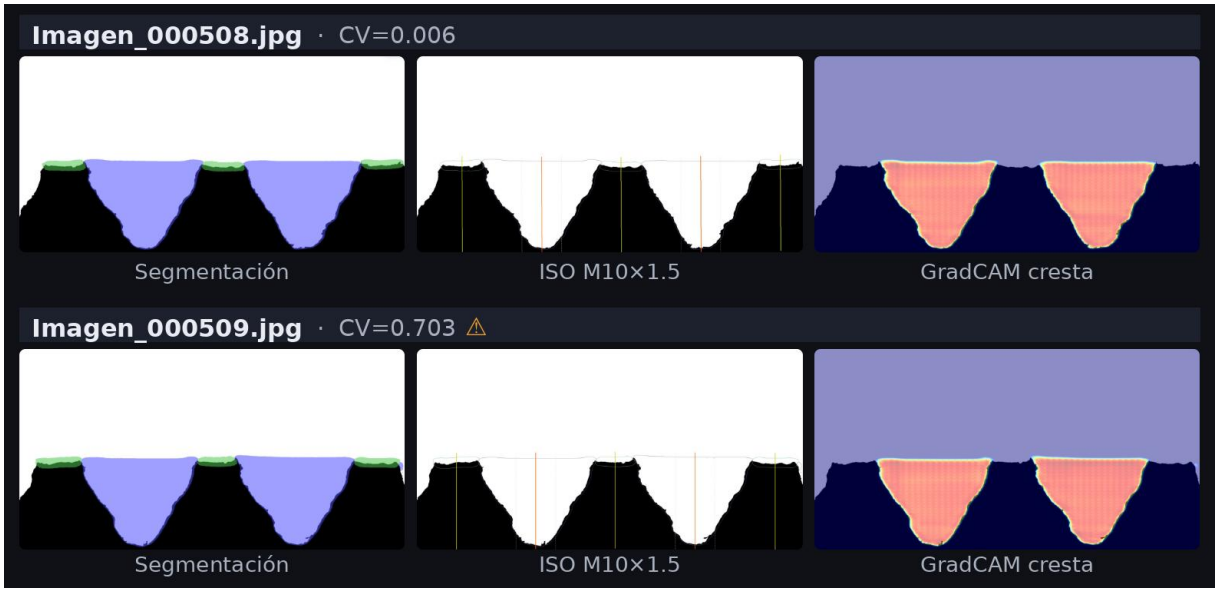
En la Figura 15 se muestra la herramienta de visualización, donde para cada imagen analizada de la rosca se presenta un conjunto de tres imágenes. La primera muestra la segmentación detectada por el modelo, con las crestas y los pasos identificados.

La segunda superpone sobre la imagen el perfil teórico ISO M10×1,5, donde las líneas amarillas indican la posición de los centros de los pasos detectados que se utilizan como referencia de calibración, las líneas naranja indican la posición teórica de las crestas calculada como el punto medio entre pasos consecutivos, y las líneas blancas discontinuas representan el ancho teórico de la cresta (±P/8) cuando la calibración píxel a milímetro está disponible.

Esta visualización permite al técnico comprobar de forma visual si la geometría segmentada se ajusta al perfil esperado o si existen desviaciones que confirmen el diagnóstico del sistema. La tercera es una visualización Grad-CAM de las crestas, un tipo de mapa de calor que permite observar qué zonas de la imagen tienen más peso en el análisis realizado por el modelo. Esto es útil para comprobar de forma manual que el análisis se ha realizado sobre las zonas correctas y que no existe un fallo del sistema o algún artefacto en la imagen que interfiera en la clasificación.

Para generar el mapa Grad-CAM se utiliza la segunda capa de upsampling de la cabeza de segmentación (SegHead), ya que es la última capa antes de la clasificación final y conserva suficiente resolución espacial para localizar las zonas relevantes. Los gradientes se calculan únicamente sobre la cabeza de segmentación, sin propagar al encoder base, de forma que el mapa refleje la contribución de las capas entrenadas específicamente para la segmentación de crestas y pasos. El mapa final se genera ponderando las activaciones de esa capa por la importancia de cada canal, conservando únicamente las contribuciones positivas. El resultado es un mapa de calor normalizado del mismo tamaño que la imagen original, donde las zonas con mayor intensidad indican las regiones que más influyen en la segmentación de las crestas.

Figura 15. Segmentación, ISO y Grad-CAM por imagen analizada.



Fuente: Elaboración propia.

4.1.7. Limitaciones

La estrategia SAM+LoRA, bajo las condiciones de estudio realizadas en este trabajo presentan varias limitaciones que deben ser consideradas antes de plantearse su uso en un entorno industrial.

La primera limitación es el proceso de anotación de imágenes de forma manual de las imágenes. Como se pudo ver en puntos anteriores, para poder entrenar un modelo es necesario crear las máscaras en cada una de las imágenes de las regiones de cresta y paso. Este proceso conlleva mucho tiempo, ya que etiquetar todas las regiones de una rosca de la que se toman 12 imágenes puede tardar de media unos 40 minutos. Otro aspecto que hay que considerar es que se necesita personal experto a la hora de crear las máscaras, ya que una segmentación incorrecta puede trasladar errores de cálculo de métricas geométricas.

Otra limitación importante es el tamaño del conjunto de datos utilizado para entrenar y evaluar el modelo. Con el conjunto disponible para este trabajo, los resultados obtenidos no serían suficientes para usarse un entorno industrial. El mejor modelo obtenido tiene una alta sensibilidad etiquetando roscas con desgaste, pero tiene una baja especificidad generando muchas falsas alertas al clasificar con posible desgaste roscas sin desgaste.

Para imaginar el impacto de esta baja especificidad en un entorno industrial, se analizan 50 roscas y el sistema tarda aproximadamente 25 segundos en analizar cada rosca y esta tiene 12 imágenes, el análisis automático completo se puede realizar en unos 21 minutos. Con una especificidad del 40%, el sistema generaría alertas de posible desgaste en 30 de las 50 roscas, esto significa que, si la mayoría de las roscas analizadas son roscas sin desgaste, la mayor parte de las alertas serían falsas alarmas que el técnico tendría que revisar de forma manual. Aunque la herramienta de interpretabilidad facilita esta revisión, un volumen alto de falsas alertas puede provocar que el técnico ignore las alertas del sistema, lo que reduciría su eficacia como herramienta de apoyo a la inspección.

Por último, existe una limitación importante, este tipo de estrategia requiere una capacidad de cómputo elevada. Para poder llevarla a cabo con tiempos de entrenamiento y de inferencia aceptables, fue necesario entrenarlo en GPU, concretamente con una NVIDIA RTX 4090. Esto implica que, para el entrenamiento se debe tener un equipo de altas prestaciones, en cambio para la inferencia no hace falta estas prestaciones pudiendo ejecutarse sobre CPU, aunque esto penalizaría el tiempo de análisis por imagen.

Como trabajos futuros, sería conveniente probar con un conjunto mayor de roscas y con distinto tipo de imágenes. También se puede considerar probar la autosegmentación con supervisión manual, esto puede reducir el tiempo de anotación manual de forma considerable. Otra línea de investigación sería probar con nuevas métricas y cambios dinámicos de umbral, con el objetivo de reducir las falsas alertas sin aumentar el número de imágenes de rosca del dataset.

En definitiva, la estrategia SAM+Lora demuestra que es viable la identificación de roscas con desgaste utilizando enfoques few-shot con pocos datos para entrenar el modelo. Además, esta estrategia aporta a la detección la segmentación visual de la imagen, el cálculo de métricas geométricas y herramientas visuales para la inspección manual de la alerta.

4.2.CLASIFICACIÓN MEDIANTE MULTIPLE INSTANCE LEARNING Y ANÁLISIS DEL PERFIL ISO

4.2.1. La idea en una frase y su uso industrial

A cada pieza le corresponden once imágenes y una sola etiqueta (conforme o desgastada). El modelo aprende a juzgar el conjunto sin que se le diga qué imagen concreta muestra el defecto, y le basta con que se detecte desgaste en una de las once para marcar la rosca entera. Es la forma en que un operario decide: la pieza se acepta o se rechaza como un todo.

El primer enfoque plantea el problema como Multiple Instance Learning (MIL): cada pieza está compuesta por las once imágenes que la representan y tiene una única etiqueta binaria, y el modelo aprende a clasificar el conjunto sin supervisión individual sobre cada imagen. El clasificador es EfficientNet-B0, una red neuronal convolucional preentrenada en ImageNet y adaptada al dominio mediante fine-tuning en dos fases. Los once scores de imagen se combinan en el score de rosca mediante max-pooling, es decir, el score de la rosca es el máximo de los once. Esta elección es semánticamente correcta: si cualquiera de las once imágenes muestra evidencia clara de desgaste, la pieza debe clasificarse como desgastada.

4.2.2. Datos y etiquetado

La estrategia opera sobre el dataset común descrito en el capítulo 3: 22 herramientas, con once imágenes cada una, etiquetadas a nivel de rosca. En la formulación MIL, cada rosca es un conjunto (las once imágenes) con una única etiqueta binaria, y el modelo no recibe ninguna indicación sobre qué imagen concreta contiene el desgaste. Las imágenes entran al modelo a resolución 384×512 píxeles en escala de grises, replicadas en tres canales para ser compatibles con los pesos preentrenados en ImageNet, y se normalizan con los estadísticos de ImageNet (media [0.485, 0.456, 0.406] y desviación típica [0.229, 0.224, 0.225] por canal).

4.2.3. Cómo se entrena

El modelo mira las once imágenes de una pieza, da a cada una nota de "sospecha de desgaste" y se queda con la nota más alta como veredicto de la rosca. Se entrena en dos tandas: primero ajusta solo la última capa, sin tocar el grueso de la red, y después afina con cuidado las capas finales para no estropear lo que ya sabía.

EfficientNet-B0 está diseñada mediante escalado compuesto, que ajusta a la vez la profundidad, la anchura y la resolución de entrada de la red. Utiliza bloques MBConv (Mobile Inverted Bottleneck Convolution) con squeeze-and-excitation, que aprenden a ponderar de forma adaptativa los canales de características, y produce un vector de características de dimensión 1280 antes del clasificador. Sobre este backbone se añade un cabezal de clasificación formado por una capa de dropout (p=0,5) y una capa lineal de 1280 a 1 con activación sigmoide, cuya salida es un escalar en [0,1] que representa la probabilidad de desgaste de una imagen individual.

La agregación MIL se implementa con max-pooling a nivel de rosca. Para cada rosca de entrenamiento se procesan sus once imágenes en un único paso hacia delante, lo que produce once scores; el score de la pieza es el máximo de esos valores, y la función de pérdida Binary Cross-Entropy se aplica entre ese máximo y la etiqueta binaria de la rosca. La formulación tiene una lectura directa: si cualquiera de las once imágenes muestra evidencia de desgaste, con un score alto, la rosca se clasifica como desgastada.

$$L = -\left[y \cdot \log(\max_i s_i) + (1-y) \cdot \log(1-\max_i s_i)\right] \qquad (15)$$

El entrenamiento se organiza en dos fases para no deteriorar los pesos preentrenados durante la adaptación al dominio. En la primera fase, de 10 épocas, el backbone se congela por completo y solo se entrena el cabezal de clasificación con el optimizador Adam (lr=1×10^{-3}, weight_decay=1×10^{-4}), lo que permite que el cabezal aprenda una proyección útil sobre las características preentrenadas sin perturbar la red. En la segunda fase, de 20 épocas, se descongelan los dos últimos bloques MBConv y se afina con una tasa de aprendizaje diez veces menor (lr=1×10^{-4}, weight_decay=1×10^{-4}) y recorte de gradientes a 1,0 para estabilizar el proceso. Cada paso de entrenamiento procesa una pieza completa, con sus once imágenes,

de modo que cada actualización de pesos agrega información de once secciones distintas de la misma pieza.

4.2.4. Cómo decide conforme/desgastada

La decisión a nivel de rosca se toma con el criterio de max-pooling descrito: el score de la pieza es el máximo de los once scores de imagen, y se compara con el umbral óptimo de 0,081. Por debajo de ese valor la rosca se considera conforme y por encima, desgastada.

4.2.5. Parámetros del modelo

Tabla 13. Parametrización de la estrategia MIL + EfficientNet-B0.

Parámetro	Valor	Qué controla
Backbone	EfficientNet-B0 (ImageNet)	Red base que extrae características
Resolución de entrada	384×512 px, escala de grises a 3 canales	Tamaño de imagen que procesa
Cabezal	Dropout 0,5 + lineal 1280→1 + sigmoide	Convierte características en probabilidad de desgaste
Función de pérdida	Binary Cross-Entropy sobre el score máximo	Ajusta el veredicto a la etiqueta de la rosca
Fase 1	10 épocas, solo cabezal, Adam $lr=1\times10^{-3}$	Aprende sobre las características congeladas
Fase 2	20 épocas, últimos 2 bloques MBConv, Adam $lr=1\times10^{-4}$	Afina sin sobrescribir lo preentrenado
Agregación por rosca	MAX-POOL (máximo de 11 scores)	Combina las imágenes en un veredicto
Umbral de decisión	0,081	Frontera conforme/desgastada

4.2.6. Resultados

El enfoque MIL + EfficientNet-B0 obtiene AUC-ROC = 1,0000, AUPRC = 1,0000 y F1 óptimo = 1,0000 sobre los 24 folds de la validación LOO-CV, con un umbral óptimo de 0,081. Los scores de las herramientas conformes se concentran en el rango 0,001–0,013, con muy baja varianza, mientras que las desgastadas producen scores entre 0,081 y 1,000. Dos herramientas desgastadas presentan scores relativamente bajos (000501_1 = 0,081 y 000511_1 = 0,331), probablemente por desgaste leve o por una calidad de imagen inferior, pero ambas quedan por encima del umbral y se clasifican correctamente. A nivel de pieza, esto equivale a clasificar correctamente las 12 roscas conformes y las 12 desgastadas (24 de 24), sin ningún falso positivo ni falso negativo sobre el conjunto de evaluación. La Tabla 14, la Tabla 15 y la Tabla 16 recogen estos resultados.

Tabla 14. Resultado del modelo MIL + EfficientNet-B0 (LOO-CV, 24 folds)

Métrica / parámetro	Valor
AUC-ROC	1,0000
AUPRC	1,0000
F1 óptimo	1,0000
Umbral óptimo	0,081
Folds LOO-CV	24

Tabla 15. Distribución de scores por clase

Clase	Rango de scores	Observaciones
Rosca conforme	0,001 – 0,013	Alta confianza; todos por debajo del umbral
Rosca desgastada	0,081 – 1,000	Todos por encima del umbral; clasificación correcta

Tabla 16. Casos límite en herramientas desgastadas

ID de la rosca	Score	Estado	Clasificación
000501_1	0,081	Score bajo (desgaste leve o baja calidad de imagen)	Correcta
000511_1	0,331	Score moderado (desgaste leve o baja calidad de imagen)	Correcta

Conviene leer estos resultados con cautela por el riesgo de sobreajuste: con solo 22 muestras, un F1 de 1,0 podría indicar que el modelo ha capturado características muy específicas del conjunto de evaluación. Validar el modelo sobre las 36 imágenes de estado intermedio o sobre herramientas nuevas es necesario para confirmar su capacidad de generalización.

4.2.7. Interpretabilidad

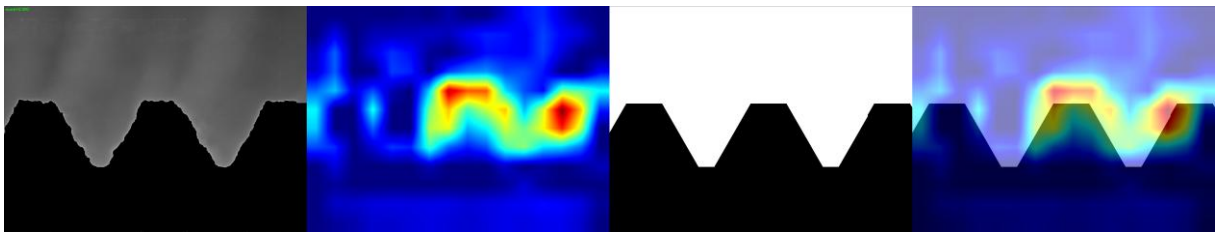
Para interpretar el modelo se ha empleado GradCAM++, una generalización de Grad-CAM que pondera los gradientes teniendo en cuenta la curvatura de segundo orden de la función de activación.

$$\alpha_k^c = \frac{\partial^2 y^c \;/\; \partial (A_k^{ij})^2}{2 \cdot \partial^2 y^c / \partial (A_k^{ij})^2 + \sum_{ab} A_k^{ab} \cdot \partial^3 y^c / \partial (A_k^{ij})^3} \qquad (16)$$

Esta formulación es más robusta que Grad-CAM cuando hay varias regiones discriminativas en la imagen, como ocurre con varias zonas desgastadas en distintas posiciones del diente, una situación habitual en este dataset. La alternativa de implementar manualmente los gradientes sobre EfficientNet-B0 se descartó por su incompatibilidad con la función de activación SiLU de los bloques MBConv, que al no ser lineal a trozos exige un tratamiento diferencial más cuidadoso. El mapa se genera sobre la última capa convolucional del backbone y se redimensiona a la resolución completa de la región de interés (384×512) para la visualización. Para no penalizar la evaluación, los gradientes solo se calculan cuando se solicita la visualización; el resto de la evaluación LOO-CV se ejecuta sin ese coste. Tal y como se

muestra en la Figura 16 la interpretabilidad permite verificar que la activación se concentra en los flancos y las cimas de los dientes, que son las zonas donde el desgaste produce los cambios visuales más marcados.

Figura 16. Mapa de calor de la imagen 000501 de la rosca conforme 5 (RB05)



4.2.8. Comparación con el baseline geométrico: perfil ISO directo

Como contraste, se ha evaluado un método de comparación geométrica pura que no requiere ningún entrenamiento. Su hipótesis es que el desgaste se manifiesta como una deformación macroscópica del perfil de la rosca (redondeo de cimas, relleno de valles y pérdida del ángulo de flanco de 60°), detectable comparando el perfil binario real con el perfil ISO teórico.

El procedimiento toma como perfil real la máscara binaria de Otsu de la separación rosca-fondo (cap. 3), genera y registra la máscara ISO ideal (cap. 3) y cuantifica la discrepancia entre ambos mediante la ratio XOR normalizada por el área del perfil ideal: un valor de 0,0 indica coincidencia perfecta y los valores mayores, desviación creciente. El score de rosca es la media de los once scores de imagen; se usa la media, y no el máximo del enfoque MIL, porque el desgaste geométrico, cuando existe, se distribuye a lo largo de toda la pieza y todas las secciones son igualmente informativas.

$$score_{imagen} = \frac{|tool_mask \oplus registered_ideal|}{|registered_ideal|} \qquad (17)$$

Al no haber entrenamiento, el modelo almacenado es solo el diccionario de parámetros geométricos de la configuración (paso, altura de diente, anchos de cima y valle, factor de escala), de modo que el enfoque es aplicable a cualquier geometría de rosca ISO con solo cambiar esos parámetros.

La comparación directa de perfil ISO obtiene AUC-ROC = 0,6875, AUPRC = 0,6178 y F1 óptimo = 0,7742, con umbral óptimo 0,0280 sobre los 24 folds LOO-CV. Ese umbral se sitúa en el extremo inferior del rango de scores observado, lo que indica que la mayoría de las herramientas sea cual sea su estado, producen un score superior; con el umbral por defecto de 0,5 el F1 cae a 0,0, porque ninguna rosca alcanza ese nivel de desviación, lo que subraya la necesidad de calibrar el umbral con los datos. El AUC-ROC de 0,6875, por encima del 0,5 de la clasificación aleatoria, confirma que la desviación geométrica contiene señal discriminante, aunque débil. La diferencia respecto a MIL + EfficientNet-B0 (AUC-ROC = 1,0000) cuantifica la información adicional que aportan las representaciones texturales aprendidas, ausentes en el perfil binario. Los scores quedan muy comprimidos (entre 0,025 y 0,109 para las 22 herramientas) porque el registro alinea bien la máscara ideal tanto en herramientas conformes como desgastadas, y la silueta binaria de una rosca desgastada puede ser casi idéntica a la de una conforme cuando el desgaste no ha producido todavía una deformación macroscópica. Este resultado tiene valor diagnóstico: fija el techo de los enfoques puramente geométricos y justifica la necesidad de los basados en aprendizaje, porque en este dataset la señal predominante del desgaste es la textura superficial y no la deformación del perfil.

4.2.9. Limitaciones

La principal salvedad del enfoque MIL es el riesgo de sobreajuste asociado al tamaño del dataset: 22 herramientas son muy pocas para afirmar que la separación perfecta se mantendrá en producción, por lo que la validación sobre estados intermedios y herramientas nuevas es prioritaria. El baseline geométrico, por su parte, queda limitado por la naturaleza del desgaste en este dominio, que apenas deforma el perfil binario, y sirve sobre todo como referencia del techo que alcanza un método sin aprendizaje.

4.3.ARQUITECTURA U-NET CON ENCODER EFFICIENTNET-B0

4.3.1. La idea en una frase y su uso industrial

Como no se dispone de dibujos manuales del desgaste, este modelo aprende a redibujar cómo debería ser una rosca perfecta a partir de las imágenes de herramientas en buen estado. Cuando recibe una pieza nueva, compara lo que el modelo "esperaría" con lo que ve: cuanto más se

separan, más sospecha de desgaste. Su ventaja es que no necesita ejemplos de piezas defectuosas.

La ausencia de máscaras de segmentación anotadas manualmente impide el entrenamiento supervisado convencional de una red de segmentación. Este enfoque lo resuelve combinando una U-Net con máscaras sintéticas generadas a partir del perfil ISO teórico, sin necesidad de anotación manual. La U-Net se entrena solo con imágenes de herramientas conformes, usando las máscaras ISO sintéticas como referencia. El objetivo no es segmentar la zona desgastada, que no se conoce, sino aprender a reproducir el perfil geométrico teórico a partir de imágenes en buen estado; durante la inferencia, la desviación entre la máscara predicha y la máscara ideal registrada mide cuánto se aleja la rosca de la geometría normal aprendida.

4.3.2. Datos y etiquetado

El conjunto de entrenamiento se construye solo con las imágenes de roscas conformes del fold activo, y su tamaño varía según el tipo de fold: cuando la rosca excluida es desgastada, las doce piezas conformes completas aportan 130 imágenes; cuando la excluida es conforme, las once restantes aportan 119 (121 únicamente en el caso de excluir la herramienta 000512_0, que dispone de 9 imágenes en lugar de las 11 habituales). Para cada imagen conforme se genera la máscara ideal ISO correspondiente, mediante la detección automática de frontera y el registro descritos en el capítulo 3, que actúa como referencia de la segmentación.

4.3.3. Cómo se entrena

El modelo solo ve roscas buenas y aprende a dibujar su forma teórica. No se le enseña ninguna rosca gastada: lo que sabrá hacer es reconocer cuándo algo no encaja con la forma normal que ha aprendido.

La arquitectura es una U-Net con encoder EfficientNet-B0 preentrenado en ImageNet, con la estructura codificador-decodificador simétrica y conexiones de salto característica de la U-Net. El codificador extrae representaciones jerárquicas a distintas resoluciones, reduciendo progresivamente la resolución espacial mientras aumenta la dimensionalidad de los mapas de características, de modo que capta texturas de bajo nivel en las primeras capas y estructuras

geométricas globales en las más profundas. El decodificador reconstruye la resolución original mediante bloques de upsampling bilineal y convoluciones, y en cada nivel concatena sus características con las del encoder a través de las conexiones de salto, lo que preserva la información espacial de alta resolución necesaria para producir máscaras precisas a nivel de píxel. La capa de salida es una convolución 1×1 con activación sigmoide que genera un mapa de probabilidad en [0,1]. La entrada es monocromática, se redimensiona a 384×512 píxeles y se normaliza con media y desviación típica 0,5, lo que lleva el rango de los tensores de [0,1] a [−1,1].

La función de pérdida es la Binary Cross-Entropy estándar, que penaliza por igual la predicción incorrecta de los píxeles de material y de valle.

$$L_{BCE} = -\sum[y_i \cdot \log(p_i) + (1 - y_i) \cdot \log(1 - p_i)] \quad (18)$$

El optimizador es Adam con lr=1×10⁻³ y un planificador de tasa de aprendizaje de tipo CosineAnnealingLR (con lr mínimo de 1×10⁻⁵), con tamaño de lote 2 y 10 épocas de entrenamiento.

4.3.4. Cómo decide conforme/desgastada

Una vez obtenida la máscara segmentada por la U-Net, binarizada con umbral 0,5, el score de desgaste de cada imagen se calcula como la ratio de desviación respecto a la máscara ideal registrada, normalizada por el área de esa máscara ideal.

$$score_{imagen} = \frac{|pred_mask \oplus ideal_mask|}{|ideal_mask|} \quad (19)$$

El score de rosca es el máximo de los once scores de imagen. Esta agregación por máximo es semánticamente adecuada: si cualquiera de las once imágenes muestra desviación geométrica respecto al perfil normal aprendido, la pieza debe clasificarse como potencialmente desgastada. El umbral de decisión se fija en 0,017.

4.3.5. Parámetros del modelo

Tabla 17. Parametrización de la estrategia U-Net + ISO

Parámetro	Valor	Qué controla
Arquitectura	U-Net con encoder EfficientNet-B0 (ImageNet)	Segmentador codificador-decodificador con skip connections
Entrada	1 canal, 384×512 px, normalización 0,5/0,5 a [−1,1]	Imagen que procesa
Capa de salida	Convolución 1×1 + sigmoide	Mapa de probabilidad de material por píxel
Datos de entrenamiento	Solo herramientas conformes; máscara ISO como referencia	Define qué aprende (la geometría normal)
Función de pérdida	Binary Cross-Entropy	Compara la máscara predicha con la ideal
Optimizador	Adam lr=1×10^{-3}, CosineAnnealingLR, lote 2, 10 épocas	Cómo se ajustan los pesos
Score de imagen	Ratio XOR de desviación frente a la máscara ideal	Mide el alejamiento de la geometría normal
Agregación / umbral	MAX-POOL / 0,017	Combina las imágenes y fija la frontera

4.3.6. Resultados

La U-Net con máscaras ISO obtiene AUC-ROC = 0,8056, AUPRC = 0,6904 y F1 óptimo = 0,8462, con umbral óptimo 0,0279. Los scores quedan comprimidos y con solapamiento entre clases:

los de roscas conformes oscilan entre 0,0148 y 0,2312, y los de desgastadas entre 0,0246 y 0,1420. De las 24 piezas evaluadas, el modelo falla en 4: tres falsos positivos (000501_0 (0,1847), 000503_0 (0,0289) y 000512_0 (0,2312, el score más alto de todo el dataset, por encima de cualquier pieza desgastada)) y un falso negativo, 000504_1 (0,0246, por debajo del umbral pese a tratarse de una herramienta desgastada). El umbral óptimo de 0,0279 se sitúa muy cerca del rango de scores de ambas clases, lo que hace este enfoque especialmente sensible a las variaciones de calibración entre sesiones. La Tabla 18 y la

Tabla 19 recogen estos resultados.

Tabla 18. Resultados del modelo U-Net (agregación por máximo, LOO-CV)

Métrica / parámetro	Valor
AUC-ROC	0,8056
AUPRC	0,6904
F1 óptimo	0,8462
Umbral óptimo	0,0279

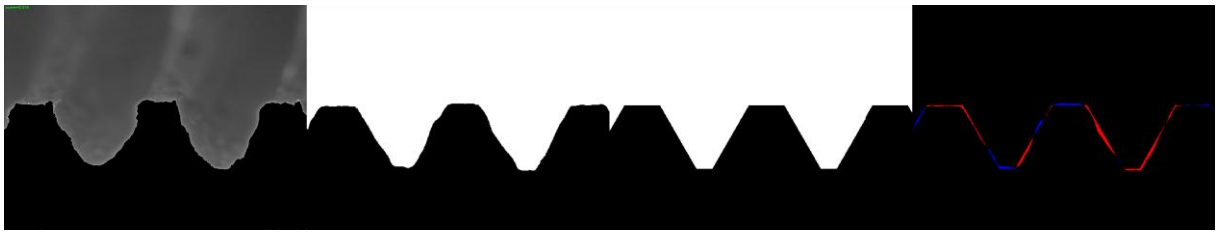
Tabla 19. Caso anómalo detectado

ID de rosca	Clase real	Score obtenido	Predicción	Observación
000512_0	Conforme	0,2312	Desgastada (FP)	Score más alto del dataset; supera a todas las desgastadas
000501_0	Conforme	0,1847	Desgastada (FP)	Segundo score más alto entre las conformes
000503_0	Conforme	0,0289	Desgastada (FP)	Roza el umbral por muy poco margen
000504_1	Desgastada	0,0246	Conforme (FN)	Único falso negativo; por debajo del umbral pese al desgaste

4.3.7. Interpretabilidad

La desviación entre la máscara predicha y la ideal se visualiza con una codificación bicolor que distingue los dos modos de discrepancia geométrica: el rojo indica que la máscara predicha marca material donde la ideal indica vacío, es decir, desgaste que rellena el valle, y el azul indica que marca vacía donde la ideal indica material, esto es, desgaste que erosiona el diente. Como se puede observar en la Figura 17 permite ver de un vistazo no solo cuánto se desvía la rosca, sino de qué forma lo hace.

Figura 17. Desviación entre la máscara predicha y la ideal de la rosca desgastada 07 (RM07)



4.3.8. Limitaciones

El perfil de rosca presenta un desequilibrio de clases inherente: alrededor del 85 % de los píxeles de la región de interés corresponden a material y solo el 15 % a los valles vacíos. Con la Binary Cross-Entropy estándar, el modelo aprende que predecir siempre material, una máscara casi completamente blanca, ya produce una pérdida baja sin necesidad de segmentar bien los valles, lo que hace que la U-Net genere máscaras con muy poca varianza entre imágenes y comprima el rango del score de desviación. Por eso el umbral óptimo queda casi al nivel del ruido, lo que vuelve frágil el enfoque ante cambios de calibración, y aparece además el caso atípico de la pieza conforme 000512_0 con el score más alto del dataset. Como mejora prioritaria se ha identificado sustituir la función de pérdida por una combinación Dice + BCE, que penaliza de forma proporcional al tamaño de cada clase y debería aumentar la separabilidad de los scores; la revisión de la arquitectura y la normalización, y la inspección visual del caso atípico, completan el trabajo pendiente.

Un análisis visual adicional de las máscaras predichas revela que la discrepancia entre la máscara segmentada y el contorno real de la rosca no es uniforme: en la mayor parte del perfil ambos contornos coinciden con precisión, pero se observan desalineaciones localizadas en los dientes parcialmente cortados en los bordes del ROI, además de manchas aisladas de píxeles sin relación con la geometría de la rosca. La causa más probable es el redimensionado del ROI (de aproximadamente 2088×1552 px a 384×512 px, un factor de reducción de ~4x) antes de la inferencia, que pierde precisión de borde justo donde el contraste diente/fondo es más ambiguo tras el reescalado. Este efecto es un contribuyente plausible adicional al ruido y la compresión de los scores, junto al sesgo hacia la clase mayoritaria ya identificado.

La Tabla 20 resume estas limitaciones.

Tabla 20. Limitaciones identificadas y trabajo pendiente

Problema	Descripción	Solución propuesta
Umbral óptimo cercano al ruido	El umbral 0,017 es casi indistinguible del ruido de fondo	Revisar arquitectura y normalización
Sesgo hacia la clase mayoritaria	El modelo tiende a predecir siempre material	Función de pérdida Dice + BCE
Caso atípico en clase conforme	La rosca 000512_0 produce un score anómalamente alto	Inspección visual y revisión del preprocesado
Artefactos de segmentación en los bordes del ROI	El redimensionado a 384×512 px introduce imprecisión en los dientes parciales/cortados en los extremos del recorte	Aumentar la resolución de entrada del modelo, o recortar el ROI evitando dientes parciales en los bordes

4.4. PATCHCORE

4.4.1. La idea en una frase y su uso industrial

PatchCore aprende cómo es una rosca en buen estado observando solo ejemplos correctos, y guarda en memoria ese aspecto normal. Cuando llega una pieza nueva, mide cuánto se aleja de lo que ha aprendido: si la diferencia sobrepasa el umbral establecido, la marca como sospechosa de desgaste. Al no necesitar ejemplos de piezas defectuosas, encaja con una fábrica real, donde casi todo lo que se produce es correcto y reunir defectos variados es difícil.

PatchCore pertenece a la familia de detectores one-class, construye un modelo de lo que es una rosca normal a partir de ejemplos conformes y señalan como anomalía cualquier desviación significativa respecto a ese patrón. Su ventaja es que no requiere ejemplos de desgaste para funcionar. Esto resuelve dos limitaciones del dataset descritas en el capítulo 3

(la escasez de muestras defectuosas y la heterogeneidad entre tipos de defecto), escenarios en los que un clasificador supervisado clásico tendería a sobreajuste.

El objetivo es identificar herramientas defectuosas a partir de imágenes ópticas, combinando un detector de anomalías profundas con un módulo de cuantificación física en unidades reales (mm^2 y µm), de forma que la decisión conforme/desgastada sea trazable y verificable. La arquitectura encadena tres componentes. Un preprocesado clásico, basado en un filtrado paso-alto rápido, realza primero el filo de la rosca. Sobre esa imagen ya tratada actúa el detector PatchCore, construido con el backbone Wide-ResNet50_2, que aprende el aspecto de una rosca normal y marca como anomalía cualquier desviación. Como complemento, un perfilómetro óptico compara el perfil real con el perfil ISO teórico y devuelve cinco magnitudes geométricas interpretables. Conviene precisar que este perfilómetro no decide: no es un clasificador alternativo, sino un apoyo de cuantificación física que aporta interpretabilidad metrológica al sistema (ver 4.4.7).

El sistema se ha desarrollado de manera reproducible y registra de forma automática los tiempos, los parámetros y el consumo de memoria de cada ejecución. Para facilitar el trabajo experimental se ha añadido, además, una aplicación web ligera con la que pueden lanzarse los experimentos y consultarse de forma interactiva la cuantificación conforme/desgastada/ISO.

4.4.2. Datos y etiquetado

La experimentación se ha realizado sobre el dataset común descrito en el capítulo 3: 22 herramientas etiquetadas a nivel de rosca por personal experto, 11 conformes y 11 con desgaste. De cada rosca se han capturado 11 imágenes que recorren secciones consecutivas de la rosca (porciones que, unidas, recomponen la rosca completa), con el eje alineado horizontalmente con la cámara. El conjunto total asciende a 262 imágenes: 130 etiquetadas como conformes y 132 como desgastadas.

El etiquetado a nivel de rosca, y no de sección, es una decisión deliberada que refleja el contexto industrial real: en una línea de producción el operario marca la pieza como conforme o no conforme, pero no segmenta zonas concretas dentro de cada imagen. Esta convención tiene una consecuencia importante para el análisis. Como el desgaste se localiza en secciones

concretas del filo, muchas de las imágenes de una pieza desgastada caen sobre zonas todavía en buen estado y resultan indistinguibles de las de una rosca conforme.

Cada rosca se fotografía por secciones, y el desgaste suele estar solo en algunas de ellas. Por eso muchas imágenes de una pieza con desgaste parecen correctas: el límite no está en el modelo, sino en que el defecto es local y no aparece en todas las secciones.

El análisis exploratorio inicial confirma este efecto: solo 17 de las 132 imágenes desgastadas (12,9%) resultan separables en el espacio de características básicas, mientras que el 87,1% restante es estadísticamente equivalente a una imagen conforme. Esta característica se ha tenido en cuenta en dos puntos del sistema: en la agregación a nivel de rosca (4.4.4) y en una métrica complementaria de diagnóstico, el AUC sobre el subconjunto detectable (4.4.6).

4.4.3. Cómo se entrena

El modelo revisa 130 imágenes de herramientas en buen estado y guarda en una memoria pequeña los trozos de imagen más representativos de una rosca normal. No ajusta parámetros por prueba y error como una red neuronal habitual: prepara un catálogo de cómo se ve lo correcto. Por eso entrena en menos de un minuto y en un ordenador corriente, sin tarjeta gráfica.

Antes de entrar al detector, cada imagen pasa por dos etapas compartidas con el resto de las estrategias y descritas en el capítulo 3: la segmentación que aísla la rosca del fondo y el preprocesado de realce del filo (filtrado paso-alto rápido, BLMD_V10, seleccionado experimentalmente en 4.4.6).

La segmentación aísla la rosca del fondo antes de que el detector y el perfilómetro procesen los píxeles. Así se garantiza que las decisiones del sistema se basan en la geometría real de la rosca y no en variaciones del entorno, como sombras, reflejos del soporte o suciedad del campo de visión. El esquema es robusto y no necesita ajuste manual por imagen. Parte de una umbralización adaptativa de Otsu sobre la imagen en escala de grises, que separa los píxeles claros de los oscuros, y aplica a continuación un cierre morfológico con kernel 15×15 para

rellenar las pequeñas oclusiones del filo que dejan los reflejos especulares. De la máscara resultante el sistema conserva la componente conexa de mayor área, siempre que cubra al menos el 5 % del marco, con lo que descarta el ruido residual y las manchas aisladas del fondo; un filtrado por orientación elimina además las capturas mal encuadradas, al exigir que la rosca ocupe la mitad inferior de la imagen. Sobre esa máscara se traza una banda de contorno de 20 píxeles que delimita la zona del filo donde se concentra la información útil para detectar el desgaste.

El detector utiliza la red Wide-ResNet50_2 preentrenada en ImageNet como extractor de características, sin reentrenarla. Los vectores extraídos de las imágenes conformes se almacenan en un banco de memoria al que se aplica un submuestreo *coreset* al 1 %, que conserva solo los parches más representativos del espacio de normalidad y reduce el tamaño y el coste de consulta sin perder cobertura. Por su principio *one-class*, el entrenamiento no emplea validación LOO-CV: el banco se construye con la totalidad de las 130 imágenes conformes y la decisión se calibra después (4.4.4). Esta diferencia de protocolo respecto a las estrategias supervisadas se discute en el capítulo 3 y se retoma al final de 4.4.6.

4.4.4. Cómo decide conforme/desgastada

Para una imagen nueva, el score de anomalía es la distancia al parche más cercano del banco de memoria. Una imagen con zonas anómalas obtiene un score alto, sin importar el tamaño de esa zona. La decisión, en cambio, se emite a nivel de pieza, agregando los scores de sus 11 imágenes. Se han comparado tres criterios de agregación, recogidos en la Tabla 21

Las 11 imágenes de una rosca hay que resumirlas en un único veredicto. Si se marca como defectuosa en cuanto una imagen parece rara, se detecta todo, pero saltan tantas falsas alarmas que el sistema sería inservible en planta. El criterio elegido se queda con la imagen más sospechosa de cada rosca y solo avisa si supera el nivel que el 95 % de las herramientas correctas no alcanza.

Tabla 21. Comparativa de veredictos a nivel de rosca

Veredicto a nivel pieza	Accuracy	Sensibilidad	Especificidad	F1
ANY clásico	54,2%	100,0%	8,3%	68,6%
MAJORITY	41,7%	25,0%	58,3%	30,0%
MAX-POOL + umbral P95	70,8%	50,0%	91,7%	63,2%

La comparativa muestra el compromiso entre sensibilidad y especificidad propio de cada estrategia de agregación. El criterio ANY clásico marca la rosca como defectuosa si cualquiera de sus imágenes supera el umbral; con ello alcanza una sensibilidad perfecta (100%), pero su especificidad cae al 8,3%, de modo que casi todas las herramientas correctas se rechazan por error. Esa tasa de falsas alarmas lo hace inviable en una línea de producción. El voto mayoritario (MAJORITY) empeora ambas métricas (sensibilidad 25,0%, especificidad 58,3%), un comportamiento coherente con el dataset: si el 87,1% de las imágenes desgastadas equivale estadísticamente a una imagen conforme, exigir que la mayoría de las imágenes sean anómalas resulta demasiado restrictivo. La estrategia MAX-POOL con umbral P95 ofrece el mejor equilibrio: agrega los scores de las once imágenes quedándose con el máximo y aplica un único umbral calibrado en el percentil 95 de las herramientas conformes, lo que eleva la exactitud al 70,8% y la especificidad al 91,7% manteniendo una sensibilidad del 50,0%. Por ese motivo se adopta como criterio de decisión a nivel de pieza.

4.4.5. Parámetros del modelo

Tabla 22. Parámetros del modelo PatchCore

Parámetro	Valor	Qué controla
Extractor de características	Wide-ResNet50_2 (ImageNet, congelado)	Red base que describe cada parche
Preprocesado	Filtrado paso-alto rápido (BLMD_V10)	Realce del filo antes del extractor
Segmentación	Otsu + cierre 15×15 + banda 20 px	Aísla la rosca del fondo (cap. 3)
Submuestreo *coreset*	1 %	Parches que se memorizan
***Score* de imagen**	Distancia al parche más cercano	Grado de "rareza" de cada imagen
Agregación por pieza	MAX-POOL (máximo de 11 *scores*)	Combina las secciones en un veredicto
Umbral de decisión	Percentil 95 de las conformes	Frontera conforme/desgastada
Protocolo de evaluación	*One-class* (sin LOO-CV)	Cómo se mide el rendimiento

4.4.6. Resultados

4.4.6.1. Aportación de cada preprocesado

El núcleo experimental de esta sección consiste en comparar de forma cuantitativa seis pipelines de preprocesado, aplicados sobre la misma imagen de entrada y evaluados con las mismas métricas y con PatchCore como detector común. Cinco aplican algún tipo de realce o

filtrado y el sexto (SIN_PREP) actúa como control de ablación, lo que permite medir la mejora real de cada técnica frente a no preprocesar. Los pipelines son: BLMD_REAL, la descomposición Bidimensional Local Mean Decomposition rigurosa con sifting iterativo basado en splines cúbicos; BLMD_V10, una aproximación rápida tipo paso-alto basada en la sustracción de una gaussiana 15×15; BEMD_REAL, la descomposición Bidimensional Empirical Mode Decomposition; WAVELET, la transformada de Daubechies-4 con tres niveles; SOLO_HOMO, el filtrado homomórfico (σ=30, γ_low=0,5, γ_high=1,5) para mitigar reflejos especulares; y SIN_PREP, la imagen original sin procesar. La Tabla 23 reúne el rendimiento de los seis pipelines evaluado con las métricas comunes.

Tabla 23 Comparativa de los seis pipelines de procesado.

Pipeline	AUC global	AUC detect.	Acc (μ+3σ)	F1	Recall	AUPRC	T_train (s)	T_inf / img (ms)
PC_BLMD_V10	0,771	0,886	66,8 %	66,4 %	57,6 %	0,816	48,6	137
PC_SIN_PREP	0,768	0,926	64,9 %	72,9 %	73,5 %	0,804	47,5	138
PC_SOLO_HOMO	0,755	0,912	67,6 %	60,5 %	44,7 %	0,802	47,8	136
PC_BLMD_REAL	0,747	0,921	67,6 %	60,2 %	44,7 %	0,796	204,8	135
PC_WAVELET	0,735	0,937	63,7 %	66,4 %	60,6 %	0,786	49,9	138
PC_BEMD_REAL	0,566	0,802	52,7 %	45,5 %	34,1 %	0,618	52,1	136

La columna AUC detect. es una métrica de diagnóstico, no de rendimiento. Restringe el cálculo al subconjunto de imágenes que el análisis exploratorio marcó como detectables (17 de 132, 12,9 %). Como ese subconjunto se elige precisamente por contener señal separable, la cifra es optimista por construcción: sirve para distinguir el límite del modelo del límite de los datos, pero no puede utilizarse para comparar pipelines ni como cifra principal. La elección del pipeline se decide por el AUC global y el coste.

BLMD_V10 obtiene el mejor AUC global del estudio (0,771) y también el mejor AUPRC (0,816, frente a un valor de azar de 0,504), unos tres puntos por encima del baseline sin preprocesado en AUC. La aproximación rápida tipo paso-alto resulta más de cuatro veces más veloz que la implementación rigurosa BLMD_REAL (48,6 s frente a 204,8 s de entrenamiento) y, además, supera su AUC, su F1 (66,4 % frente a 60,2 %) y su recall (57,6 % frente a 44,7 %). El resultado es relevante porque la aproximación más económica computacionalmente es la preferible en este problema, y en eso reside la aportación diferencial del trabajo. El baseline SIN_PREP logra el mejor F1 (72,9 %) y recall (73,5 %) puntuales en su umbral de Youden, lo que indica que las características profundas de Wide-ResNet50_2 ya capturan parte de la señal sin realce previo; ahora bien, su AUPRC inferior (0,804 frente a 0,816) revela que BLMD_V10 mantiene alarmas de mayor calidad a lo largo de toda la curva precision-recall, y no solo en un punto de operación. Como diagnóstico, WAVELET es el que mejor capta el desgaste cuando está ópticamente presente (AUC detect. 0,937), aunque pierde rendimiento global por su menor robustez ante imágenes sin desgaste. BEMD_REAL queda por debajo del resto en todas las métricas, lo que descarta la descomposición empírica clásica para este dominio. En conjunto, BLMD_V10 ofrece el mejor compromiso global con un coste muy bajo, y eso justifica su elección como pipeline principal.

4.4.6.2. ¿Conviene recortar el fondo? Ablación con y sin máscara

Aplicar la máscara binaria al detector es una decisión de diseño con impacto potencial en el rendimiento. Para resolverla con datos, se ha evaluado el detector seleccionado (BLMD_V10 + PatchCore) sobre el dataset completo en dos configuraciones idénticas en todos sus hiperparámetros salvo en la aplicación de la máscara. Los resultados están en la Tabla 24.

Tabla 24 Ablación con y sin máscara.

Configuración	AUC global	ΔAUC
BLMD_V10 + PatchCore con máscara (fondo eliminado)	0,771	—
BLMD_V10 + PatchCore sin máscara (imagen completa)	0,862	+0,091

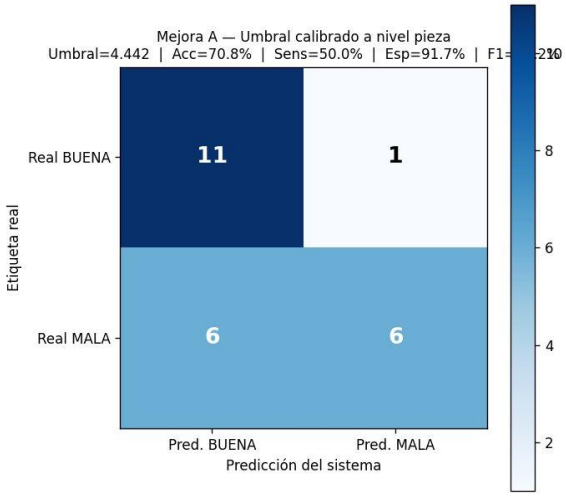
Procesar la imagen completa mejora el AUC en 0,091 puntos. Esa diferencia se explica por la información contextual que aporta el fondo (la iluminación global, la posición relativa de la rosca dentro del marco y la coherencia de los reflejos especulares), señales que el extractor Wide-ResNet50_2 incorpora a sus representaciones profundas. El problema es que esas señales dependen de las condiciones de captura del dataset y no del estado real de la rosca, por lo que constituyen una correlación potencialmente espuria cuya generalización a un entorno de producción con condiciones variables no está garantizada. Por eso la configuración final del sistema mantiene la máscara: la decisión se basa solo en los píxeles de la pieza, se preserva la interpretabilidad física del score y se elimina la dependencia del fondo. La explotación controlada de la información contextual queda señalada como línea de mejora futura.

4.4.6.3. Aciertos por pieza con el criterio MAX-POOL + P95

La matriz de confusión a nivel de rosca (Figura 18) refleja el comportamiento del criterio adoptado. Casi todas las herramientas conformes se clasifican bien, con apenas alguna falsa alarma puntual (especificidad del 91,7 %), un nivel de robustez frente a falsos positivos adecuado para un entorno productivo. En las herramientas con desgaste, el sistema detecta aproximadamente la mitad (sensibilidad del 50,0 %). Esa sensibilidad, solo aparentemente

moderada, refleja el límite físico ya descrito: como únicamente el 12,9 % de las imágenes desgastadas es ópticamente detectable, el detector no puede identificar el desgaste en herramientas cuya anomalía no aparece en ninguna de las secciones capturadas. El sistema prioriza, por tanto, no penalizar la producción conforme, y asume que una parte de las herramientas con desgaste incipiente o no visible quede sin detectar en una única inspección.

Figura 18. Matriz de confusión a nivel pieza con calibración por P95.



Fuente: Elaboración propia.

4.4.7. Nota sobre la comparabilidad de protocolos

Conviene advertir que los enfoques analizados no se someten a un marco de validación uniforme. Los modelos basados en segmentación y aprendizaje por instancias múltiples (U-Net y la combinación MIL + EfficientNet-B0) recurren a una validación cruzada dejando una pieza fuera (LOO-CV) de 24 folds, conforme a los criterios del capítulo 3. PatchCore, por su principio one-class, prescinde de esa partición: el banco de memoria se construye con la totalidad de las 130 imágenes conformes y la decisión a nivel de pieza se calibra en el percentil 95 de las puntuaciones máximas por rosca de las conformes, sin partición LOO-CV. En consecuencia, la comparación directa de las métricas absolutas debe leerse con cautela: el valor del análisis comparativo no está en la paridad de las condiciones de evaluación, sino en las tendencias de comportamiento relativo de cada estrategia.

4.4.8. Interpretabilidad: el perfilómetro y la firma física del desgaste

Una vez segmentada la pieza, el perfilómetro óptico extrae el perfil unidimensional de altura de la silueta dentada y lo compara con el perfil teórico ISO M10×1,5. De esa comparación obtiene cinco magnitudes geométricas por imagen, expresadas en las unidades físicas de la norma ISO 68-1: el área de desgaste (mm², integral del déficit de material respecto al ISO teórico), el ancho medio de la zona desgastada (µm), la profundidad máxima (µm), la desviación RMS (µm) y la desviación máxima (µm). Evaluado por sí solo como clasificador binario, el perfilómetro obtiene un AUC de 0,486 sobre el dataset completo, un valor indistinguible del azar. Por eso no se utiliza como decisor del sistema, sino como herramienta de cuantificación física que complementa al detector PatchCore y aporta interpretabilidad metrológica a los resultados.

Lo intuitivo sería pensar que una rosca gastada se aleja más del perfil teórico, pero los datos apuntan en sentido inverso. La explicación está en cómo se desgasta el filo de la rosca: una rosca nueva conserva aristas vivas y picos microestructurales que se separan localmente del ISO y generan desviaciones altas; con el uso, esas aristas disminuyen y el flanco se erosiona, de modo que la silueta tiende a aproximarse al perfil teórico, aunque la herramienta ya no corte bien. Por eso medir la semejanza con el perfil ISO no basta para detectar el desgaste; la pista útil está en la textura, y es ahí donde PatchCore acierta.

Tal y como se puede observar en la Tabla 25, las cinco métricas presentan un Cohen d negativo, aunque modesto (entre −0,11 y −0,15): las herramientas desgastadas se desvían del ISO algo menos que las conformes, con una razón mediana desgastada/conforme de 0,63× en área y 0,72× en profundidad. Esta inversión de la lógica esperada concuerda con la naturaleza física del desgaste. Una rosca nueva conserva un filo afilado con irregularidades microestructurales que se separan localmente del perfil teórico ISO y producen desviaciones elevadas; una rosca desgastada ha perdido esos picos, de modo que el flanco se erosiona y el filo se aproxima geométricamente al perfil teórico, aunque haya perdido capacidad de corte. El perfilómetro mide, por tanto, desviaciones mayores en las conformes que en las desgastadas, porque capta la microestructura agresiva del filo nuevo más que su funcionalidad. La señal es lo bastante leve como para que esta magnitud geométrica apenas

discrimine de ahí el AUC de 0,486, pero esa misma diferencia textural entre filo nuevo y filo erosionado se manifiesta como un patrón consistente en el espacio de características profundas de Wide-ResNet50_2, y es lo que PatchCore aprovecha para alcanzar un AUC de 0,771 sobre el dataset completo.

Tabla 25. Cuantificación conforme frente a desgastada frente a ISO

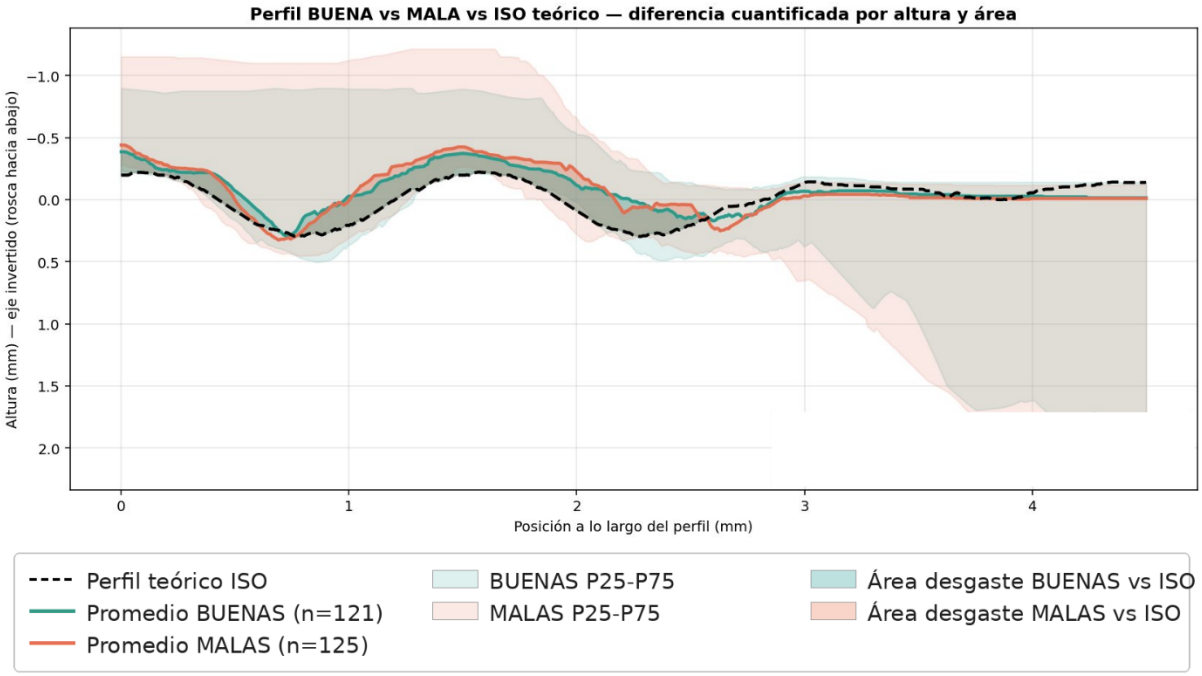
Métrica	Unidad	BUENA (mediana)	MALA (mediana)	Δ absoluto	Razón M/B	Cohen d
Desv. máxima vs ISO	µm	644,5	432,7	−211,8	0,67×	−0,14
Desv. RMS vs ISO	µm	293,0	206,6	−86,4	0,71×	−0,15
Profundidad desgaste	µm	503,3	362,3	−141,0	0,72×	−0,11
Ancho medio desgaste	µm	360,3	254,4	−105,9	0,71×	−0,13
Área desgaste	mm²	0,246	0,156	−0,090	0,63×	−0,14

Fuente: Elaboración propia.

El análisis se completa con la construcción de un perfil patrón, obtenido al promediar los perfiles 1D de roscas conformes de entrenamiento. Tiene un doble propósito: contrastar el patrón con el perfil teórico ISO para cuantificar la desviación sistemática del proceso de fabricación, y comprobar la viabilidad de un clasificador basado en la distancia de cada perfil al patrón. El procedimiento promedia 62 perfiles conformes, remuestreados a 512 puntos y alineados por correlación cruzada, y emplea una partición propia, independiente de la de PatchCore, de modo que ambas cifras corresponden a experimentos distintos y no se contradicen. El contraste entre el patrón y el ISO teórico arroja una Δ mediana de 180 µm y un área entre curvas de 0,626 mm², que cuantifican la separación sistemática entre el promedio empírico de las roscas conformes y el perfil teórico, compatible con la

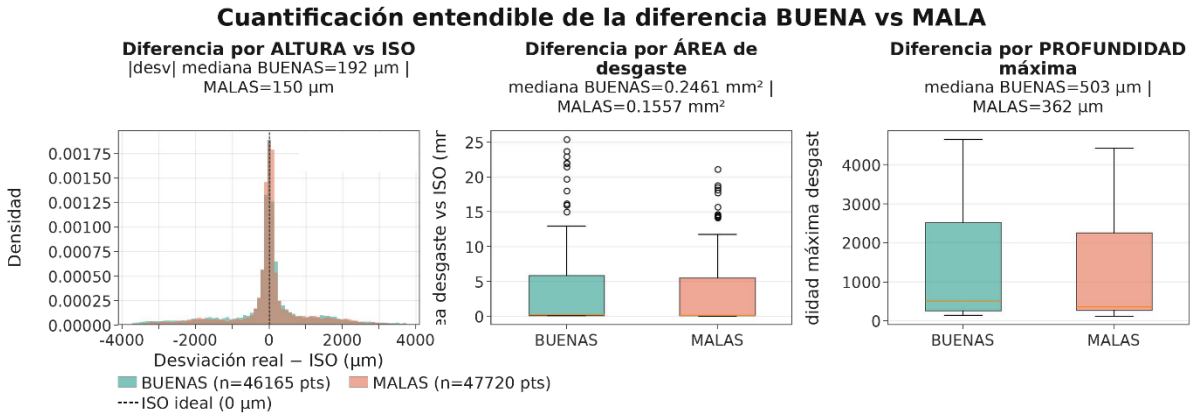
microestructura de fabricación. El perfil promedio de las herramientas conformes y desgastadas frente al ISO teórico se muestra en la Figura 19, y las distribuciones por altura, área y profundidad, en la Figura 20.

Figura 19. Perfil promedio Conforme (verde), Desgastada (naranja) e ISO teórico (línea discontinua); las bandas muestran la dispersión P25-P75 y las áreas rellenas, el déficit de material respecto al ISO.



Fuente: Elaboración propia.

Figura 20. Distribuciones por altura (izq.), área (centro) y profundidad (der.).



Fuente: Elaboración propia

Tal y como se observa en la Tabla 26 el AUC obtenido (0,489) equivale al azar, y la sensibilidad próxima a cero indica que el clasificador no distingue las herramientas defectuosas. La causa

concuerda con la interpretación física anterior: las roscas con desgaste tienen un perfil más próximo al teórico, y por tanto al patrón, que las propias conformes, debido a la pérdida de microestructura agresiva en el filo. Un clasificador basado en la distancia geométrica al patrón resulta inadecuado cuando el desgaste tiende a manifestarse como suavizado del filo más que como deformación, como ocurre en este caso. Este resultado justifica la elección de PatchCore como detector principal: captar la firma textural de la rosca, que es lo que de verdad distingue el estado nuevo del desgastado, exige un modelo capaz de operar en el espacio de características profundas y no admite una formulación puramente geométrica.

Tabla 26. Clasificador basado en distancia al perfil patrón.

Métrica	AUC	Accuracy	Sensibilidad	Especificidad
Perfil patrón (clasificador)	0,489	32,6 %	0,8 %	100,0 %

4.4.9. Limitaciones y coste computacional

La Tabla 27 muestra que el entrenamiento de PatchCore con BLMD_V10 sobre las 130 imágenes conformes del dataset (12 herramientas conformes por 11 secciones) tarda 48,7 segundos en CPU (Intel de 12 núcleos, sin GPU). La inferencia por imagen es de 138 milisegundos y el banco de memoria final ocupa 1,0 MB, lo que hace al sistema fácilmente integrable en hardware industrial estándar.

Tabla 27. Limitaciones y líneas de mejora

Limitación	Descripción	Línea de mejora
Sensibilidad moderada (50%)	Limitada por el 12,9 % de imágenes detectables, no por el modelo	Ampliar el número de secciones capturadas por pieza
Protocolo no homogéneo	PatchCore no usa LOO-CV, lo que dificulta la comparación directa con las estrategias supervisadas	Diseñar una evaluación a nivel de pieza común a todas las estrategias
Información de fondo descartada	El contexto mejora el AUC, pero es una correlación espuria	Explotación controlada del contexto sin dependencia de la captura
El perfilómetro no decide	Solo cuantifica en unidades físicas	Integrar las magnitudes físicas como evidencia auxiliar del veredicto

El sistema entrena en menos de un minuto en un PC normal, decide cada imagen en torno a 0,14 segundos y ocupa 1 MB. Se puede instalar en una línea de inspección sin equipos especiales. Su punto fuerte es que casi nunca rechaza una pieza correcta; su límite es que solo ve el desgaste cuando resulta ópticamente visible, algo que mejora al capturar más secciones de cada pieza.

4.5.COMPARATIVA GLOBAL DE LAS ESTRATEGIAS

A lo largo de los apartados anteriores se han implementado y evaluado cuatro estrategias de inteligencia artificial sobre el mismo problema: la detección del desgaste en roscas métricas M10×1,5 a partir de imágenes. Las cuatro estrategias implementadas son: (1) PatchCore con preprocesado de paso-alto BLMD_V10, que constituye el detector principal del sistema; (2) clasificación supervisada débil mediante Multiple Instance Learning con EfficientNet-B0; (3) adaptación del modelo fundacional de segmentación SAM mediante LoRA; y (4) segmentación con U-Net entrenada con máscaras sintéticas del perfil ISO.

Junto a estas cuatro estrategias se emplean además dos métodos de referencia que no toman la decisión y se incluyen solo a título informativo: la comparación directa con el perfil ISO teórico, que actúa como línea base puramente geométrica, y el perfilómetro óptico, que es el tipo de instrumento con el que la industria mide habitualmente las roscas y que aquí sirve para cuantificar el desgaste en unidades físicas (milímetros y micras). Ambos sirven de referencia para valorar cuánto aportan realmente las estrategias que sí aprenden de los datos, pero no son estrategias de detección.

Todas comparten el mismo conjunto de datos: 22 piezas (11 conformes y 11 con desgaste), de las que se han capturado 11 imágenes cada una, lo que supone 264 capturas nominales. El conjunto etiquetado final reúne 262 imágenes 130 conformes y 132 con desgaste; las dos imágenes restantes corresponden a piezas buenas y no se incorporaron al conjunto. Se reservan además 36 imágenes de estado intermedio, no empleadas en la evaluación principal.

4.5.1. Cómo se entrenó y se validó cada estrategia

Una diferencia importante entre las estrategias es la cantidad de imágenes que cada una utiliza para aprender (entrenamiento) y para comprobar su acierto (validación). No todas siguen el mismo reparto, porque su naturaleza es distinta: algunas necesitan ejemplos de las dos clases y otras aprenden solo con piezas buenas. La Tabla 28 resume, para cada estrategia, qué hace y con qué datos se entrena y se valida.

Tabla 28. Las cuatro estrategias: qué hace entrenamiento y validación

Estrategia	Qué hace	Entrenamiento	Validación
PatchCore + BLMD_V10 (estrategia principal)	Memoriza cómo es una pieza buena y avisa cuando algo no encaja con lo aprendido.	130 fotos (solo las 12 piezas buenas). No ve ningún defecto.	Se prueba con las 262 fotos (todas) y da un veredicto por pieza.
MIL + EfficientNet-B0	Mira las 11 fotos de una pieza y dice si, en conjunto, está buena o gastada.	Las otras 23 piezas cada vez: unas 251 fotos (buenas y gastadas).	Las ~11 fotos de la pieza apartada se prueban las 262 fotos.
SAM+LoRA	Dibuja las crestas y los huecos de la rosca y mide si su forma es regular.	3 roscas buenas marcadas a mano (~33 fotos; unos 40 min cada rosca).	Las roscas que no se usaron para entrenar.
U-Net + máscaras ISO	Aprende la forma ideal de la rosca y mide cuánto se aleja de ella una pieza.	Solo piezas buenas: 130 fotos (o ~119 si se aparta una buena), con la forma teórica como guía.	Las ~11 fotos de la pieza apartada se prueban las 262 fotos.

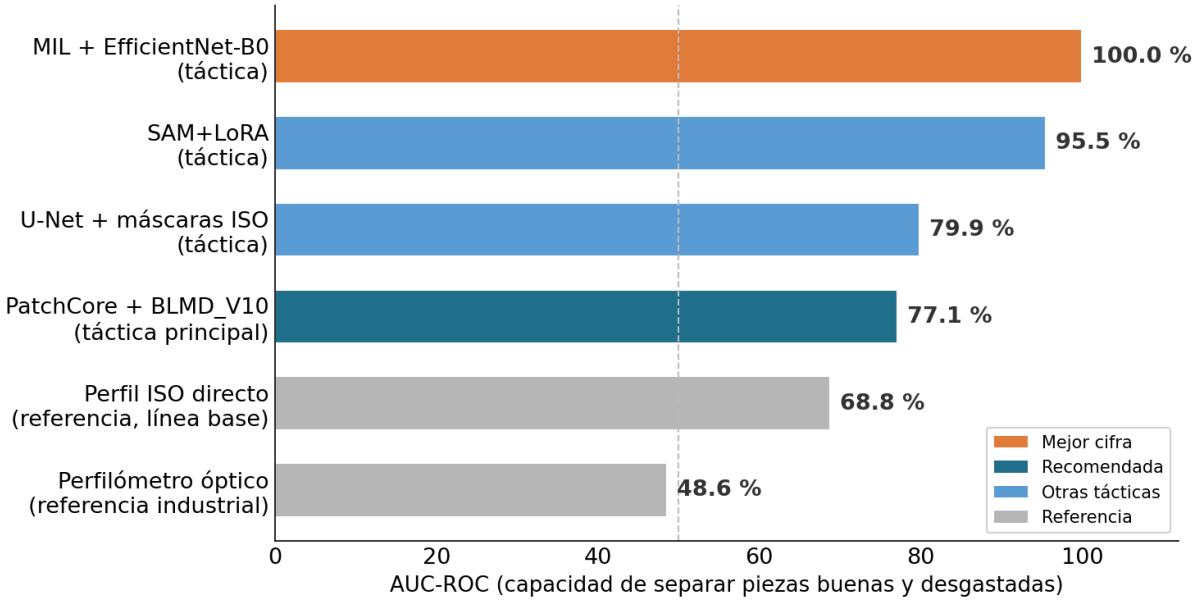
Fuente: Elaboración propia.

4.5.2. Rendimiento comparado y mejor estrategia

Para comparar el acierto de todas las estrategias se emplea el AUC-ROC, una medida entre 0 y 100 % que indica la capacidad de separar correctamente las piezas buenas de las desgastadas (50 % equivale a acertar al azar). El gráfico siguiente resume el rendimiento de las cuatro estrategias y, al final, el de los dos métodos de referencia. Debe tenerse presente que los

protocolos de validación no son idénticos entre estrategias, por lo que las cifras absolutas se interpretan como tendencias. La Figura 21 muestra comparativa cuatro estrategias frente a los métodos de referencia

Figura 21. Comparativa cuatro estrategias frente a los métodos de referencia



¿Cuál es la mejor estrategia? La respuesta depende del criterio. En cifras puras, la mejor es MIL + EfficientNet-B0, que alcanza un 100 % en todas las métricas (AUC-ROC, AUPRC y F1) sobre el conjunto de evaluación; ahora bien, con solo 22 piezas ese resultado perfecto puede esconder sobreajuste, por lo que necesita validarse con piezas nuevas antes de darlo por bueno. Si el criterio es la aplicabilidad real en una línea de producción, la estrategia recomendada es PatchCore + BLMD_V10: con un 77,1 % de AUC-ROC y, a nivel de pieza, un 70,8 % de acierto (17 de 24 piezas) y un 91,7 % de especificidad (11 de las 12 piezas buenas), ofrece el mejor equilibrio porque se entrena únicamente con piezas buenas, lo más fácil de conseguir en una fábrica, funciona en un ordenador normal sin tarjeta gráfica (48,7 s de entrenamiento y 138 ms por imagen) y casi nunca da una falsa alarma sobre una pieza buena. SAM+LoRA, con un 95,5 %, es muy competitiva e interpretable, pero su elevado coste de anotación manual la hace menos práctica de momento. U-Net, que no necesita ejemplos de piezas defectuosas, alcanza un 79,9 %, aunque su umbral de decisión queda muy cerca del

nivel de ruido y conviene afinarlo. Los dos métodos de referencia (perfil ISO directo y perfilómetro) se quedan cerca del azar, lo que confirma que la pura geometría no basta y justifica el uso de estrategias que aprenden de las imágenes.

4.5.3. Cada estrategia explicada en lenguaje sencillo

Para entender el trabajo sin necesidad de conocimientos técnicos, a continuación, se describe cada estrategia como una forma distinta de “enseñar” a un inspector automático a reconocer una rosca gastada.

PatchCore (estrategia principal). Funciona como un inspector al que solo se le enseñan piezas en buen estado hasta que memoriza perfectamente cómo deben ser. Cuando ve una pieza nueva, no busca un defecto concreto: simplemente avisa si "algo no encaja" con todo lo que ha visto antes. Se validó enseñándole las piezas buenas y pidiéndole luego que juzgara todas las piezas, dando el veredicto pieza a pieza. En la prueba final acertó en 11 de las 12 piezas buenas y detectó 6 de las 12 desgastadas: casi nunca da una falsa alarma sobre una pieza correcta, aunque deja escapar parte del desgaste que no es visible en las fotos. Su gran ventaja es que no necesita ejemplos de piezas defectuosas, que son los más difíciles de reunir en una fábrica.

SAM+LoRA. Parte de un modelo muy potente y general (sabe segmentar casi cualquier objeto) y se le da un curso intensivo para especializarlo en roscas, enseñándole a dibujar las crestas y los huecos del filete. A partir de ese dibujo mide si la rosca conserva una forma regular. Es la estrategia más transparente, ya que permite ver qué zona ha mirado para decidir, pero exige marcar a mano muchas imágenes, unos cuarenta minutos por rosca.

U-Net + máscaras ISO. En lugar de mostrarle defectos, se le enseña la forma teórica perfecta de la rosca según la norma y se le pide que la reproduzca observando solo piezas buenas. Después, ante una pieza nueva, mide cuánto se aleja de esa forma ideal aprendida. Se validó con la misma prueba de dejar una pieza fuera, repetida 24 veces.

Dos referencias para comparar (no son estrategias). El perfil ISO directo es la comparación más sencilla posible y no aprende nada: superpone la silueta real de la rosca sobre el dibujo

teórico de la norma y mide la diferencia; su acierto del 68,8 % marca el techo de lo que se puede lograr solo con geometría. El perfilómetro óptico no decide, sino que actúa como una cinta métrica de precisión del tipo que se usa en la industria para medir roscas, traduciendo el desgaste a milímetros y micras de material para que un técnico pueda entenderlo y verificarlo.

Una conclusión común a todo el trabajo, y quizá el hallazgo más importante, es que en estas herramientas el desgaste no se nota como un cambio grande de forma, sino como un cambio de textura de la superficie: una rosca nueva tiene un filo “vivo” y rugoso, y al gastarse ese filo se suaviza. Por eso las estrategias que miran la textura aprendida (PatchCore, MIL) aciertan, mientras que los métodos que solo miran la forma geométrica (perfil ISO y perfilómetro) apenas superan el azar.

5. CONCLUSIONES Y TRABAJO FUTURO

5.1. CONCLUSIONES

Este Trabajo Fin de Estudios ha abordado la detección automática del desgaste en piezas de rosca métrica M10×1,5 a partir de imágenes ópticas. El problema se ha planteado de forma deliberada como una comparativa experimental de soluciones bajo un marco común, en lugar de defender de antemano un único modelo. Sobre un mismo conjunto de 22 herramientas (11 conformes y 11 con desgaste, en torno a 262 imágenes etiquetadas a nivel de pieza) y un protocolo de validación por pieza, se han implementado y contrastado una etapa de preprocesado multiescala y cuatro estrategias de inteligencia artificial complementarias, junto con una comparación geométrica directa frente al perfil ISO empleada como línea base sin entrenamiento, evaluando no solo su precisión, sino también su robustez, su coste computacional y su interpretabilidad. Las conclusiones que se exponen a continuación se ordenan siguiendo los objetivos definidos en el capítulo 3.

En cuanto al marco experimental, se ha definido y aplicado un esquema de evaluación homogéneo, sustentado en un conjunto de datos compartido, una validación cruzada dejando una pieza fuera y un conjunto de métricas calculadas de forma global sobre las 22 muestras. Evaluar y agregar la decisión a nivel de pieza, y no de imagen, reproduce la unidad de decisión real de una línea de producción y evita las fugas de información entre entrenamiento y prueba. Conviene explicitar, no obstante, una limitación metodológica: no todas las estrategias han compartido un protocolo idéntico, ya que PatchCore se ha evaluado mediante una calibración a nivel de pieza con el percentil 95 en lugar de la validación cruzada de 22 particiones, de modo que la comparación directa de las cifras absolutas entre enfoques debe interpretarse con cautela.

La comparación de seis pipelines de preprocesado, evaluados con PatchCore como detector común, ha mostrado que la aproximación rápida de tipo paso-alto obtiene el mejor AUC global (0,771) y el mejor AUPRC (0,816), y resulta más de cuatro veces más rápida que la descomposición rigurosa (48,6 s frente a 204,8 s de entrenamiento), a la que además supera en F1 y en recall. La descomposición empírica bidimensional ofrece el peor rendimiento (AUC

0,566), lo que la descarta para este dominio, mientras que la transformada wavelet destaca sobre el subconjunto ópticamente detectable (AUC 0,937). De esta comparación se desprende que un filtrado computacionalmente económico que realce el filo resulta suficiente, por lo que la costosa descomposición multiescala rigurosa no queda justificada en este problema; este hallazgo, que invierte la expectativa de partida, constituye una de las aportaciones diferenciales del trabajo.

En cuanto a las estrategias de inteligencia artificial, se ha observado una gradación clara del rendimiento, ligada al nivel de supervisión disponible y al tipo de señal explotada. El aprendizaje de instancias múltiples con EfficientNet-B0, supervisado con ejemplos de ambas clases, alcanza una separación perfecta en el conjunto de evaluación, con AUC-ROC, AUPRC y F1 iguales a 1,0. La red U-Net, entrenada únicamente con herramientas conformes y máscaras sintéticas derivadas del perfil ISO, llega a un AUC de 0,80, y la comparación directa con el perfil ISO, sin entrenamiento alguno, se queda en 0,69. PatchCore, como detector de una sola clase, obtiene un AUC de 0,771 que, agregado a nivel de rosca mediante max-pooling y umbral en el percentil 95, ofrece una especificidad del 91,7 % y una sensibilidad del 50 %. La adaptación del modelo fundacional de segmentación mediante SAM+LoRA aporta, por su parte, una segmentación interpretable con un AUC de hasta 0,955 en configuraciones favorables. La distancia entre la geometría pura (0,69) y la representación aprendida (1,0) cuantifica de forma directa el valor añadido de aprender sobre las imágenes de este conjunto.

Más allá de las cifras, el conjunto de experimentos converge en un hallazgo no evidente sobre la naturaleza física del fenómeno: en este conjunto de datos el desgaste se manifiesta sobre todo como un cambio de textura superficial y de reflectancia, y no como una deformación macroscópica del perfil binario. De forma contraintuitiva, las herramientas desgastadas presentan perfiles más próximos al ISO teórico que las propias conformes, ya que el tamaño del efecto, medido mediante la d de Cohen, es negativo en todas las métricas geométricas, con una razón mediana entre herramientas desgastadas y conformes en torno a 0,63 en área. Esto se debe a que el filo nuevo pierde, al desgastarse, su microestructura agresiva de aristas vivas. La interpretación explica por qué fracasan los clasificadores puramente geométricos: el perfilómetro alcanza un AUC de 0,486 y el clasificador por distancia al perfil patrón, un AUC de 0,489, ambos indistinguibles del azar, mientras que las características texturales profundas

extraídas por PatchCore y EfficientNet-B0 sí discriminan. Este es, probablemente, el aporte más relevante del trabajo, porque reorienta el problema desde la metrología del perfil hacia la caracterización de la textura de la superficie.

Este comportamiento se enmarca, además, en un límite intrínseco de detectabilidad del propio conjunto: el análisis exploratorio revela que solo el 12,9 % de las imágenes de herramientas desgastadas (17 de 132) resulta ópticamente detectable y que el 87,1 % restante es estadísticamente equivalente a una imagen conforme. Ese techo explica la sensibilidad moderada a nivel de pieza y fija unas expectativas realistas, ya que ningún método basado en una sola imagen puede detectar un desgaste que no aparece en ninguna de las secciones capturadas de la rosca. Por ello, el sistema se ha diseñado para priorizar la no penalización de la producción conforme, asumiendo que una fracción de las herramientas con desgaste incipiente o no visible quede sin detectar en una única inspección. A esa robustez frente a falsos positivos se suma una vocación de interpretabilidad: el sistema trasciende la mera etiqueta binaria mediante los mapas Grad-CAM++, los mapas de anomalía, las máscaras de segmentación, las métricas geométricas referidas a la norma ISO 68-1 y las visualizaciones unificadas en cuatro paneles, integradas en aplicaciones web interactivas, que hacen cada decisión trazable y revisable. Desde la perspectiva de la producción, PatchCore con preprocesado de paso-alto se entrena en 48,7 s sobre CPU, infiere en 138 ms por imagen y ocupa un banco de memoria de 1 MB, lo que lo hace integrable en hardware industrial estándar sin necesidad de GPU.

Estos resultados deben leerse, no obstante, con la prudencia que impone el tamaño del conjunto. El resultado perfecto del aprendizaje de instancias múltiples con EfficientNet-B0 podría reflejar, con solo 22 muestras, un sobreajuste a las características específicas del conjunto de evaluación, por lo que validarlo sobre herramientas nuevas y sobre las 36 imágenes de estado intermedio reservadas resulta necesario antes de afirmar capacidad de generalización; del mismo modo, la ausencia de medidas numéricas de desgaste de flanco de referencia mantiene las métricas geométricas en un plano exploratorio. El trabajo ha demostrado la viabilidad de la visión artificial combinada con aprendizaje profundo para detectar el desgaste sin recurrir a metrología de laboratorio costosa, ha establecido que los enfoques aprendidos basados en textura dominan a los puramente geométricos en este

problema y, sobre todo, ha identificado la naturaleza física de la señal de desgaste, aunque el despliegue industrial pleno exija ampliar los datos y validar la robustez en condiciones reales.

5.2. LÍNEAS DE TRABAJO FUTURO

Los resultados obtenidos y las limitaciones identificadas a lo largo del trabajo perfilan varias líneas de continuación, que pueden ordenarse de mayor a menor proximidad respecto al estado actual del sistema.

La más inmediata es la ampliación y validación del conjunto de datos. Resulta prioritario incorporar más herramientas y, sobre todo, capturas en condiciones industriales reales, con presencia de taladrina, virutas adheridas, vibraciones, sombras y brillos del metal, así como evaluar las 36 imágenes de estado intermedio reservadas, tanto para medir la robustez del sistema ante casos ambiguos como para calibrar un nivel de alerta intermedio. En esa misma dirección se sitúan la validación externa del aprendizaje de instancias múltiples, que permitiría descartar el sobreajuste que sugiere su resultado perfecto, y la incorporación de medidas numéricas de desgaste de flanco mediante microscopio digital o máquina de medición por coordenadas, lo que haría posible calcular el error absoluto medio y convertir las métricas geométricas, hoy exploratorias, en una cuantificación metrológica validada.

En el plano algorítmico, el propio desarrollo ha dejado señaladas mejoras concretas. En la U-Net conviene sustituir la función de pérdida de entropía cruzada binaria por una combinación con el coeficiente de Dice, que contrarreste el desequilibrio de clases material/vacío (85 % frente a 15 %) y aumente la separabilidad de las puntuaciones, y en el generador de máscaras sintéticas debe corregirse el parámetro de ancho de valle para que la geometría reproducida cierre el paso y coincida con la norma. Conviene además adoptar una calibración de umbral más robusta que el percentil 95 o el índice de Youden, sensible al coste o adaptada a cada condición de adquisición, dado que los umbrales óptimos observados se sitúan muy cerca del nivel de ruido. Sobre esta base, y puesto que las señales explotadas son complementarias, parece natural explorar la combinación de estrategias, ya que PatchCore captura la textura, el perfilómetro cuantifica la geometría y el aprendizaje de instancias múltiples aprende patrones discriminativos: una fusión jerárquica o por voto ponderado podría elevar la sensibilidad preservando la elevada especificidad que exige el entorno productivo, e incluso aprovechar

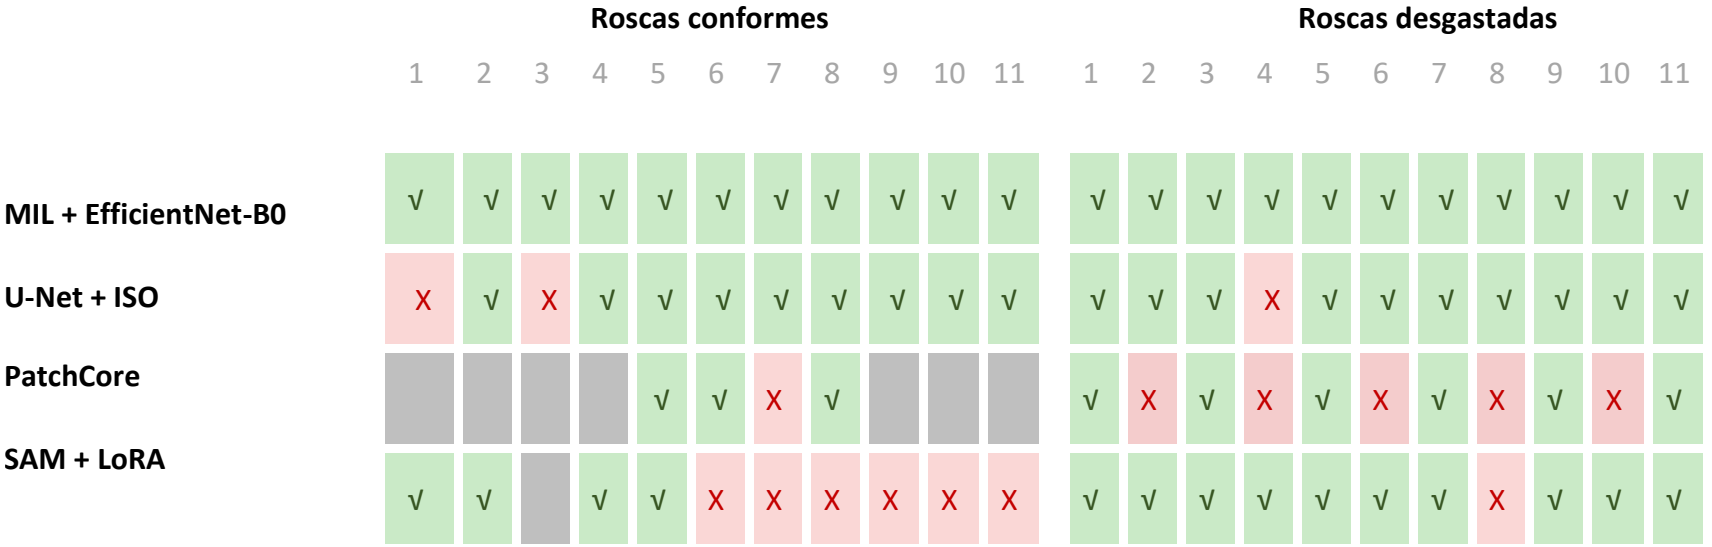
de forma controlada la información contextual del fondo, responsable de una mejora de 0,091 de AUC, sin introducir una dependencia espuria de las condiciones de adquisición.

A medio plazo, dos vías permitirían superar las limitaciones intrínsecas del análisis por imagen aislada. El modelado temporal del desgaste sustituiría el examen independiente de cada captura por el seguimiento de la trayectoria de cada pieza a lo largo de los ciclos de mecanizado, mediante arquitecturas recurrentes o de atención, lo que abordaría la detección temprana del desgaste progresivo que apenas se aprecia en una sola imagen. La integración multimodal, por su parte, combinaría la visión con señales del proceso y del control numérico, como las fuerzas de corte, la vibración o la emisión acústica, para compensar el elevado porcentaje de imágenes no detectables visualmente y ganar robustez en entornos complejos, aun a costa de una mayor complejidad de integración y de la necesidad de datos sincronizados.

De cara a la explotación industrial, conviene además estudiar arquitecturas de muy baja latencia y despliegue en el borde que sitúen la decisión de parada antes de que se fabriquen piezas defectuosas, y reducir el coste de anotación de la estrategia SAM+LoRA, que ha requerido alrededor de 40 minutos por pieza, integrando un modelo de IA generativa como backend de la pieza de anotación Label Studio. Con este esquema, el modelo genera de forma automática una primera segmentación de cresta y paso para cada imagen, y el operario solo necesita revisarla a mano para corregir, mejorar o adaptar las etiquetas si es necesario, en lugar de anotar desde cero. Esta anotación asistida con revisión humana reduce de forma drástica el tiempo de etiquetado y mantiene el control de calidad sobre las máscaras, lo que hace la estrategia escalable a conjuntos mayores. En esta línea de aliviar la escasez de datos se inscriben también el recurso a modelos generativos de difusión para sintetizar imágenes de herramientas desgastadas y el uso de variantes más capaces de los modelos fundacionales bajo esquemas few-shot. Por último, la generalización del sistema a otros tamaños y tipos de rosca, y a machos, fresas y brocas, se ve facilitada por el carácter paramétrico de los enfoques basados en la norma, independientes de la geometría concreta por configuración, lo que permitiría transferirlo a nuevas herramientas con cambios mínimos

MIL + EfficientNet-B0	U-Net + ISO	PatchCore	SAM + LoRA
22/22	**19/22**	**16/22**	**14/22**

√ Acierto X Fallo Entreno



Referencias bibliográficas

Alhabshan, F. (2023). Optical Measurement of Tool Wear Parameters: Leveraging Machine Vision. *Optometry: Open Access*, *8*(1), 201. https://doi.org/10.4172/2476-2075.1000201

An, F.-P. (2019). Image feature extraction algorithm based on bi-dimensional local mean decomposition. *Optical Review*, *26*(1), 43–64. https://doi.org/10.1007/s10043-018-0477-5

Astakhov, V. P. (2010). *Geometry of Single-point Turning Tools and Drills* (1st ed.). Springer London. https://doi.org/10.1007/978-1-84996-053-3

Batzner, K., Heckler, L., & König, R. (2024). *EfficientAD: Accurate Visual Anomaly Detection at Millisecond-Level Latencies*. http://arxiv.org/abs/2303.14535

Bayoudh, K., Knani, R., Hamdaoui, F., & Mtibaa, A. (2022). A survey on deep multimodal learning for computer vision: advances, trends, applications, and datasets. *The Visual Computer*, *38*(8), 2939–2970. https://doi.org/10.1007/s00371-021-02166-7

Bian, Z. (2024). Surface Defect Detection of Mining Automation Equipment Based on Convolutional Neural Networks. *Applied Mathematics and Nonlinear Sciences*. https://doi.org/10.2478/amns-2024-3500

Bilal, M., Podishetti, R., Koval, L., Gaafar, M. A., Grossmann, D., & Bregulla, M. (2024). Automatized End Mill Wear Inspection Using a Novel Illumination Unit and Convolutional Neural Network. *IEEE Access*, *12*, 124282–124297. https://doi.org/10.1109/ACCESS.2024.3454692

Cheng, Y., Wang, Y., & Hu, Y. (2009). Image enhancement algorithm based on Retinex for Small-bore steel tube butt weld's X-ray imaging. *WSEAS Transactions on Mathematics*, *8*, 279–288. https://www.wseas.us/e-library/transactions/mathematics/2009/29-295.pdf

Dornfeld, D. (2019). *Precision Manufacturing*. Scholars Portal.

Hifly Technology (Shenzhen) Co., Ltd. (2026, January 7). *Application of Polarizers and Polarized Lights in Machine Vision Inspection Projects*. https://www.szhifly.com/application-of-polarizers-and-polarized-lights-in-machine-vision-inspection-projects

Holgado, M. M. M. E. S. (2023). International journal of computer integrated manufacturing. *International Journal of Production Research*, *58*(23), 7292–7310. https://doi.org/10.1080/00207543.2020.1808257

International Organization for Standardization. (2023a). *ISO general purpose screw threads — Basic and design profiles — Part 1: Metric screw threads (ISO 68-1:2023)*. https://www.iso.org/standard/85107.html

International Organization for Standardization. (2023b). *ISO general purpose metric screw threads — Basic dimensions (ISO 724:2023)*.

Jang, Y. J., & Lee, J. S. (2013). *Camera for detecting metal surface defects, device for detecting metal surface defects including the camera, and method for detecting metal surface defects* (Number WO2013012106A1). https://patents.google.com/patent/WO2013012106A1/en

Jiang, Z., Zhang, Y., Wang, Y., Li, J., & Gao, X. (2024). FR-PatchCore: An Industrial Anomaly Detection Method for Improving Generalization. *Sensors*, *24*(5). https://doi.org/10.3390/s24051368

Kamat, P., Kumar, S., & Kotecha, K. (2024). DeepTool: A deep learning framework for tool wear onset detection and remaining useful life prediction. *MethodsX*, *13*. https://doi.org/10.1016/j.mex.2024.102965

Khan, I. U., Aslam, N., Aboulnour, M., Bashamakh, A., Alghool, F., Alsuwayan, N., Alturaif, R., Gull, H., Iqbal, S. Z., & Hussain, T. (2024). Deep Learning-Based Surface Defect Detection in Steel Products Using Convolutional Neural Networks. *Mathematical Modelling of Engineering Problems*, *11*(11), 3006–3014. https://doi.org/10.18280/mmep.111113

Li, Z., Huo, D., Meurer, M., & Bergs, T. (2024, June 17). Efficient Cutting Tool Wear Segmentation Based on Segment Anything Model. *Volume 2: Manufacturing Equipment and Automation; Manufacturing Processes; Manufacturing Systems; Nano/Micro/Meso Manufacturing; Quality & Reliability*. https://doi.org/10.1115/MSEC2024-124455

Li, Z., Huo, D., Meurer, M., Panesso, M., Drossel, W.-G., & Bergs, T. (2025). Enhancing Tool Wear Segmentation with LoRA-SAM and Point Prompts. *Procedia CIRP*, *134*, 705–710. https://doi.org/10.1016/j.procir.2025.02.184

Lin, W. J., Chen, J. W., Jhuang, J. P., Tsai, M. S., Hung, C. L., & Li, K. M. (2021). Integrating object detection and image segmentation for detecting the tool wear area on stitched image. *Scientific Reports*, *11*(1). https://doi.org/10.1038/s41598-021-97610-y

Liu, T., Li, B., Jin, X., Shi, Y., Li, Q., & Wei, X. (2025). *Exploring Few-Shot Defect Segmentation in General Industrial Scenarios with Metric Learning and Vision Foundation Models*. http://arxiv.org/abs/2502.01216

Lu, Y., & Lu, R. (2018). Fast Bi-dimensional empirical mode decomposition as an image enhancement technique for fruit defect detection. *Computers and Electronics in Agriculture*, *152*, 314–323. https://doi.org/10.1016/j.compag.2018.07.025

Molitor, D. A., Kubik, C., Hetfleisch, R. H., & Groche, P. (2021). *Workpiece Image-based Tool Wear Classification in Blanking Processes Using Deep Convolutional Neural Networks*. https://doi.org/10.1007/s11740-022-01113-2

Mrinal Sarvagya, M G, R. K., & M J, A. (2024). HOMOMORPHIC FILTERING-BASED REFLECTION COMPENSATION AND BINARY THRESHOLDING DURING THE PREPREG-BASED COMPOSITE MANUFACTURING. *Journal of Manufacturing Engineering*, *19*(2), 030–036. https://doi.org/10.37255/jme.v19i2pp030-036

Nie, C., Xu, C., Li, Z., Chu, L., & Hu, Y. (2023). Specular Reflections Detection and Removal for Endoscopic Images Based on Brightness Classification. *Sensors*, *23*(2), 1032. https://doi.org/10.3390/s23021032

NIE, X., & YU, C. (2025). Few-Shot Learning for Industrial Defect Detection Using Meta-Learning Techniques. *International Journal of Scientific Research and Management (IJSRM)*, *13*(06), 2301–2318. https://doi.org/10.18535/ijsrm/v13i06.ec08

Nunes, J.-C., & Deléchelle, É. (2009). EMPIRICAL MODE DECOMPOSITION: APPLICATIONS ON SIGNAL AND IMAGE PROCESSING. *Advances in Adaptive Data Analysis*, *01*(01), 125–175. https://doi.org/10.1142/S1793536909000059

Singh, D. K., & Pant, D. R. (2025). Five shot and Ten Shot Analysis for Anomaly Detection of Video Scenes. *Journal of Advanced College of Engineering and Management*, *11*, 47–59. https://doi.org/10.3126/jacem.v11i1.84526

Sumanto, S., Buono, A., Priandana, K., Paruhum Silalahi, B., & Sri Hendrastuti, E. (2023). Texture Analysis of Citrus Leaf Images Using BEMD for Huanglongbing Disease Diagnosis. *Jurnal Online Informatika*, *8*(1), 115–121. https://doi.org/10.15575/join.v8i1.1075

Sun, Y., Yin, S., Teng, L., & Liu, J. (2018). Study on Wavelet Transform Adjustment Method with Enhancement of Color Image. *Journal of Information Hiding and Multimedia Signal Processing*, *9*(3), 606–614. https://bit.kuas.edu.tw/2018/vol9/JIH-MSP-2018-03-010.pdf

Vishwanatha, J. S., Srinivasa Pai, P., D'Mello, G., Sampath Kumar, L., Bairy, R., Nagaral, M., Channa Keshava Naik, N., Lamani, V. T., Chandrashekar, A., Yunus Khan, T. M., Almakayeel, N., & Ahmad Khan, W. (2024). Image-processing-based model for surface roughness evaluation in titanium based alloys using dual tree complex wavelet transform and radial basis function neural networks. *Scientific Reports*, *14*(1), 28261. https://doi.org/10.1038/s41598-024-75194-7

Wang, R. (2022). Exploring Wavelet Transform-Based Image Enhancement Algorithm for Image Restoration of Long March National Cultural Park. *Journal of Environmental and Public Health*, *2022*, 1434763. https://doi.org/10.1155/2022/1434763

Wu, X., Liu, Y., Zhou, X., & Mou, A. (2019). Automatic identification of tool wear based on convolutional neural network in face milling process. *Sensors (Switzerland)*, *19*(18). https://doi.org/10.3390/s19183817

Wu, Y., & Chen, B. (2026). Real time diagnosis and prediction of tool wear in mechanical machining based on deep learning. *Diagnostyka*, *27*(1), 1–19. https://doi.org/10.29354/diag/219836

Yu, J., Cheng, X., Lu, L., & Wu, B. (2021). A machine vision method for measurement of machining tool wear. *Measurement*, *182*, 109683. https://doi.org/10.1016/j.measurement.2021.109683

Yu, J., Zheng, Y., Wang, X., Li, W., Wu, Y., Zhao, R., & Wu, L. (2021). *FastFlow: Unsupervised Anomaly Detection and Localization via 2D Normalizing Flows*. http://arxiv.org/abs/2111.07677

Zhang, J., & Regtien, P. P. L. (2007). Illumination methods for optical wear detection. In *MEASUREMENT SCIENCE REVIEW* (Vol. 7, Number 3).

Zhang, X. (2020). *Coventry University DOCTOR OF PHILOSOPHY Deep Learning Driven Tool Wear Identification and Remaining Useful Life Prediction*.

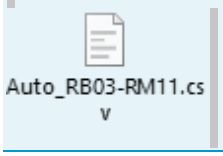
Zhao, W., Chen, F., Huang, H., Li, D., & Cheng, W. (2021). A New Steel Defect Detection Algorithm Based on Deep Learning. *Computational Intelligence and Neuroscience*, *2021*(1). https://doi.org/10.1155/2021/5592878

Zhou, H. (2024). Exploring Feature Detection: A Comparative Study of Classical and Deep Learning Methods Across Complex Scenes. *Applied and Computational Engineering*, *105*(1), 57–73. https://doi.org/10.54254/2755-2721/105/2024tj0068

Anexo A. Código fuente y datos analizados

Enlace a repositorio: https://github.com/MVod/MVod-TFM

Csv de omparación de métricas para la detección de desgaste en roca en estrategia SAM + Lora



Anexo B. Glosario

Término	Definición técnica	En lenguaje de taller
BLMD (Bidimensional Local Mean Decomposition)	Descomposición multiescala que separa la imagen en componentes de baja y alta frecuencia adaptadas a su propia distribución de intensidades, concentrando el detalle fino del filo en la banda alta.	Filtro que limpia la foto y resalta los detalles del filo de la rosca, separando lo importante del brillo y las sombras.
BLMD_V10 (paso-alto)	Aproximación rápida tipo paso-alto basada en restar una gaussiana 15×15; realza bordes con coste mínimo.	Versión rápida y barata del filtro anterior: hace casi lo mismo en una fracción del tiempo.

Término	Definición técnica	En lenguaje de taller
BEMD (Bidimensional Empirical Mode Decomposition)	Descomposición empírica y adaptativa que extrae funciones de modo intrínseco (IMF) sin funciones base predefinidas.	Otro filtro que separa la imagen en capas; en este trabajo fue el que peor funcionó.
Wavelet	Transformada multiescala con base matemática fija (Daubechies-4) que descompone la imagen en niveles de frecuencia.	Filtro clásico que separa la imagen en niveles de detalle; útil solo cuando el desgaste ya se ve.
Filtrado homomórfico	Corrección de iluminación en el dominio logarítmico que atenúa la componente lenta de luz y conserva la reflectancia.	Truco para igualar la luz de la foto y quitar reflejos antes de analizarla.
SAM+LoRA	Modelo fundacional de segmentación (SAM) especializado al dominio de roscas mediante adaptación de bajo rango (LoRA) en las capas de atención.	Un modelo general muy potente al que se le da un curso intensivo barato para que aprenda a “dibujar” las roscas.
MIL (Multiple Instance Learning)	Clasificación supervisada débil: se etiqueta el conjunto (la pieza con sus secciones) y no cada imagen, y el modelo aprende qué vistas son reveladoras.	Se le enseña la pieza entera diciéndole solo si está buena o gastada, sin señalarle en qué foto está el daño.

Término	Definición técnica	En lenguaje de taller
EfficientNet-B0	Red neuronal convolucional eficiente usada como extractor de características dentro del enfoque MIL.	El "motor" de reconocimiento que mira las fotos y aprende a distinguir buena de gastada.
U-Net	Red de segmentación que aprende la forma teórica de la rosca (máscara ISO) usando solo piezas buenas y mide la desviación de cada pieza nueva.	Aprende cómo debería ser una rosca perfecta y mide cuánto se aleja la pieza inspeccionada.
PatchCore	Detector de anomalías one-class: memoriza parches de piezas conformes en un banco y puntúa cada imagen por su distancia al parche más cercano.	Inspector al que solo se le enseñan piezas buenas; luego avisa cuando algo "no encaja".
Perfil ISO directo	Comparación geométrica pura, sin entrenamiento, entre la silueta real de la rosca y el perfil teórico de la norma.	La comparación más simple: superponer la rosca real sobre el dibujo de la norma y medir la diferencia.
Perfilómetro óptico	Herramienta de cuantificación que mide el perfil real frente al ISO teórico en unidades físicas (mm y µm).	Una "cinta métrica" de precisión que traduce el desgaste a milímetros y micras.

Término	Definición técnica	En lenguaje de taller
AUC-ROC	Área bajo la curva ROC; capacidad de separar dos clases con independencia del umbral (0,5 = azar; 1,0 = perfecto).	Nota de 0 a 100 % de lo bien que el sistema distingue una pieza buena de una gastada.
AUPRC	Área bajo la curva precisión-recall; mide la calidad de las alarmas, útil cuando las clases están desbalanceadas.	Nota que premia que las alarmas sean fiables, no solo numerosas.
F1	Media armónica de precisión y recall; equilibra falsos positivos y falsos negativos en un punto de operación.	Nota global que combina "no dar falsas alarmas" con "no dejar escapar defectos".
Sensibilidad (recall)	Proporción de piezas defectuosas correctamente detectadas.	De cada 100 piezas gastadas, cuántas consigue cazar el sistema.
Especificidad	Proporción de piezas buenas correctamente clasificadas como buenas.	De cada 100 piezas buenas, cuántas deja pasar sin falsa alarma.
IoU (Intersection over Union)	Solapamiento entre la máscara predicha y la de referencia; mide la calidad de la segmentación.	Cómo de bien encaja el "dibujo" del modelo con la forma real de la rosca.

Término	Definición técnica	En lenguaje de taller
LOO-CV (Leave-One-Out)	Validación cruzada en la que cada pieza se aparta una vez para prueba y se entrena con las restantes 22 herramientas.	Prueba exigente: se examina con una pieza nunca vista al aprender, repitiéndolo con todas.
Umbral P95	Línea de decisión calibrada en el percentil 95 de las puntuaciones de las piezas buenas.	El listón se pone dónde queda el 95 % de las piezas buenas, para no llenar la línea de falsas alarmas.
Grad-CAM	Mapa de calor que indica qué regiones de la imagen más influyeron en la decisión de la red.	Muestra en colores en qué zona de la rosca se ha fijado el sistema para decidir.
Memory bank / coreset	Banco de características de piezas buenas, reducido a un 1 % representativo mediante muestreo coreset.	El “archivo de referencia” de cómo son las piezas buenas, resumido para que ocupe poco y vaya rápido.
Máscara ISO	Imagen binaria generada matemáticamente con la geometría perfecta de la rosca según la norma.	El dibujo ideal de cómo debería ser la rosca, usado como patrón de comparación.
Otsu	Método de umbralización automática que separa objeto y fondo maximizando la varianza entre clases.	Truco para separar la rosca del fondo de la foto sin ajustar nada a mano.

Término	Definición técnica	En lenguaje de taller
ROI (Region of Interest)	Región de la imagen que contiene la rosca, aislada del fondo antes del análisis.	La zona útil de la foto: solo la rosca, sin fondo ni ruido.
Fold	Cada una de las particiones de la validación cruzada (en este trabajo, cada vuelta deja una pieza fuera).	Cada "vuelta" del examen, en la que se aparta una pieza distinta.
Coeficiente de variación (CV)	Cociente entre desviación típica y media; mide la regularidad de las áreas de cresta segmentadas.	Indica si las crestas de la rosca son parecidas entre sí o muy irregulares (señal de desgaste).